DESARROLLO DE UN MODELO ESTADÍSTICO PARA PREDECIR EL EFECTO DE LA MÚSICA EN LA SALUD MENTAL

Eduardo García Alfonso
2024

Abstract

En el presente trabajo se analizará la relación existente entre los hábitos de escucha de música de ciertas personas y su salud mental. Para ello, se procederá a desarrollar un modelo que permita predecir si los síntomas mejorarán en función de dichos hábitos. Se utilizó una base de datos de acceso libre, en la cual 736 personas fueron encuestadas sobre diversas variables sobre sus costumbres y gustos a la hora de escuchar música, y sobre su salud mental. Los modelos desarrollados se aplicarán a una nueva encuesta idéntica a 172 personas, para comprobar si los resultados son reproducibles de forma satisfactoria.

Para muchos, la capacidad de la música para llegar hasta lo más hondo de uno mismo y de sonsacarle emociones complejas y reales es una parte importante del lugar que ocupa en su vida.

(Hellmuth Margulis, 2019)

ÍNDICE

1. INTRODUCCIÓN 1

1.1 RESUMEN DE LOS DATOS UTILIZADOS 1

1.2 VARIABLES DE LA BASE DE DATOS 1

1.2.1 Variables generales sobre el encuestado 1
1.2.2 Variables sobre la frecuencia con la que el encuestado escucha cada género musical 2
1.2.3 Variables sobre la salud mental del encuestado 2

1.3 TRANSFORMACIÓN DE LAS VARIABLES 3

1.3.1 Variables binarias y ordinales 3
1.3.2 Datos faltantes 3

2. ANÁLISIS PREVIOS 6

2.1 ANÁLISIS DE LAS VARIABLES 6

2.1.1 Variables numéricas 6
2.1.2 Variables categóricas 8
2.1.3 Variables ordinales 10
2.1.4 Variables sobre salud mental 10

2.2 RELACIONES ENTRE VARIABLES 12

2.2.1 Relaciones con la edad 12
2.2.2 Relaciones con las horas diarias 14
2.2.3 Relaciones entre las variables binarias 15
2.2.4 Relaciones entre los trastornos de salud mental 15
2.2.5 Análisis de componentes principales (PCA) 16

3. MODELOS CON LAS VARIABLES DE SALUD MENTAL 20

3.1 REGRESIONES NUMÉRICAS CON LAS VARIABLES DE SALUD MENTAL COMO RESPUESTA 20

3.1.1 Ansiedad como variable respuesta 20
3.1.2 Depresión como variable respuesta 22
3.1.3 Insomnio como variable respuesta 24
3.1.4 Trastorno Obsesivo-Compulsivo como variable respuesta 26
3.1.5 Suma de las variables de salud mental 27

3.2 RELACIÓN DE LAS VARIABLES DE SALUD MENTAL CON EL EFECTO 30

4. MODELOS PREDICTIVOS 32

4.1 ÁRBOLES DE DECISIÓN 32

4.1.1 Árboles de decisión con respuesta categórica triple 32
4.1.2 Árboles de decisión con respuesta binaria 35

4.2 RANDOM FOREST 39

4.2.1 Random Forest con respuesta categórica triple 39
4.2.2 Random Forest con respuesta binaria 41

4.3 MÁQUINAS DE VECTOR SOPORTE (SVM) 43

4.4 REGRESIÓN LOGÍSTICA 44

4.5 VALIDACIÓN CRUZADA K-FOLD 46

4.6 BOOTSTRAPPING **47**

4.7 BOOSTED TREE **48**

4.8 k-NEAREST NEIGHBOURS (kNN) **49**

5. MODELOS PREDICTIVOS CON DATOS COMPENSADOS ***51***

5.1 OBTENCIÓN DE DATOS EQUILIBRADOS **51**

5.2 RANDOM FOREST **51**

5.3 MÁQUINAS DE VECTOR SOPORTE (SVM) **53**

5.3.1 SVM Lineal 54

5.3.2 SVM Polinómica 54

5.3.3 SVM Radial 54

5.4 REGRESIÓN LOGÍSTICA **55**

5.5 BOOTSTRAPPING **57**

6. APLICACIÓN DE LOS MODELOS PREDICTIVOS ***58***

6.1 ELABORACIÓN DE UNA NUEVA ENCUESTA **58**

6.2 COMPARACIÓN ENTRE POBLACIONES **58**

6.3 PREDICCIONES CON LOS DATOS ORIGINALES **61**

6.4 PROGRAMACIÓN DE UN NUEVO MODELO kNN **64**

6.5 PREDICCIONES CON LOS DATOS COMPENSADOS **66**

7. CONCLUSIONES ***68***

8. BIBLIOGRAFÍA ***69***

ANEXO I. Código utilizado ***70***

1. INTRODUCCIÓN

1.1 RESUMEN DE LOS DATOS UTILIZADOS

Los datos fueron obtenidos del siguiente sitio web:

https://www.kaggle.com/datasets/catherinerasgaitis/mxmh-survey-results

La encuesta fue realizada por Catherine Rasgaitis, de la Universidad de Washington, Estados Unidos, mediante un formulario de Google Form entre el 27 de julio y el 11 de agosto de 2022.

Estos son los datos que se utilizarán para desarrollar diversos modelos predictivos, que se aplicarán después a una nueva encuesta realizada en agosto de 2024 con las mismas variables de esta encuesta original.

Los datos originales son un archivo en formato csv volcado directamente de las respuestas de la encuesta, por lo que incluyen 33 columnas, que se corresponden con las 31 variables, el momento en el que se envió cada formulario individual, y una última pregunta de consentimiento para publicar los resultados de los análisis de datos de forma anónima.

Las dos columnas anteriormente mencionadas que no se corresponden con variables se ignoraron, y se renombraron las variables para su mayor facilidad de utilización en el código. A continuación, se exponen los nombres utilizados para estas variables, sus tipos y una breve descripción de cada una.

1.2 VARIABLES DE LA BASE DE DATOS

1.2.1 Variables generales sobre el encuestado

- age: Edad del encuestado (numérica).
- stream: Servicio de streaming musical más utilizado por el encuestado (categórica, opciones: “Spotify”, “Youtube Music”, “Apple Music”, “Pandora”, “Otro servicio de streaming” y “No suelo escuchar música en servicios de streaming”).
- hours: Horas diarias que el encuestado escucha música (numérica).
- work: Indica si el encuestado suele escuchar música mientras estudia o trabaja (binaria: sí/no).
- instr: Indica si el encuestado toca algún instrumento (binaria: sí/no).
- compose: Indica si el encuestado compone música (binaria: sí/no).
- favgenre: Género favorito del encuestado (categórica, elige el género de una lista de 16 géneros).
- explore: Los encuestados responden si exploran activamente nuevos artistas o géneros musicales (binaria: sí/no).
- lang: Los encuestados responden si escuchan regularmente música con letra en idiomas en los que carecen de fluidez (binaria: sí/no).
- bpm: “Beats per minute”, pulsos por minuto del género favorito del encuestado (numérica).

1.2.2 Variables sobre la frecuencia con la que el encuestado escucha cada género musical

Se trata de 16 variables ordinales en las que el encuestado responde la frecuencia con la que escucha 16 estilos diferentes de música, que coinciden con los que se presentan como opciones en la variable favgenre. Los nombres de las variables, y los géneros musicales a los que se refieren son los siguientes:

- classical: Música clásica.
- country: Música country
- edm: Del ingés “Electronic Dance Music”, Musica dance electrónica.
- folk: Música folk
- gospel: Música gospel
- hiphop: Música hip hop.
- jazz: Música jazz.
- kpop: Música k-pop (pop coreano).
- latin: Música latina.
- lofi: Música lo-fi, del inglés “Low Fidelity”.
- metal: Música heavy metal.
- pop: Música pop
- rnb: Música R&B, del inglés “Rhytm and blues”.
- rap: Música rap
- rock: Música rock
- videogame: Música de videojuegos

Para todas estas variables, las opciones, de menor a mayor frecuencia son: Nunca, rara vez, a veces, con frecuencia.

1.2.3 Variables sobre la salud mental del encuestado

Las cuatro siguientes variables describen las respuestas del encuestado a un autodiagnóstico sobre cuatro de los trastornos más comunes:

- anxiety: Ansiedad.
- depression: Depresión.
- insomnia: Insomnio.
- ocd: Trastorno obsesivo-compulsivo (TOC).

En todas estas variables, el encuestado elige un valor numérico entero de 0 a 10, donde 0 se corresponde con “no experimentar en absoluto el trastorno”, y 10 se corresponde con “experimentar el trastorno regularmente, constantemente y/o de forma extrema).

- effect: Esta variable será la utilizada como dependiente durante la mayor parte de los análisis que se realizarán en este trabajo. Se corresponde con la respuesta de los encuestados a si su salud mental mejora con la escucha de música. Se trata de una variable categórica, que podría considerarse ordinal, para la cual las opciones son “mejora”, “ningún efecto” o “empeora”.

1.3 TRANSFORMACIÓN DE LAS VARIABLES

1.3.1 Variables binarias y ordinales

Las variables categóricas binarias se transformaron todas en 0 y 1 para los valores “No” y “Sí” respectivamente. De esta forma pueden aplicarse tanto de forma categórica para algunos métodos, como árboles de decisión, como numérica para regresiones.

Las variables ordinales correspondientes con la frecuencia de escucha de cada género se convirtieron en numéricas, con números enteros de 0 a 3 de la siguiente manera:

- Nunca = 0
- Rara vez = 1
- A veces = 2
- Con frecuencia = 3

La variable categórica favgenre, tiene 16 posibles respuestas, en función del género favorito de cada persona. Como coincide con las 16 variables relacionadas con la frecuencia de escucha de cada género, se utilizarán en las categorías de favgenre los mismos nombres correspondientes a estas variables. De esta forma, se facilita un potencial análisis en el que entren en juego estas variables.

En caso de necesitar variables dummy correspondientes con las variables categóricas para algún análisis, se detallará su creación en el apartado concreto en el que se vayan a utilizar.

1.3.2 Datos faltantes

Se observó que muchas de las variables tienen valores faltantes (NAs). Antes de realizar algún tipo de análisis, se deberá decidir cómo proceder en cada caso. En primer lugar, se calculó cuántas filas tienen algunos valores faltantes:

NAs	Número de filas
0	616
1	115
2	4
6	1

Tabla 1.1 Cantidad de filas con cada número de variables sin rellenar

La única fila con más de 2 variables vacías es la correspondiente al dato número 562, con 6 variables no completadas: work, instr, comp, lang, bpm y effect. En este caso, se decidió eliminar este dato, puesto que no solo faltan la mayoría de las variables del bloque 0, sino que también falta la variable que se utilizará como dependiente.

Una vez eliminada dicha fila, se analizó el número de datos faltantes (NAs) de cada una de las variables.

Variable	NAs
age	1
stream	1
work	2
Instr	3
lang	3
bpm	106
effect	7

Tabla 1.2 Número de valores vacíos en cada variable

Se decidió qué hacer con estos valores faltantes para cada variable de forma individual. Se intentará en todos los casos aprovechar al máximo los datos existentes, e influir lo menos posible en los resultados finales. Es inevitable inducir algún tipo de arbitrariedad cuando se rellenan algunos datos que faltan, por lo que intentará justificarse mediante algún tipo de criterio.

- stream: Se trata de un único caso. Como no respondió a qué servicio de streaming musical utiliza, se interpretará que no utiliza ninguno, por lo que se añadirá a la categoría “No suelo escuchar música en servicios de streaming”.

- work: Estos casos se añadirán a la moda, que es la respuesta “sí”.

- instr: En este caso se interpretará “no”, ya que es la moda, y el hecho de no responder puede indicar que no toca ningún instrumento.

- lang: La moda en este caso es el “Sí” (personas que sí escuchan habitualmente canciones con letras en idiomas que no hablan con fluidez); sin embargo, solo representa el 55.2% de los datos, por lo que se intentó ajustar un poco más antes de sustituir. Una variable que parece correlada con Calculando la media de edad para los que respondieron “Sí” y “No”, se obtuvo que los que responden “Sí” tienen una edad media de 23.7 años, y los que responden “No”, una edad de 27.1. Es posible que personas más jóvenes escuchen más asiduamente canciones en idiomas extranjeros. Se calcularon los valores de las edades de los 3 datos para los que falta la variable lang, siendo estos 14, 15 y 31; y se realizó una regresión logística de lang con respecto a la variable age, obteniéndose lo siguiente:

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	0.798	0.178	4.485	7.28e-06	***
age	-0.023	0.006	-3.650	2.6e-04	***

Tabla 1.3 Resultado de la regresión lineal age vs lang

Introduciendo los valores de las edades, en los tres se obtiene una probabilidad de pertenecer a Lang=1 superior al 50%, por lo que en todas se tomará como que sí escuchan música en idiomas extranjeros.

- bpm: Se tienen 107 valores vacíos, lo cual supone un 14.5% del total. Además, observando los valores, se tienen algunos números incoherentes como 0, 4 o 1e+09. Además, la formulación de la pregunta en la encuesta (pulsos por minuto del género favorito), no es muy clara. Por estas razones, no se utilizará esta variable en el análisis. Antes de eliminarla, se calculó la media de esta variable para las personas que sí respondieron, respecto a su género favorito, ignorando los valores por debajo de 50 y por encima de 230:

Género	BPM medios
Metal	143
EDM	134
Latina	134
Kpop	129
Rap	127
Jazz	124
Rock	124
Música de videojuegos	120
Pop	119
R&B	118
Música clásica	116
Gospel	116
Hip hop	115
Folk	114
Lo-Fi	114
Country	110

Tabla 1.4 BPM medios de cada estilo de música elegido como favorito por los encuestados

Los resultados parecen ajustarse bastante a la realidad, siendo el metal, la música electrónica y la latina los géneros más “rápidos” y el folk, el lo-fi y el country los más “lentos”.

- age: Falta únicamente un dato de esta variable. A priori podría considerarse una variable importante en la predicción de los efectos de la música sobre la salud mental, por lo que se eliminará el dato en lugar de intentar rellenarlo mediante alguna estimación.

- effect: Para esta variable faltan 7 datos. Como se trata de la variable que será tratada como variable respuesta, asociarlos a una categoría podría adulterar los resultados de forma significativa, por lo que estas filas se eliminarán de la base de datos.

Tras realizar estas modificaciones, restan 727 datos en la base de datos que se usará para desarrollar los modelos.

2. ANÁLISIS PREVIOS

2.1 ANÁLISIS DE LAS VARIABLES

Se analizarán de forma individual cada variable, para extraer información útil o interesante, y también para comprobar si, aunque se hayan retirado o rellenado los valores vacíos, siguen existiendo incongruencias o valores que se escapan a la lógica.

2.1.1 Variables numéricas

2.1.1.1 Edad

En primer lugar, se analizará la edad de los encuestados.

Mínimo	10
1º Cuartil	18
Mediana	21
3º Cuartil	28
Máximo	89
Media	25.14
Moda	18
Coef. Asimetría	2.127
W Shapiro-Wilk	0.756
p-valor Shapiro-Wilk	<2.2e-16

Tabla 2.1 Valores estadísticos de la distribución de la variable “edad”

Se observa que la muestra proviene de gente bastante joven, (la mitad de los encuestados tienen 21 años o menos), y la moda es 18 años. Esto tiene sentido puesto que se realizó la encuesta en un entorno universitario y, por ello, existe una enorme asimetría positiva en los datos.

Esta distribución tan asimétrica puede generar problemas a la hora de realizar regresiones, como magnificar los errores o que haya outliers entre las personas de mayor edad, ya que son muchas menos.

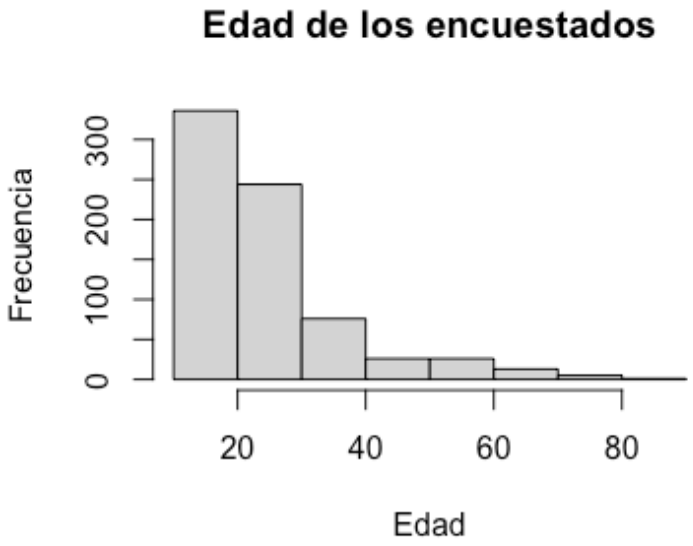

Figura 2.1 Histograma con la distribución de la variable “edad”

2.1.1.2 Horas diarias

Inicialmente, en esta variable se obtienen valores que no parecen lógicos. Los valores de 0 implican que el encuestado nunca escucha música, lo cual haría ilógicas el resto de las respuestas. Por tanto, se fijará un valor mínimo de 0.25, y los valores menores se fijarán a esta cantidad. De forma similar, existen respuestas muy altas (20 o 24 horas diarias), por lo que se fijará un máximo de 13 horas, y todos los valores superiores se transformarán a este valor.

Una vez realizadas dichas transformaciones, se analizó la distribución de esta variable:

Mínimo	0.25
1º Cuartil	2
Mediana	3
3º Cuartil	5
Máximo	13
Media	3.52
Coef. Asimetría	1.49
W Shapiro-Wilk	0.846
p-valor Shapiro-Wilk	<2.2e-16

Tabla 2.2 Valores estadísticos de la variable “horas diarias”

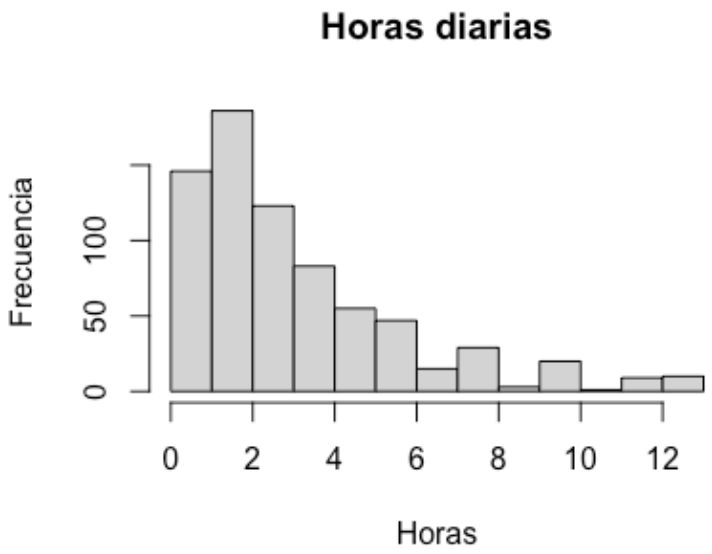

Figura 2.2 Histograma con la distribución de la variable “horas diarias”

Al igual que con la edad, la hipótesis de normalidad se rechaza, observándose igualmente asimetría positiva. La mitad de los encuestados escuchan música entre 2 y 5 horas diarias.

2.1.2 Variables categóricas

2.1.2.1 Variables binarias

La mayoría de los encuestados escuchan música mientras trabajan, y aseguran explorar activamente nuevos artistas y géneros musicales. También superior al 50%, pero más equilibrada está la proporción de personas que escuchan asiduamente música en idiomas extranjeros.

Menos de un tercio, el 31.9% tocan algún instrumento, y solamente el 17.2% componen música.

Variable	"No"	"Sí"	% "Sí"
work	153	574	78.95%
instr	495	232	31.91%
compose	602	125	17.19%
explore	207	520	71.53%
lang	325	402	55.30%

Tabla 2.3 Frecuencia de respuestas “Sí” y “No” de las cinco variables dicotómicas de la encuesta

2.1.2.2 Géneros favoritos

En la siguiente tabla se observa que los géneros favoritos más comunes entre los encuestados son el rock, pop y metal, mientras que los menos comunes son el gospel, la música latina y el lo-fi.

Género	Favorito	Porcentaje
Rock	186	25.58%
Pop	114	15.68%
Metal	88	12.10%
Música clásica	53	7.29%
Música de videojuegos	44	6.05%
EDM	36	4.95%
R&B	35	4.81%
Hip hop	34	4.68%
Folk	29	3.99%
Country	25	3.44%
Kpop	23	3.16%
Rap	22	3.03%
Jazz	20	2.75%
Lo-Fi	10	1.38%
Gospel	6	0.83%
Latina	2	0.28%

Tabla 2.4 Frecuencia y porcentaje de encuestados que eligieron cada género musical como favorito

2.1.2.3 Servicios de streaming

Por su parte, el servicio de streaming más utilizado con más de la mitad de los encuestados es Spotify, y el menos utilizado, Pandora. 71 de los encuestados, el 9.8%, no utilizan ningún servicio de streaming, escuchando música por otros medios de forma más habitual.

Servicio Streaming	Frecuencia	Porcentaje
Spotify	454	62.45%
Youtube Music	93	12.79%
Ninguno	71	9.77%
Apple Music	50	6.88%
Otros	49	6.74%
Pandora	10	1.38%

Tabla 2.5 Frecuencia y porcentaje de encuestados que eligieron cada servicio de streaming como el más utilizado

2.1.3 Variables ordinales

Analizando ahora las variables individuales de cada género, observamos que los géneros que más escuchan los encuestados de media son rock y pop, con bastante diferencia. La mediana de 2 indica que más de la mitad escuchan estos géneros asiduamente. En el otro extremo se encuentran el kpop, la música latina y el gospel, cuya mediana de 0 nos hace ver que menos de la mitad de los encuestados escuchan alguna vez estos tipos de música.

El metal y la música de videojuegos son los géneros con una mayor desviación estándar, lo cual puede tener sentido al ser estilos más polarizantes.

Género	Media	Mediana	Desv. Est.
Rock	2.08	2	1.03
Pop	2.03	2	0.93
Hip hop	1.38	1	1.03
Rap	1.34	1	1.05
Música clásical	1.34	1	0.99
R&B	1.25	1	1.06
Música de videojuegos	1.25	1	1.07
Metal	1.23	1	1.13
Lo-Fi	1.07	1	1.03
Jazz	1.03	1	0.94
EDM	1.03	1	1.05
Folk	1.01	1	1.01
Country	0.82	1	0.92
Kpop	0.72	0	0.99
Latina	0.60	0	0.86
Gospel	0.38	0	0.70

Tabla 2.6 Estadísticos de las variables de frecuencia de escucha de cada género

2.1.4 Variables sobre salud mental

2.1.4.1 Trastornos de salud mental

Trastorno	Media	Q1	Mediana (Q2)	Q3	Desv. Est.
Ansiedad	5.84	4	6	8	2.79
Depresión	4.81	2	5	7	3.03
Insomnio	3.76	1	3	6	3.10
TOC	2.64	0	2	4.5	2.84

Tabla 2.7 Estadísticos de las variables relacionadas con los trastornos de salud mental en la encuesta original

Observando los distintos trastornos de salud mental, el más común es la ansiedad, seguido por la depresión. El Trastorno Obsesivo Compulsivo es el menos común, con al menos una cuarta parte de los encuestados asegurando que no lo padecen en absoluto, y tres cuartas partes respondiendo con valores por debajo de 5. El insomnio es el que presenta una mayor desviación, lo que puede indicar que, en general, es un trastorno más binario y con menos forma de espectro que el resto.

2.1.4.2 Efecto

Por último, se analizó el efecto de la música sobre la salud mental de los encuestados. Casi tres cuartos afirman mejorar, mientras que solamente 17, el 2.3%, dicen empeorar. El resto no creen tener ningún efecto.

Efecto	Casos	Porcentaje
Mejoran	541	74.42%
Ningún efecto	169	23.25%
Empeoran	17	2.34%

Tabla 2.8 Frecuencia de encuestados que respondieron cada opción sobre el efecto que tiene la escucha de música en su salud mental

Esta variable será utilizada como variable respuesta en la mayor parte de este trabajo. Existe una desigualdad muy grande entre las tres categorías, lo cual puede llevar a que los modelos no funcionen de forma óptima. Por ello, algunos de los modelos se plantearán con una respuesta binaria.

2.1.4.3 Efecto como variable respuesta binaria

Como se observa en la tabla 2.8, la variable efecto toma un valor “empeorar” para muy pocos casos, y “mejorar” para la gran mayoría. Por tanto, se duplicó la base de datos, cambiando esta variable para que tenga una variable binaria, en lugar de 3 opciones. Estas dos respuestas serían simplemente “Sí” (o 1) para los casos en los que el paciente afirma mejorar, o “No” (o 2) para los casos en los que el paciente dice no mejorar, ya sea porque no nota ningún efecto, o porque empeora.

Efecto (binario)	Casos	Porcentaje
Sí (1)	541	74.42%
No (0)	169	25.58%

Tabla 2.9 Frecuencia de la variable efecto para respuesta binaria

Esta variable será utilizada como categórica Sí/No o numérica 1/0 dependiendo de las necesidades del método que se utilice en cada caso. Algunos de los modelos se desarrollarán dos veces, una con cada una de las dos opciones para esta variable respuesta (triple y binaria).

2.2 RELACIONES ENTRE VARIABLES

2.2.1 Relaciones con la edad

La correlación entre la edad y el número de horas diarias que escuchan música los encuestados es de -0.096. El número negativo indica que, en general, las personas jóvenes escuchan música durante más tiempo. Sin embargo, su valor absoluto es demasiado pequeño como para ser considerada significativa.

Si analizamos la edad media y mediana de los usuarios de cada servicio de streaming, se puede comprobar que existen grandes diferencias entre unos y otros. Pandora es utilizado por gente más mayor, y las medias de los que no utilizan ninguno, u otros diferentes a los incluidos en la pregunta, son superiores a la media global de 25 años. Por su parte, Spotify es el preferido por la mayoría de la gente, pero esta mayoría se acentúa aún más entre la gente más joven.

Servicio Streaming	Media	Mediana
Apple Music	24.28	20
Pandora	48.90	56.5
Spotify	22.72	20
Youtube Music	27.61	22
Otro	30.47	26
Ninguno	30.96	23

Tabla 2.10 Edad media y mediana de los encuestados que eligieron cada servicio de streaming como favorito

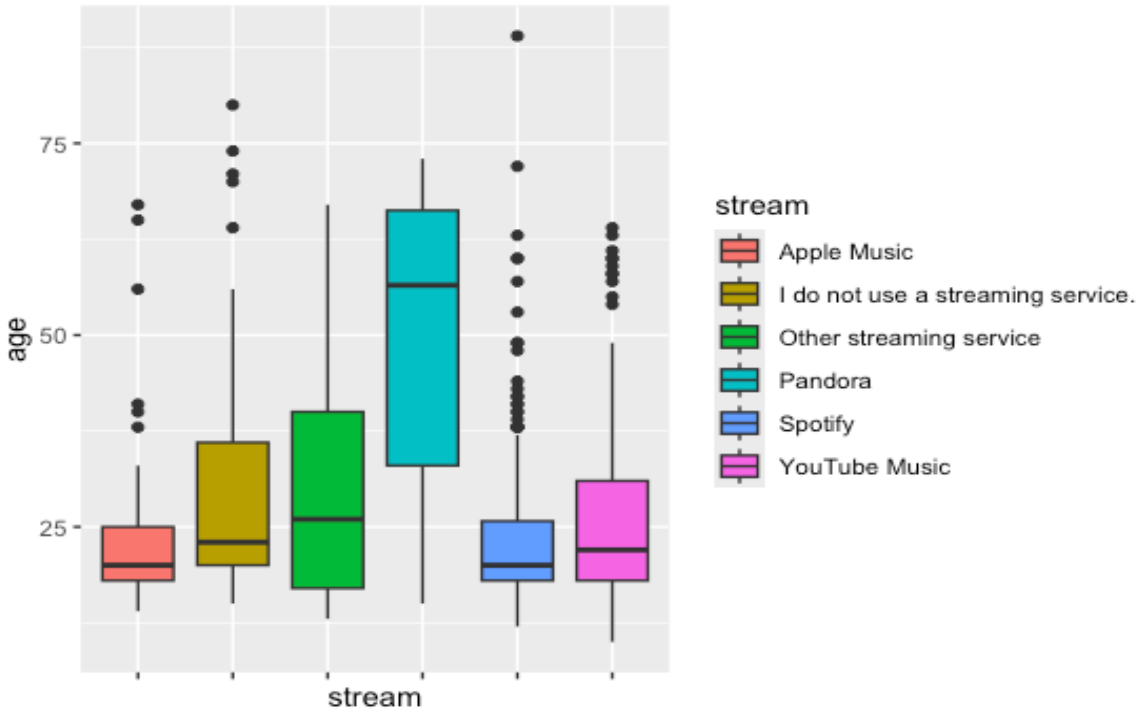

Figura 2.3 Boxplots de la edad con respecto a cada servicio de streaming

Se calculó la edad media para cada género favorito, y la correlación de la frecuencia de escucha de cada género con la edad:

GenFav	Edad Media	R Pearson
gospel	55.67	0.129
rock	28.03	0.049
classical	26.23	0.095
folk	25.97	0.113
jazz	25.45	0.070
country	25.36	0.120
rnb	25.34	0.037
metal	25.11	-0.017
hiphop	23.44	-0.142
pop	23.25	-0.184
lofi	22.10	-0.212
edm	22.08	-0.095
rap	21.77	-0.202
videogame	21.59	-0.263
kpop	18.30	-0.162
latin	17.50	0.073

Tabla 2.11 Media de la edad de los encuestados que eligieron cada género como favorito, y coeficiente de correlación de la edad con la frecuencia de escucha

Como es de esperar, hay bastante similitud entre la media de edad de las personas que seleccionaron cada género como favorito, y la correlación de la edad con la frecuencia de escucha de cada género. El gospel es el estilo escuchado por personas más mayore según ambas métricas. Todas las correlaciones negativas se encuentran en géneros con menor media de edad que las positivas, a excepción de la música latina, que solamente fue elegida como favorita por 2 personas, con edad media 17.5 años, pero en general es más escuchado por personas de mayor edad.

Para las variables binarias, se calcularon las edades medias y medianas de las personas que respondieron “Sí” y las que respondieron “No”. También se realizó para cada una un test t de Student para comprobar si las poblaciones correspondientes con cada respuesta son significativamente diferentes.

Variable	SÍ		NO		t-student
	Media	Mediana	Media	Mediana	p-valor
work	24.70	21	26.80	23	0.0455
instr	23.01	20	26.14	22	0.0007
compose	24.34	20	25.31	21	0.4453
explore	23.79	20	28.54	23	4.19e-05
lang	23.75	21	26.87	21	0.0008

Tabla 2.12 Estadísticos sobre la edad de los que respondieron sí o no a las preguntas de la encuesta con respuesta binaria

2.2.2 Relaciones con las horas diarias

Se analizó si existe una relación visible entre el servicio de streaming preferido y las horas diarias de escucha de música, pero no parece haber diferencias muy obvias.

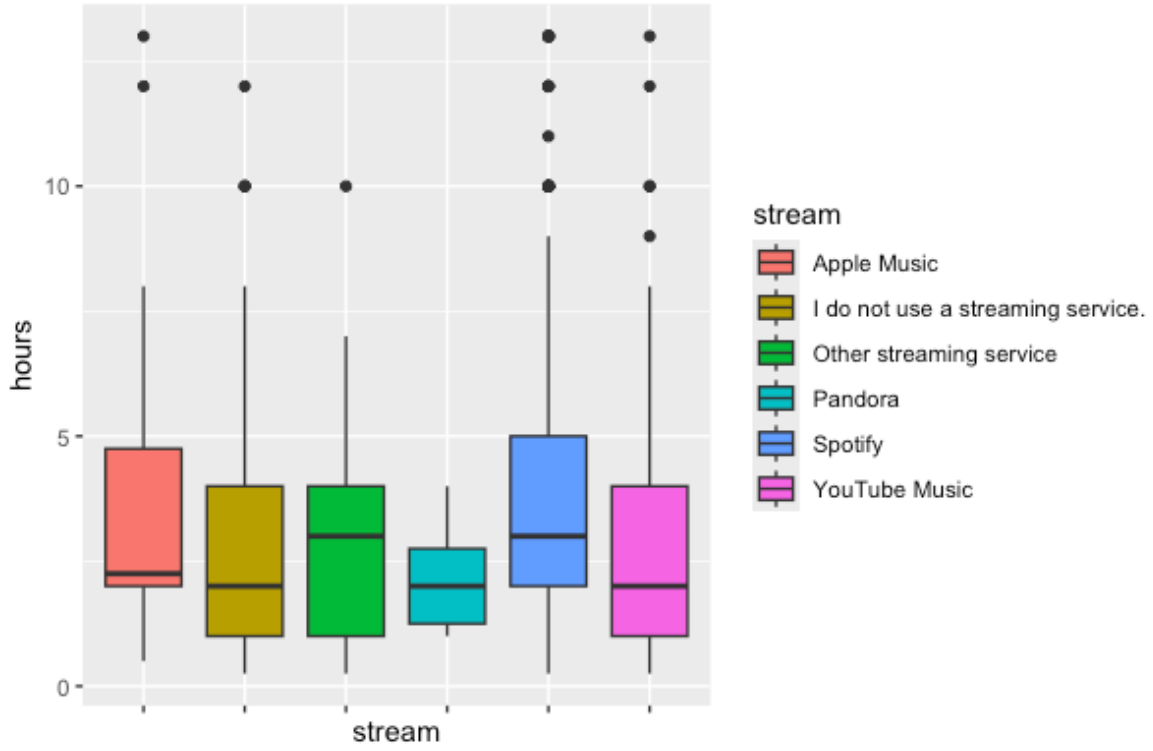

Figura 2.4 Boxplots de las horas diarias de escucha de música con respecto a cada servicio de streaming

También se analizó si existe una diferencia discernible de horas diarias de escucha entre los que respondieron sí y no a las preguntas de respuesta binaria.

Variable	SÍ		NO	
	Media	Mediana	Media	Mediana
work	3.94	3	1.94	1.5
instr	3.43	3	3.57	3
compose	4.35	3	3.35	3
explore	3.78	3	2.86	2
lang	3.78	3	3.21	2

Tabla 2.13 Estadísticos sobre las horas diarias que escuchan música los que respondieron sí o no a las preguntas de la encuesta con respuesta binaria

Como parece lógico, las personas que escuchan música mientras trabajan, tienden a escuchar muchas más horas diarias de música. De la misma forma, las personas que componen y exploran activamente nuevos estilos y artistas, también pasan más tiempo escuchando música.

2.2.3 Relaciones entre las variables binarias

Se realizó una matriz de correlaciones con las variables binarias para explorar su relación. El método elegido fue el coeficiente de correlación Phi (Φ), que es matemáticamente equivalente al coeficiente de correlación de Pearson aplicado a una variable dicotómica:

Φ	work	instr	compose	explore	lang
work	1.000	0.078	0.047	0.138	0.113
instr	0.078	1.000	0.400	0.072	-0.014
compose	0.047	0.400	1.000	0.094	-0.045
explore	0.138	0.072	0.094	1.000	0.181
lang	0.113	-0.014	-0.045	0.181	1.000

Tabla 2.14 Matriz de correlaciones entre las variables binarias

La relación más fuerte es la existente entre las variables “componer” y “tocar un instrumento”. Esta relación es positiva. Resulta congruente que las personas que tocan instrumentos tiendan a ser las mismas que componen música. El resto de las correlaciones son bastante débiles, todas ellas menores a 0.2 en valor absoluto.

2.2.4 Relaciones entre los trastornos de salud mental

Se representaron en la siguiente figura las correlaciones entre las cuatro variables que miden los niveles de intensidad con los que los encuestados sufren trastornos de salud mental:

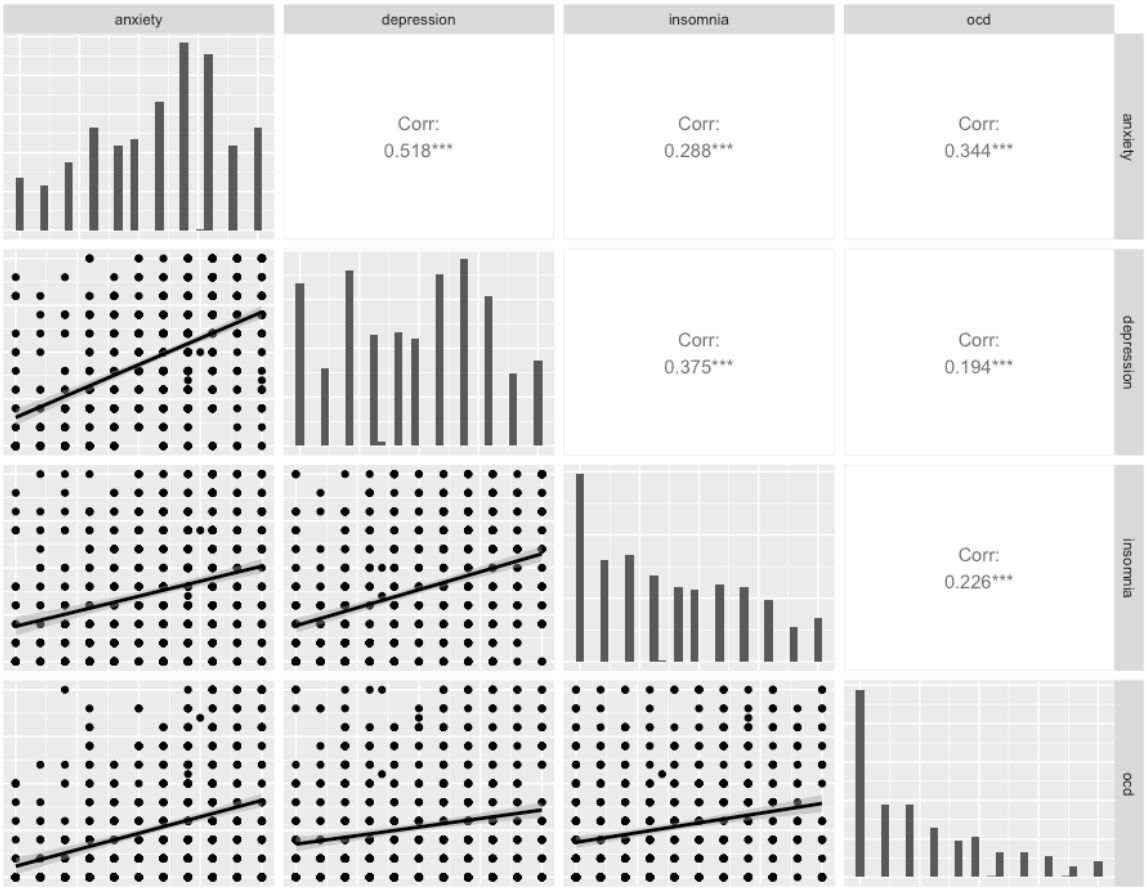

Figura 2.5 Correlaciones entre las cuatro variables relacionadas con trastornos de salud mental en los datos de la encuesta original

Todas las correlaciones son positivas, lo cual es coherente, puesto que es esperable que personas que sufran problemas de salud mental tengan más de un tipo de trastorno. La más fuerte es la relación entre la ansiedad y la depresión, que son trastornos que suelen ir juntos y, en ocasiones, pueden ser complicados de diferenciar para el que los sufre.

2.2.5 Análisis de componentes principales (PCA)

Para analizar de forma general las relaciones subyacentes entre las variables que se usarán como predictoras se realizó un análisis de componentes principales (PCA). Las variables ordinales se utilizan como numéricas, y la variable categórica “stream” se convertirá en 5 variables binarias “dummy” correspondientes con 5 de las 6 posibles respuestas. La opción “No utilizo ningún servicio de streaming” se tomó como base, y se corresponde con un valor de 0 en todas estas variables dummy. Habría sido posible realizar lo mismo para la variable “género favorito”, pero habría que crear 15 nuevas variables que ya están en cierto modo representadas por las variables ordinales correspondientes con cada género musical. Por esta razón, la variable favgenre no ha sido tenida en cuenta para este análisis.

Variable	PC1	PC2	PC3	PC4
age	-0.134	0.094	-0.384	0.067
hours	0.165	-0.148	-0.024	-0.030
work	0.050	-0.018	0.002	0.020
instr	-0.015	-0.022	-0.031	0.096
compose	0.012	-0.025	-0.033	0.028
explore	0.080	-0.028	-0.016	-0.043
lang	0.083	-0.013	0.008	0.020
classical	0.028	0.026	-0.249	0.443
country	0.057	-0.063	-0.371	-0.146
edm	0.219	-0.076	0.098	-0.137
folk	0.104	-0.232	-0.418	-0.076
gospel	0.131	0.103	-0.332	0.190
hiphop	0.393	0.141	0.062	-0.210
jazz	0.220	0.032	-0.303	0.215
kpop	0.268	0.176	0.143	0.104
latin	0.247	0.112	-0.221	0.171
lofi	0.302	0.003	0.035	0.052
metal	-0.008	-0.411	-0.141	-0.309
pop	0.273	0.082	0.070	-0.057
rnb	0.370	0.194	-0.081	-0.016
rap	0.382	0.076	0.102	-0.281
rock	0.037	-0.373	-0.241	-0.351
videogame	0.120	-0.212	0.073	0.015
anxiety	0.121	-0.352	0.196	0.274
depression	0.150	-0.386	0.119	0.188
insomnia	0.095	-0.316	0.065	0.299
ocd	0.095	-0.222	0.148	0.255
apple	0.004	0.002	0.006	-0.003
other	-0.010	0.012	-0.008	0.014
pandora	-0.003	0.008	-0.015	0.006
spotify	0.052	-0.037	0.059	-0.049
youtube	-0.014	0.014	-0.026	0.018

Tabla 2.15 “Cargas” de cada variable en cada uno de las cuatro primeros componentes del PCA

Se representaron las varianzas de los primeros 10 componentes en un gráfico.

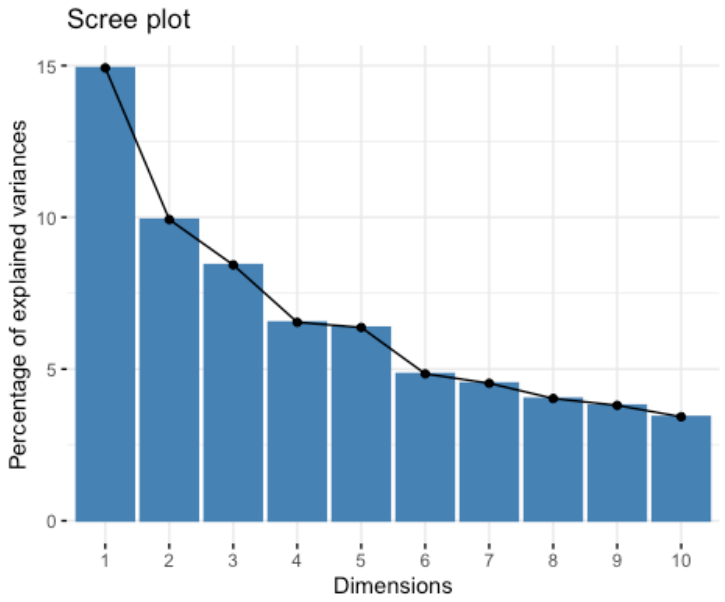

Figura 2.6 Varianzas relativas de los 10 primeros componentes del PCA

El primer componente explica, aproximadamente, el 15% de la varianza total, y los 2 primeros el 25%. Se comprobó que la correlación entre estos dos primeros componentes es nula.

Se representaron en un gráfico de dispersión todos los puntos de la base de datos utilizando como ejes estos dos primeros componentes (PC1 y PC2). Para observar la importancia relativa de cada variable en cada componente, se representó cada una de ellas en forma de vector con las cargas correspondientes a cada uno.

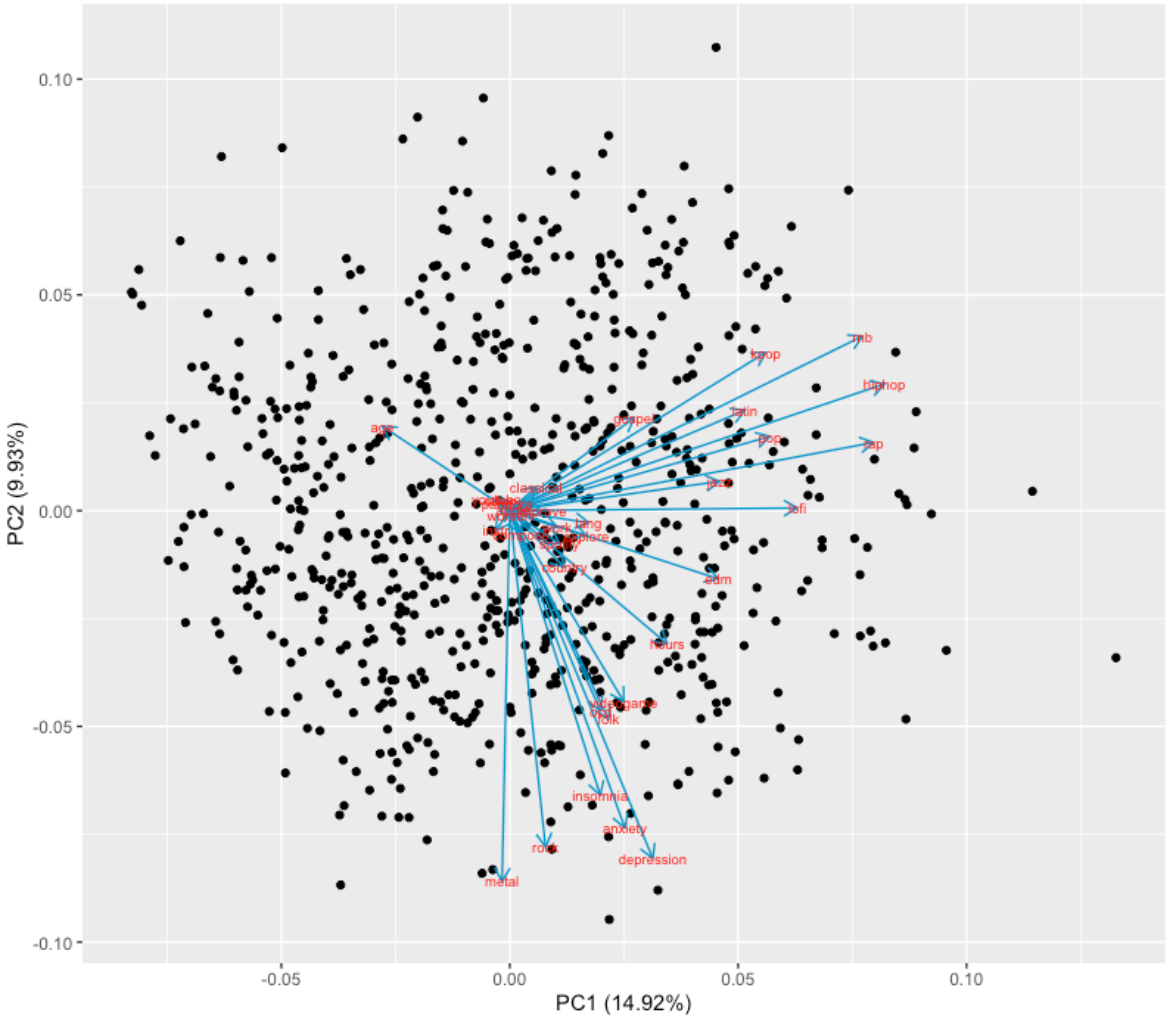

Figura 2.7 Gráfico de dispersión con vectores señalando las cargas de cada variable sobre los dos primeros componentes del PCA

Se observa como las cuatro variables sobre salud mental, insomnio, ansiedad ocd y depresión, tienen cargas muy parecidas: muy pequeñas y positivas sobre el componente PC1, y grandes y negativas sobre el componente PC2. También se puede ver como estilos de música similares tienen cargas similares, como por ejemplo metal y rock; o r&b, hip hop y rap. Por su parte, la variable edad tiene una carga completamente diferente a la del resto de variables, siendo prácticamente la única que tiene carga negativa en PC1. La variable horas también destaca por tener carga en ambas variables, con sentido casi totalmente opuesto a edad, siendo estas dos de las pocas variables que tienen vectores tan oblicuos.

Se puede concluir que el primer componente, PC1, representa principalmente a las variables de salud mental, mientras que el segundo, PC2, componente representa en forma variable varios estilos musicales. Las variables edad y horas tienen una carga notable en ambos componentes, por lo que podemos suponer que pueden ser de las variables más importantes a la hora de desarrollar el modelo, especialmente la edad, puesto que parece ser la que menos relación tiene con el resto de las variables.

3. MODELOS CON LAS VARIABLES DE SALUD MENTAL

3.1 REGRESIONES NUMÉRICAS CON LAS VARIABLES DE SALUD MENTAL COMO RESPUESTA

De forma adicional al modelo principal, se realizaron regresiones multivariantes para tratar de explicar las variaciones en cada uno de los trastornos de salud mental, con respecto al resto de variables (excluyendo las demás variables de salud mental, incluido el efecto). Se realizó una regresión para cada una de las cuatro variables y una adicional para una suma de las cuatro. En todos los casos se realizó una primera regresión utilizando todas las variables, y después se aplicó el método stepwise, seleccionándose por el criterio de Akaike las variables más significativas, y se repitió el modelo con menos variables.

3.1.1 Ansiedad como variable respuesta

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	5.876	0.427	13.768	< 2e-16	***
age	-0.428	0.123	-3.495	0.001	***
hours	0.119	0.112	1.061	0.289	
work	-0.023	0.270	-0.084	0.933	
instr	0.235	0.261	0.899	0.369	
compose	-0.065	0.303	-0.213	0.832	
explore	-0.428	0.255	-1.679	0.094	.
lang	0.301	0.230	1.307	0.192	
classical	-0.143	0.114	-1.245	0.214	
country	-0.064	0.113	-0.567	0.571	
edm	-0.009	0.112	-0.076	0.939	
folk	0.336	0.121	2.780	0.006	**
gospel	-0.068	0.113	-0.596	0.551	
hiphop	-0.189	0.178	-1.060	0.290	
jazz	0.007	0.122	0.054	0.957	
kpop	0.019	0.122	0.153	0.879	
latin	-0.099	0.117	-0.848	0.397	
lofi	0.029	0.123	0.239	0.811	
metal	0.082	0.128	0.639	0.523	
pop	0.236	0.121	1.956	0.051	.
rnb	0.091	0.141	0.650	0.516	
rap	0.087	0.174	0.498	0.619	
rock	0.050	0.131	0.379	0.705	
videogame	0.107	0.121	0.882	0.378	
apple	1.011	0.526	1.922	0.055	.
other	0.033	0.517	0.064	0.949	
pandora	0.542	0.963	0.563	0.574	
spotify	0.043	0.375	0.115	0.908	
youtube	-0.334	0.445	-0.751	0.453	

Tabla 3.1 Resultado de la regresión lineal para predecir el valor de ansiedad utilizando todas las variables predictoras

El valor de R^2 para esta regresión es de 0.042. Solamente dos variables (age y folk) son significativamente distintas de 0, para un nivel de confianza del 95%. Tras aplicar el método stepwise, se obtiene que el modelo que minimiza el AIC es el que contiene las variables age, explore, lang, folk, pop, apple y metal.

La regresión utilizando estas variables se presenta a continuación:

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	5.917	0.217	27.238	< 2e-16	***
age	-0.500	0.105	-4.744	0.000	***
explore	-0.427	0.237	-1.804	0.072	.
lang	0.302	0.208	1.456	0.146	
folk	0.296	0.105	2.809	0.005	**
pop	0.233	0.105	2.210	0.027	*
apple	0.966	0.398	2.427	0.016	*
metal	0.165	0.106	1.560	0.119	

Tabla 3.2 Resultado de la regresión lineal para predecir el valor de la variable ansiedad utilizando las variables predictoras seleccionadas por el método stepwise

En este caso el nuevo R^2 es de 0.057, más alto que el anterior. Se puede concluir que existe una relación significativa entre la edad y en nivel de ansiedad, siendo esta mayor para personas más jóvenes.

3.1.2 Depresión como variable respuesta

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	4.525	0.456	9.925	< 2e-16	***
age	-0.265	0.131	-2.023	0.043	*
hours	0.233	0.120	1.947	0.052	.
work	0.047	0.289	0.162	0.871	
instr	-0.108	0.279	-0.385	0.700	
compose	0.283	0.324	0.874	0.382	
explore	-0.325	0.272	-1.192	0.234	
lang	0.186	0.246	0.756	0.450	
classical	0.059	0.122	0.486	0.627	
country	-0.315	0.120	-2.615	0.009	**
edm	0.113	0.120	0.947	0.344	
folk	0.235	0.129	1.819	0.069	.
gospel	0.022	0.121	0.180	0.857	
hiphop	0.027	0.190	0.140	0.889	
jazz	0.058	0.131	0.443	0.658	
kpop	-0.176	0.130	-1.352	0.177	
latin	0.070	0.125	0.561	0.575	
lofi	-0.180	0.131	-1.374	0.170	
metal	0.276	0.137	2.018	0.044	*
pop	0.181	0.129	1.402	0.161	
rnb	0.066	0.150	0.439	0.661	
rap	0.224	0.186	1.206	0.228	
rock	0.328	0.140	2.343	0.019	*
videogame	0.070	0.130	0.541	0.589	
apple	0.635	0.562	1.129	0.259	
other	0.249	0.552	0.450	0.653	
pandora	0.137	1.029	0.133	0.894	
spotify	0.517	0.400	1.291	0.197	
youtube	-0.206	0.475	-0.433	0.665	

Tabla 3.3 Resultado de la regresión lineal para predecir el valor de depresión utilizando todas las variables predictoras

Se obtuvo un coeficiente de regresión R^2 igual a 0.072, muy bajo pero mayor al obtenido en el caso de la ansiedad. Tras aplicar el criterio de Akaike, se obtuvo que el modelo con el menor AIC es el que utiliza las variables age, hours, country, folk, metal, rap, rock y Spotify.

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	4.581	0.181	25.270	< 2e-16	***
age	-0.237	0.115	-2.070	0.039	*
hours	0.239	0.111	2.154	0.032	*
country	-0.305	0.115	-2.648	0.008	**
folk	0.241	0.121	1.996	0.046	*
metal	0.246	0.127	1.943	0.052	.
rap	0.292	0.112	2.596	0.010	**
rock	0.391	0.131	2.982	0.003	**
spotify	0.361	0.234	1.542	0.123	

Tabla 3.4 Resultado de la regresión lineal para predecir el valor de la variable depresión utilizando las variables predictoras seleccionadas por el método stepwise

En este modelo la R^2 aumentó hasta 0.082. De nuevo hay una ligera relación negativa entre la edad y la depresión, que indicaría que es más común en personas de menor edad. Varios estilos de música parecen más populares entre gente más propensa a la depresión, como el folk el rap y el rock, mientras que el country parece más popular entre gente que no sufre depresión.

3.1.3 Insomnio como variable respuesta

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	4.110	0.476	8.639	< 2e-16	***
age	0.132	0.137	0.965	0.335	
hours	0.383	0.125	3.062	0.002	**
work	-0.186	0.302	-0.617	0.538	
instr	-0.122	0.291	-0.418	0.676	
compose	0.543	0.338	1.606	0.109	
explore	0.103	0.284	0.361	0.718	
lang	-0.159	0.257	-0.620	0.536	
classical	0.257	0.128	2.017	0.044	*
country	-0.258	0.126	-2.052	0.041	*
edm	0.120	0.125	0.958	0.338	
folk	-0.007	0.135	-0.054	0.957	
gospel	0.018	0.127	0.142	0.887	
hiphop	-0.084	0.199	-0.423	0.672	
jazz	-0.119	0.136	-0.876	0.382	
kpop	0.009	0.136	0.067	0.946	
latin	0.179	0.130	1.374	0.170	
lofi	0.087	0.137	0.637	0.524	
metal	0.411	0.143	2.884	0.004	**
pop	-0.024	0.135	-0.178	0.859	
rnb	0.035	0.157	0.222	0.824	
rap	0.111	0.194	0.573	0.567	
rock	0.049	0.146	0.339	0.735	
videogame	0.127	0.135	0.943	0.346	
apple	-0.519	0.587	-0.885	0.377	
other	0.132	0.576	0.229	0.819	
pandora	-1.469	1.074	-1.368	0.172	
spotify	-0.266	0.418	-0.637	0.525	
youtube	-0.268	0.496	-0.541	0.589	

Tabla 3.5 Resultado de la regresión lineal para predecir el valor de insomnio utilizando todas las variables predictoras

El valor de R^2 obtenido es 0.035. Tras utilizar el metodo Stepwise, se obtiene que el modelo que minimiza el AIC es el que utiliza como predictoras las variables hours, compose, classical, country y edm. Por primera vez, la variable age no es significativa, y no está en el modelo final.

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	3.674	0.123	29.805	< 2e-16	***
hours	0.376	0.115	3.271	0.001	**
compose	0.478	0.302	1.585	0.113	
classical	0.246	0.113	2.182	0.029	*
country	-0.230	0.113	-2.041	0.042	*
edm	0.177	0.114	1.559	0.119	
metal	0.438	0.114	3.847	0.000	***

Tabla 3.6 Resultado de la regresión lineal para predecir el valor de la variable insomnio utilizando las variables predictoras seleccionadas por el método stepwise

Las variables hours y metal son las que presentan mayor significancia, y ambas son mayores que 0, lo cual nos indica una que personas que escuchan este estilo de música, y las que escuchan música durante más horas al día tienden a sufrir más insomnio. Especialmente en el caso de la variable “horas”, es posible que el hecho de escuchar música durante más tiempo sea una consecuencia directa de dormir menos horas.

3.1.4 Trastorno Obsesivo-Compulsivo como variable respuesta

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	2.573	0.440	5.844	0.000	***
age	-0.375	0.126	-2.966	0.003	**
hours	0.306	0.116	2.641	0.008	**
work	0.269	0.279	0.966	0.335	
instr	0.187	0.270	0.694	0.488	
compose	-0.153	0.313	-0.490	0.624	
explore	-0.091	0.263	-0.345	0.730	
lang	-0.355	0.238	-1.495	0.135	
classical	0.082	0.118	0.691	0.490	
country	0.177	0.116	1.521	0.129	
edm	0.241	0.116	2.080	0.038	*
folk	0.109	0.125	0.871	0.384	
gospel	0.036	0.117	0.303	0.762	
hiphop	0.011	0.184	0.059	0.953	
jazz	-0.147	0.126	-1.169	0.243	
kpop	-0.042	0.126	-0.330	0.741	
latin	-0.097	0.120	-0.806	0.421	
lofi	0.022	0.127	0.177	0.860	
metal	-0.023	0.132	-0.172	0.864	
pop	-0.010	0.125	-0.081	0.935	
rnb	0.218	0.145	1.504	0.133	
rap	-0.130	0.179	-0.727	0.467	
rock	-0.066	0.135	-0.487	0.627	
videogame	-0.042	0.125	-0.334	0.739	
apple	0.211	0.543	0.389	0.698	
other	0.094	0.533	0.175	0.861	
pandora	-0.456	0.994	-0.459	0.646	
spotify	0.168	0.387	0.435	0.663	
youtube	-0.298	0.459	-0.650	0.516	

Tabla 3.7 Resultado de la regresión lineal para predecir el valor de trastorno obsesivo-compulsivo utilizando todas las variables predictoras

El R^2 es el menor obtenido hasta ahora, 0.018, y solamente tres variables tienen un nivel de significación superior al 95%. Tras aplicar el método Stepwise, el modelo obtenido tiene solamente 5 variables: age, hours, Lang, country y edm.

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	2.835	0.157	18.093	< 2e-16	***
age	-0.376	0.106	-3.560	0.000	***
hours	0.321	0.105	3.050	0.002	**
lang	-0.354	0.213	-1.662	0.097	.
country	0.184	0.105	1.758	0.079	.
edm	0.203	0.106	1.917	0.056	.

Tabla 3.8 Resultado de la regresión lineal para predecir el valor de la variable trastorno obsesivo-compusivo utilizando las variables predictoras seleccionadas por el método stepwise

El coeficiente de regresión aumentó a 0.037. Solamente age y hours son significantes para un nivel de confianza del 95%. Los signos de los coeficientes nos hacen suponer que el trastorno obsesivo-compulsivo es más común en personas más jóvenes, y también en personas que escuchan música durante más tiempo.

3.1.5 Suma de las variables de salud mental

Se creó una nueva variable “mh” (de mental health), que se corresponde con la suma de las cuatro variables anteriores. La suma se realizó de forma absoluta, es decir, no se centraron las variables antes de sumarlas. Si bien se podría hacer una media de los percentiles que corresponden a cada dato en cada una de estas variables, se decidió sumarlas directamente, puesto que las distribuciones de las variables son bastante diferentes, como se pudo comprobar en el epígrafe 2.1.4.1, y se magnificaría el efecto de las variables con una media menor en aquellas personas que las sufren en mayor medida. Además, aunque sea una escala arbitraria, de esta forma no depende de los resultados de los demás encuestados.

Analizando individualmente esta nueva variable se obtiene lo siguiente:

Mínimo	0.00
1º Cuartil	11.00
Mediana	17.00
3º Cuartil	23.00
Máximo	39.00
Media	17.05
Coef. Asimetría	0.03
W Shapiro-Wilk	0.989
p-valor Shapiro-Wilk	2.97e-05

Tabla 3.9 Resumen de la variable “mh”, suma de todas las variables de salud mental

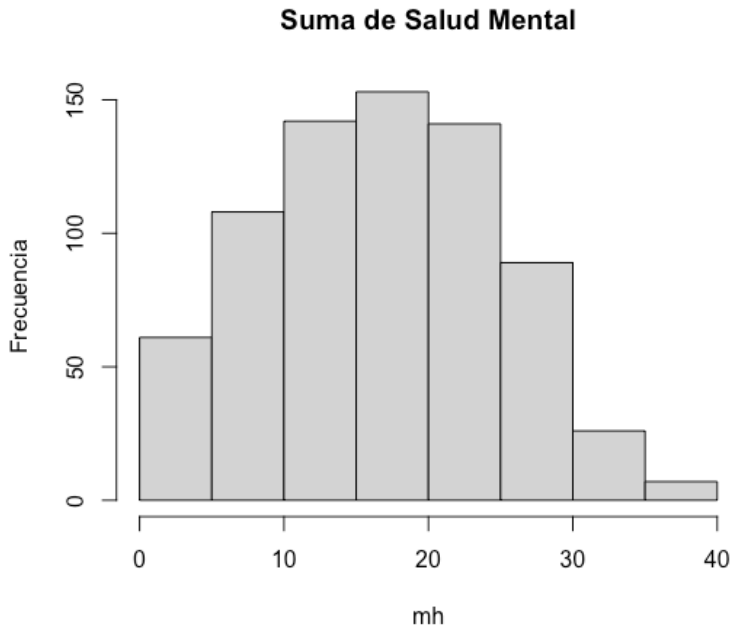

Figura 3.1 Histograma con la distribución de la variable “mh”, correspondiente a la suma de las cuatro variables numéricas sonbre salud mental

Se aprecia en el histograma que la variable es bastante simétrica, lo cual es refrendado por el coeficiente de asimetría, muy cercano a 0. Sin embargo, no pasa el contraste de hipótesis de Shapiro-Wilk, y no se puede asumir normalidad. Ha de tenerse en cuenta que los valores están acotados entre 0 y 40, siendo valores muy cercanos a 0 más comunes que cercanos a 40. De hecho, un total de 10 encuestados respondieron “0” en todas las preguntas sobre salud mental, mientras que ninguno respondió “10” en todas ellas.

Al igual que se hizo con los trastornos de forma individual, se realizó una regresión con todas las demás como predictoras para intentar predecir el valor de esta nueva variable.

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	17.084	1.256	13.604	< 2e-16	***
age	-0.936	0.361	-2.597	0.010	**
hours	1.041	0.330	3.153	0.002	**
work	0.108	0.796	0.135	0.892	
instr	0.193	0.769	0.251	0.802	
compose	0.608	0.892	0.682	0.496	
explore	-0.741	0.750	-0.987	0.324	
lang	-0.027	0.677	-0.040	0.968	
classical	0.256	0.337	0.760	0.448	
country	-0.459	0.331	-1.386	0.166	
edm	0.465	0.330	1.410	0.159	
folk	0.672	0.355	1.890	0.059	
gospel	0.008	0.334	0.023	0.982	
hiphop	-0.235	0.524	-0.449	0.654	
jazz	-0.202	0.360	-0.563	0.574	
kpop	-0.190	0.359	-0.529	0.597	
latin	0.053	0.343	0.154	0.878	
lofi	-0.041	0.361	-0.114	0.909	
metal	0.746	0.376	1.982	0.048	
pop	0.383	0.356	1.078	0.282	
rnb	0.410	0.414	0.992	0.322	
rap	0.291	0.511	0.569	0.569	
rock	0.361	0.385	0.937	0.349	
videogame	0.263	0.357	0.736	0.462	
apple	1.338	1.549	0.864	0.388	
other	0.507	1.520	0.333	0.739	
pandora	-1.246	2.834	-0.440	0.660	
spotify	0.462	1.102	0.419	0.675	
youtube	-1.106	1.308	-0.845	0.398	

Tabla 3.10 Resultado de la regresión lineal para predecir el valor de la variable “mh”, suma de todas las variables de salud mental, utilizando todas las variables predictoras

El R^2 de esta regresión fue de 0.053. Se aplicó el método Stepwise para seleccionar qué variables forman el mejor modelo, minimizando el AIC. En este caso se trata del modelo que incluye solamente las variables age, hours, country, edm, folk, metal, pop y youtube.

Variable	Estimate	Std. Error	t-value	Pr(>|t|)	
(Intercept)	17.253	0.316	54.550	< 2e-16	***
age	-0.958	0.307	-3.117	0.002	**
hours	1.070	0.303	3.536	0.000	***
country	-0.481	0.316	-1.520	0.129	
edm	0.475	0.302	1.574	0.116	
folk	0.774	0.324	2.387	0.017	*
metal	0.940	0.310	3.031	0.003	**
pop	0.486	0.309	1.572	0.116	
youtube	-1.608	0.893	-1.801	0.072	

Tabla 3.11 Resultado de la regresión lineal para predecir el valor de la variable "mh", suma de todas las variables de salud mental, utilizando las variables predictoras seleccionadas por el método stepwise

La R^2 es de 0.071. Se puede comprobar que la variable hours es la que mayor nivel de significación presenta, indicando existe una relación entre la cantidad de horas que los encuestados escucharon música y el aumento en sus niveles de los trastornos de salud mental en general. Una explicación sencilla a este fenómeno puede ser que, como la mayoría de los encuestados dicen mejorar con la escucha de música, recurren a ello en momentos de mayor nivel de depresión, ansiedad, insomnio o trastorno obsesivo-compulsivo. Al igual que ocurrió con varias variables de forma individual, los niveles de salud mental son peores en personas de menor edad. Esto puede deberse a que personas que han vivido más experiencias tienden a relativizar, y no autodiagnosticarse con niveles tan altos como las jóvenes.

3.2 RELACIÓN DE LAS VARIABLES DE SALUD MENTAL CON EL EFECTO

Se calculó la relación de estas variables con el efecto (con respuesta binaria, mejora/no mejora). En primer lugar, se calculó la correlación de cada variable individualmente con el efecto, así como de la suma de las cuatro utilizada en el epígrafe 3.1.5.

Al ser una variable numérica y otra categórica binaria, se trata de una correlación biserial-puntual, aunque es equivalente a la correlación de Pearson cuando la binaria toma valores numéricos de 0 y 1:

Correlación	effect
anxiety	0.120
depression	0.033
insomnia	0.002
ocd	0.043
mh	0.068

Tabla 3.12 Correlación biserial-puntual de cada una de las variables de salud mental con el efecto

Ninguna de las correlaciones es muy alta. Todas ellas son positivas, lo cual indica que a mayor valor, mayor probabilidad de que el encuestado mejore con la escucha de música. Esto puede deberse simplemente a que las personas que apenas sufren de estos trastornos no tienen “margen” de mejora.

La ansiedad tiene la relación más alta. Esto puede explicarse por ser el más “leve” e intermitente de estos trastornos.

Se realizó una regresión utilizando estas variables como predictoras de la mejoría (excepto la suma, evidentemente, ya que es una combinación lineal del resto), obteniéndose lo siguiente:

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	0.591	0.199	2.965	0.003	**
anxiety	0.117	0.038	3.093	0.002	**
depression	-0.024	0.034	-0.700	0.484	
insomnia	-0.023	0.030	-0.755	0.451	
ocd	0.006	0.033	0.188	0.851	

Tabla 3.13 Resultado de la regresión logística para predecir la variable “effect” con respuesta binaria, utilizando como predictoras las cuatro variables de salud mental

La desviación de los residuales es de 815.03, para 722 grados de libertad, y el p-valor del modelo es 0.009, lo que indica que la regresión logística no es estadísticamente significativa.

La única variable significativa es la ansiedad, con sentido positivo, como se calculó en el apartado anterior. En general no parece haber una relación estrecha entre estas variables y la mejoría.

Utilizando esta regresión sobre el conjunto de prueba, se predice siempre un valor de 1 (el encuestado muestra mejoría), por lo que podemos concluir que no es un modelo predictivo válido.

4. MODELOS PREDICTIVOS

En este capítulo se aplicarán varios algoritmos diferentes utilizando los datos de la encuesta, para desarrollar un modelo predictivo.

4.1 ÁRBOLES DE DECISIÓN

4.1.1 Árboles de decisión con respuesta categórica triple

De forma tentativa, se construyeron 3 árboles de clasificación, para tratar de predecir, en función del resto de variables, si la condición de la persona mejorará, empeorará o no tendrá ningún efecto.

Para construir estos árboles y que sean diferentes, se dividieron los datos en conjuntos train:test diferentes en cada uno de los casos. Se mantuvo constante la proporción del 80% para los datos de entrenamiento, y el 20% restante para los de prueba, quedando en todos los casos una distribución de 581 datos para el conjunto train y 146 para el conjunto test.

4.1.1.1 Árbol 1

Se obtuvo un árbol con 19 nodos, 10 de ellos terminales:

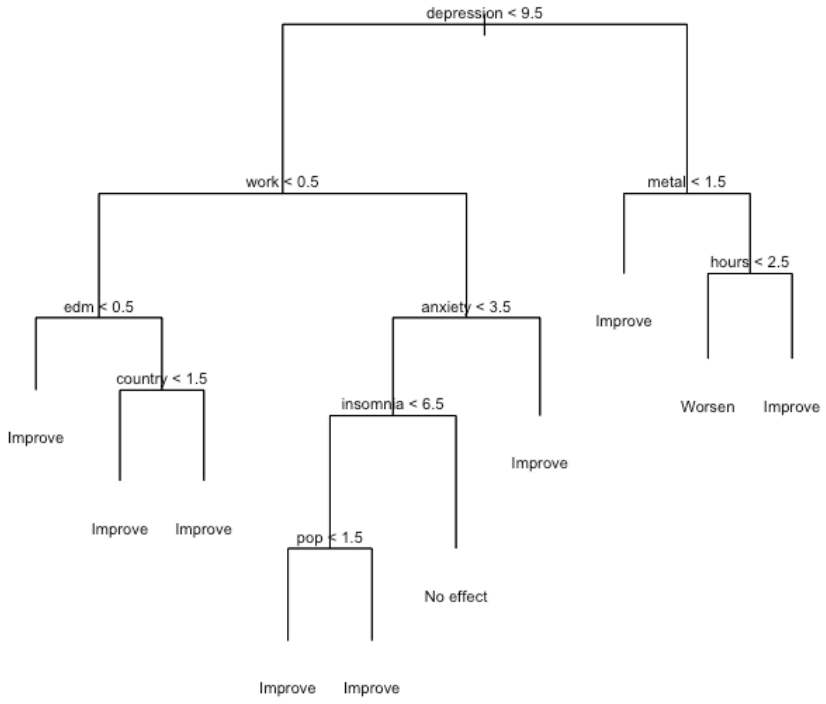

Figura 4.1 Primer árbol de decisión

Varios nodos de la parte izquierda del árbol son triviales, es decir, proporcionarían la misma respuesta a ambos lados de la división.

Árbol 1		Valores reales		
		Improve	No effect	Worsen
Valores predichos	Improve	108	0	1
	No effect	35	1	0
	Worsen	1	0	0

Tabla 4.1 Predicciones en el conjunto de prueba utilizando el primer modelo de árbol

El porcentaje de acierto es del 74.66%.

4.1.1.2 Árbol 2

Se obtuvo un árbol de 31 nodos, 16 de ellos terminales.

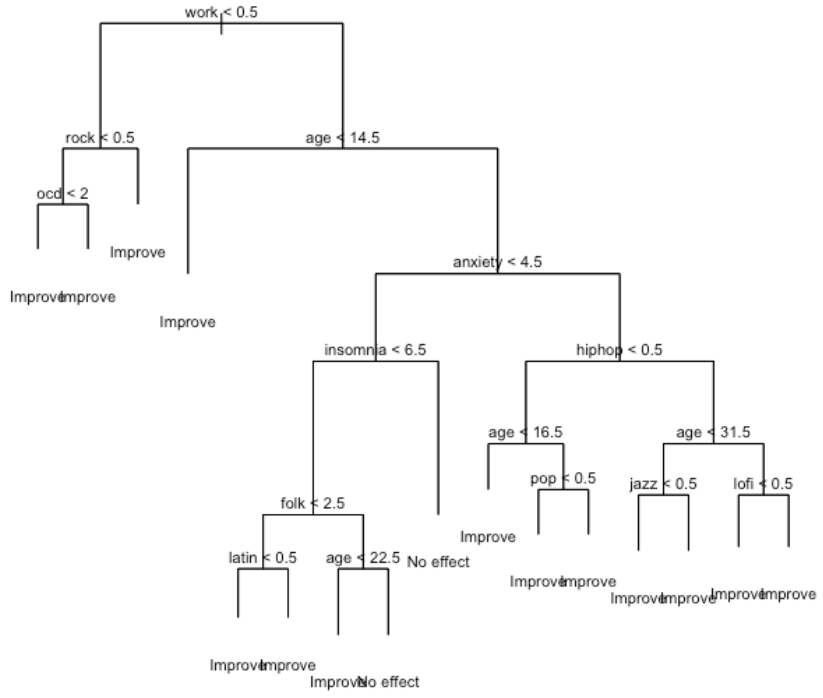

Figura 4.2 Segundo árbol de decisión

Pese al mayor número de nodos terminales con respecto al primer árbol, solamente dos proporcionan la respuesta “No effect”, y ninguno la respuesta “Worsen”.

Árbol 2		Valores reales		
		Improve	No effect	Worsen
Valores predichos	Improve	97	40	3
	No effect	4	2	0
	Worsen	0	0	0

Tabla 4.2 Predicciones en el conjunto de prueba utilizando el segundo modelo de árbol

La tasa de acierto con el conjunto de prueba es del 67.81%.

4.1.1.3 Árbol 3

Este árbol contiene 25 nodos, 13 de ellos terminales.

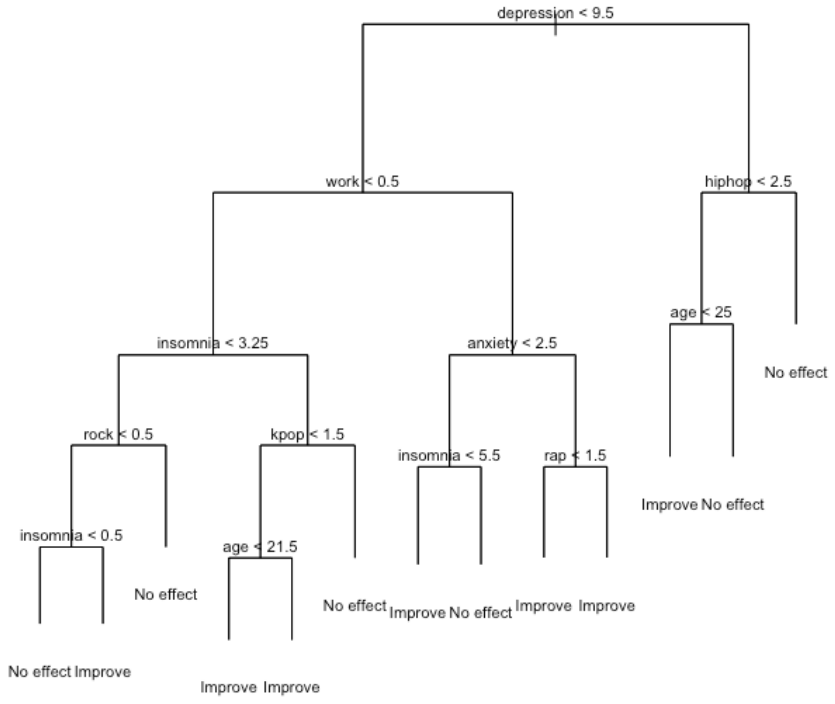

Figura 4.3 Tercer árbol de decisión

Árbol 3		Valores reales		
		Improve	No effect	Worsen
Valores predichos	Improve	95	22	2
	No effect	15	12	0
	Worsen	0	0	0

Tabla 4.3 Predicciones en el conjunto de prueba utilizando el tercer modelo de árbol

La tasa de acierto sobre el conjunto test es del 73.29%.

En este caso tampoco está representada como una posibilidad la respuesta “empeorar”. Solamente dos de los nodos terminales son triviales.

En todos los casos es posible que exista sobrerrepresentación de los datos de entrenamiento, especialmente teniendo en cuenta de la alta variabilidad de la base de datos. Se podría realizar un proceso de poda para evitar esto, y para eliminar algunas de las divisiones triviales. Previo a realizar cualquier otro algoritmo, es conveniente analizar de forma general los resultados obtenidos.

Las variables que más importancia tienen, por ser las que primero dividen el árbol, parecen ser “work” y “depression”. En las ramas más bajas, sin embargo, se observa una enorme variabilidad entre unos árboles y otros.

Los porcentajes de acierto no son buenos. En los tres casos, el porcentaje que se obtendría prediciendo la respuesta “mejorar” para todos los resultados del conjunto de prueba, se obtendría un porcentaje igual o superior al que se obtuvo mediante los árboles de decisión.

4.1.2 Árboles de decisión con respuesta binaria

En los dos últimos casos del apartado anterior, el efecto “empeorar” no está ni siquiera representado en el árbol. Recordemos que este efecto suponía solamente el 2.3% de los casos. Por tanto, para desarrollar un modelo predictivo más preciso, aunque no sea tan exacto, se repetirán los árboles con respuesta binaria (sí/no) para la variable efecto.

Se repiten los árboles utilizando respuesta binaria. Se ha utilizado el comando set.seed() para que los conjuntos train y test sean los mismos que en los árboles análogos del apartado anterior. De esta forma la comparación será más precisa.

4.1.2.1 Árbol 1

Este árbol consta de 13 nodos, 7 de ellos terminales.

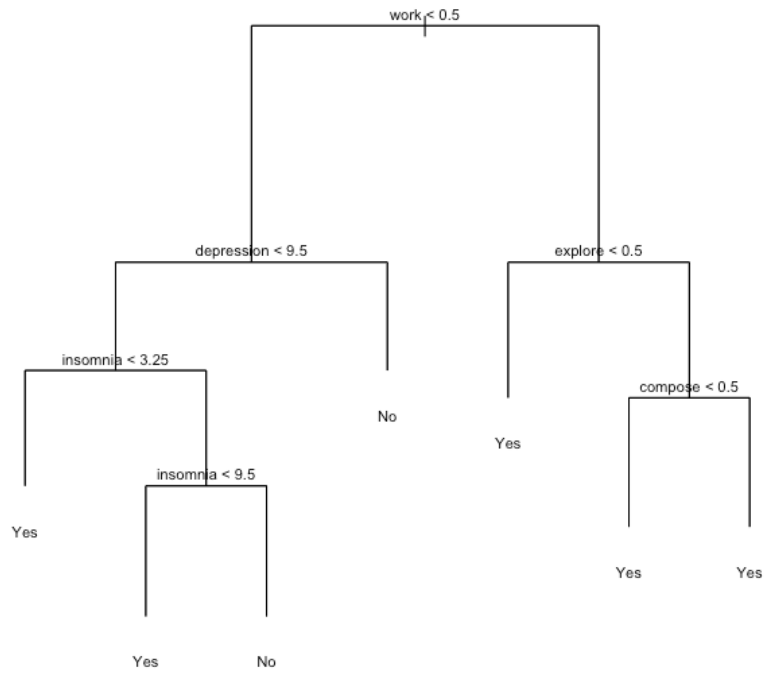

Figura 4.4 Primer árbol de decisión con respuesta binaria

El árbol es más sencillo que los obtenidos en el apartado anterior. Además, solo uno de los nodos finales es trivial.

Árbol 1 Respuesta binaria		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	106	37
	No	3	0

Tabla 4.4 Predicciones en el conjunto de prueba utilizando el primer modelo de árbol con respuesta binaria

El porcentaje de acierto para este árbol es el 72.60%, inferior al obtenido para los mismos conjuntos con respuesta ternaria.

4.1.2.2 Árbol 2

Este árbol cuenta con 29 nodos, 15 nodos terminales.

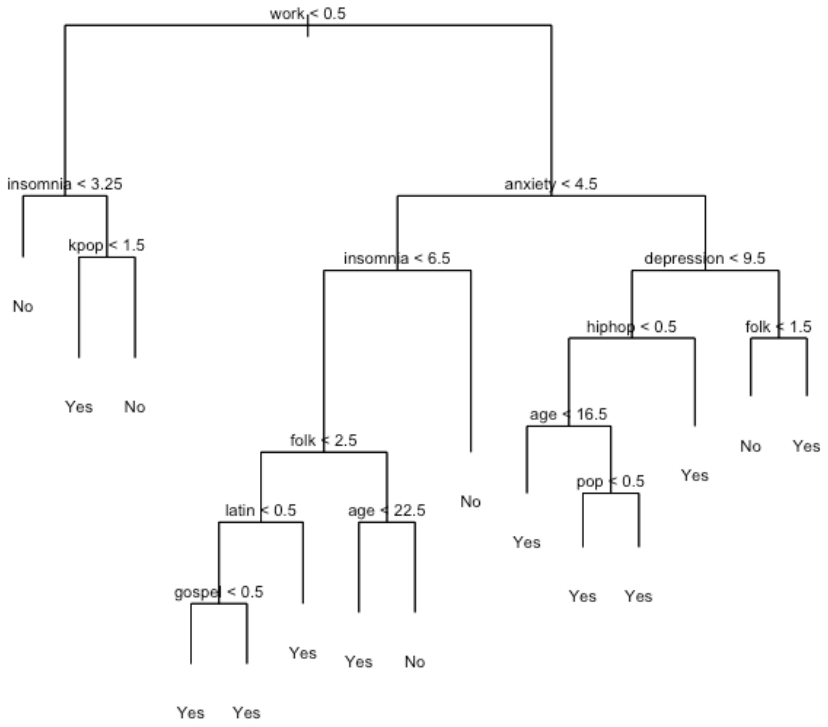

Figura 4.5 Segundo árbol de decisión con respuesta binaria

Éste es el árbol con más nodos igual que en el caso anterior, pero es más sencillo que en aquel caso. Sigue habiendo muchos nodos terminales triviales.

Árbol 2 Respuesta binaria		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	85	33
	No	16	12

Tabla 4.5 Predicciones en el conjunto de prueba utilizando el segundo modelo de árbol con respuesta binaria

De nuevo, en este caso la precisión es menor, ascendiendo solamente a un 66.44%

4.1.2.3 Árbol 3

Este árbol cuenta con 17 nodos, 9 de ellos terminales.

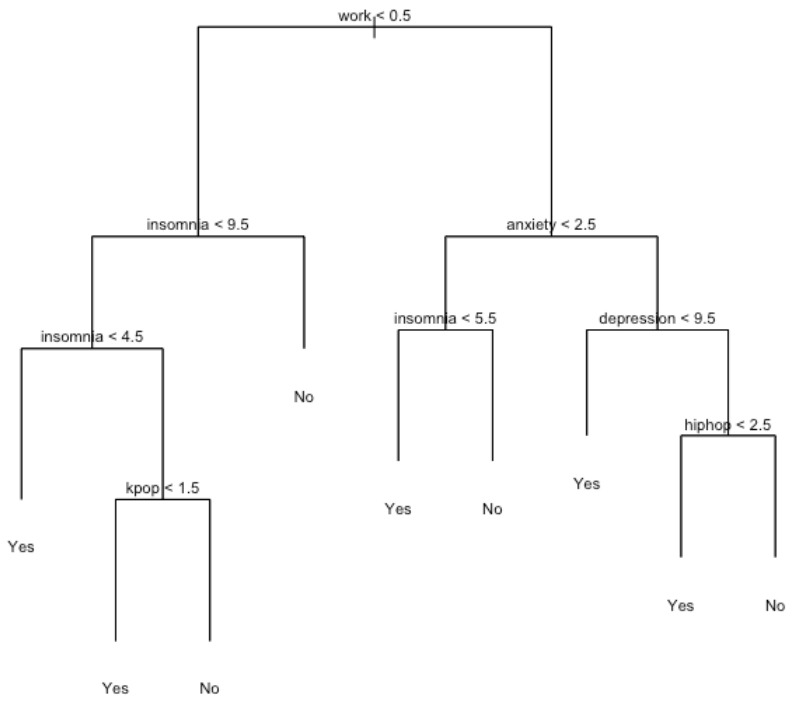

Figura 4.6 Tercer árbol de decisión con respuesta binaria

Árbol 3 Respuesta binaria		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	97	30
	No	13	6

Tabla 4.6 Predicciones en el conjunto de prueba utilizando el tercer modelo de árbol con respuesta binaria

El porcentaje de acierto es de un 70.55%, nuevamente menor que en el caso con 3 respuestas.

Al igual que cuando la respuesta era ternaria, la variable de mayor importancia parece ser work, siendo en este caso la primera división de los tres árboles. En los tres casos los porcentajes de acierto son ligeramente inferiores a los de las tres respuestas. Esto puede deberse a una sobrerrepresentación mayor del conjunto de entrenamiento, que podría subsanarse mediante un proceso de poda. En este caso, se probará a utilizar un algoritmo Random Forests, que tiende a tener mayor robustez que árboles simples.

4.2 RANDOM FOREST

4.2.1 Random Forest con respuesta categórica triple

Se realizó un algoritmo Random Forest con 500 árboles. En primer lugar, para la salida original de la variable, con 3 posibles respuestas. En primer lugar se calculó el número de variables que se examinarán aleatoriamente para cada árbol (mtry).

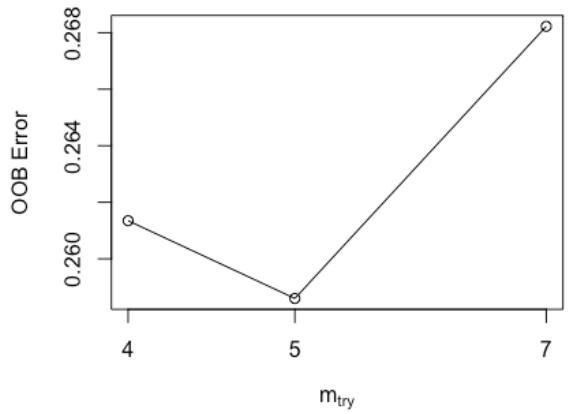

Figura 4.7 Error out-of-bag para cada valor de m_{try} del algoritmo Random Forest

El valor de mtry que minimiza el error out-of-bag es 5, por lo que será el utilizado. El número de árboles de decisión seleccionado es 500.

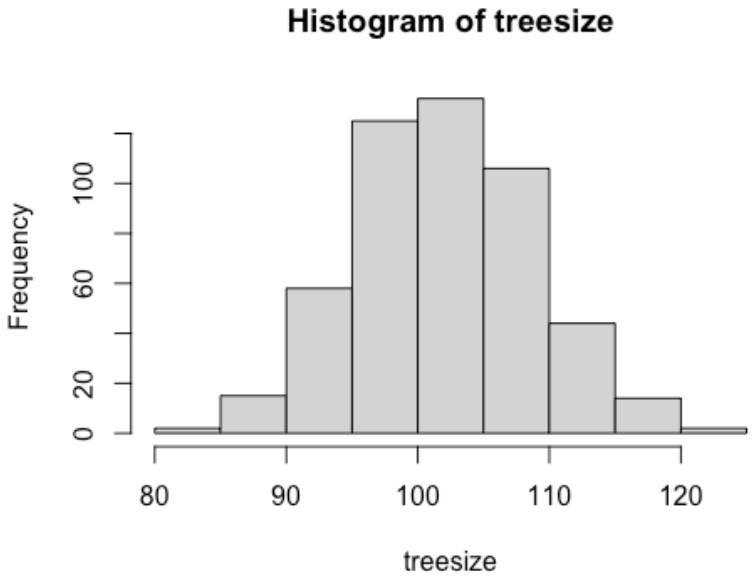

Figura 4.8 Histograma del número de nodos de los 500 árboles del modelo Random Forest desarrollado

El número medio de nodos de los árboles es 102.5.

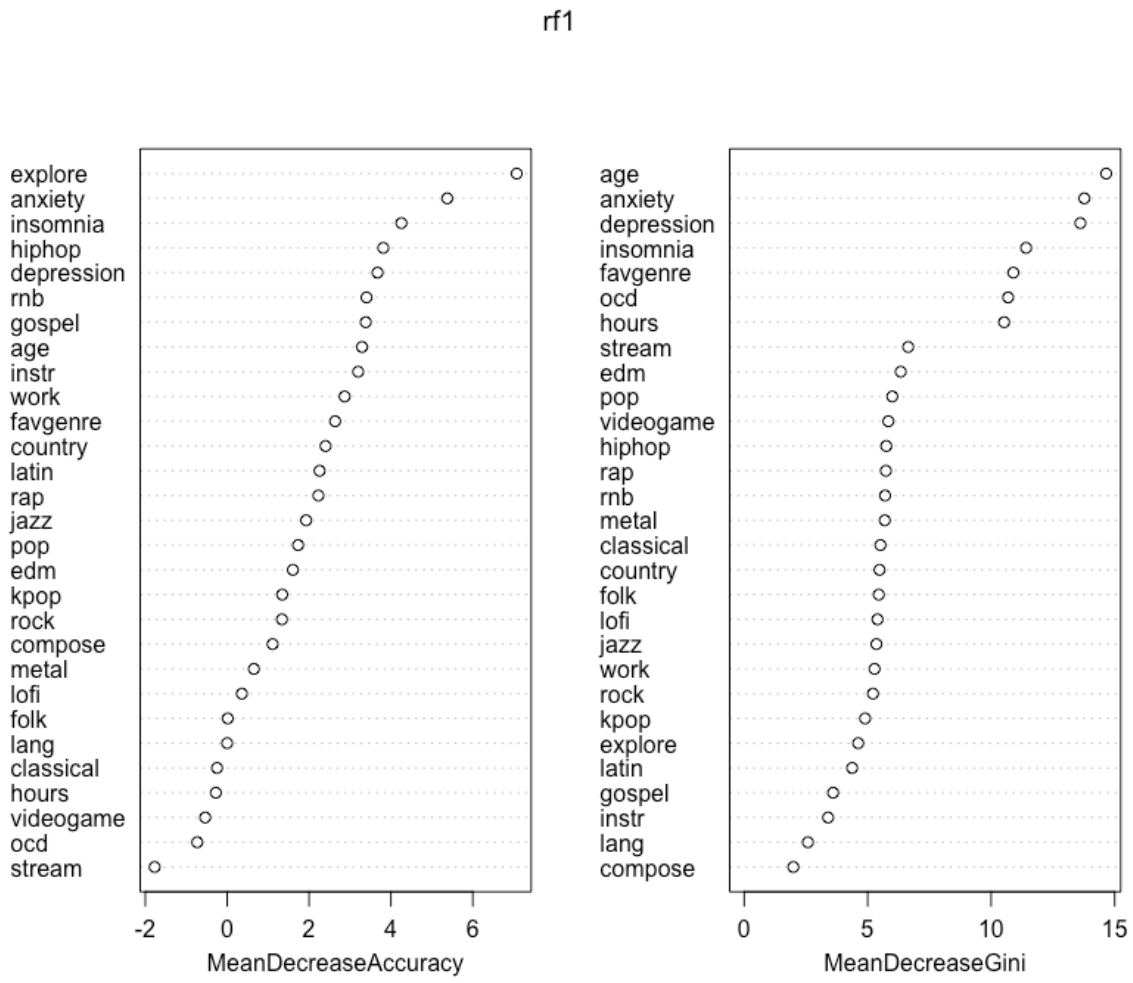

Figura 4.9 Importancia relativa de las variables utilizadas en el algoritmo Random Forest desarrollado, en porcentaje de incremento del error cuadrado medio, e incremento de la pureza del nodo cuando se selecciona cada variable

Los resultados obtenidos aplicando el modelo sobre el conjunto de prueba son los siguientes:

Random Forest 1		Valores reales		
		Improve	No effect	Worsen
Valores predichos	Improve	157	52	5
	No effect	4	1	0
	Worsen	0	0	0

Tabla 4.7 Predicciones sobre el conjunto de prueba utilizando el primer modelo Random Forest

La precisión es del 72.15%. Como podemos comprobar nunca se predice que los encuestados empeoren, y casi nunca que no haya efecto. Se repetirá el modelo para respuesta binaria mejorar/no mejorar.

4.2.2 Random Forest con respuesta binaria

Ahora, se repetirá el algoritmo, pero utilizando la variable respuesta binaria. Nuevamente, se comienza calculando el valor óptimo de mtry:

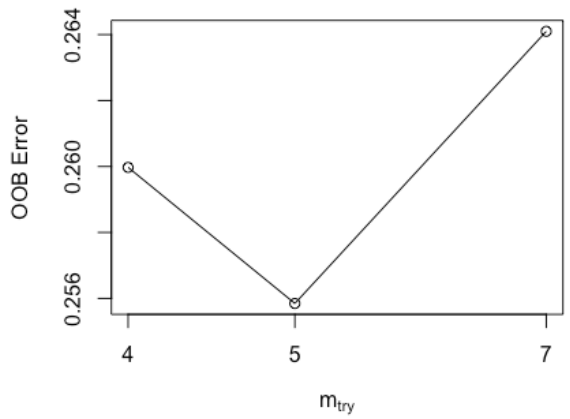

Figura 4.10 Error out-of-bag para cada valor de m_{try} del algoritmo Random Forest con respuesta binaria

El valor óptimo de mtry es de nuevo 5. Los errores out-of-bag son ligeramente menores que en el caso de la respuesta ternaria.

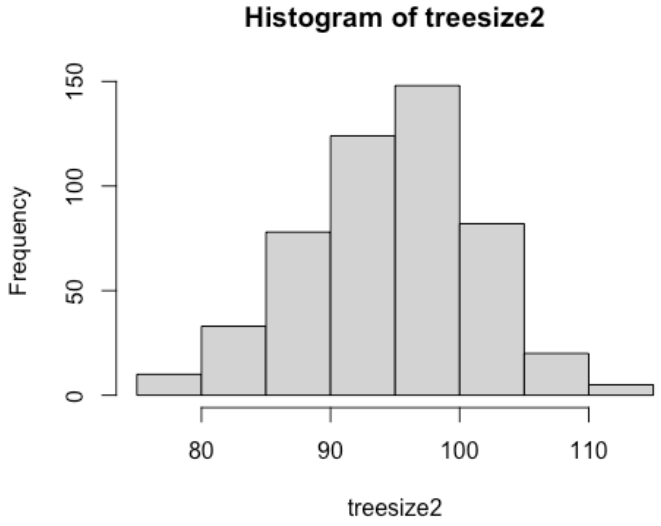

Figura 4.11 Histograma del número de nodos de los 500 árboles del modelo Random Forest con respuesta binaria

La media es de 95.16 nodos en los árboles, menor que en el caso anterior. Esto puede explicarse por tener una opción menos en la respuesta.

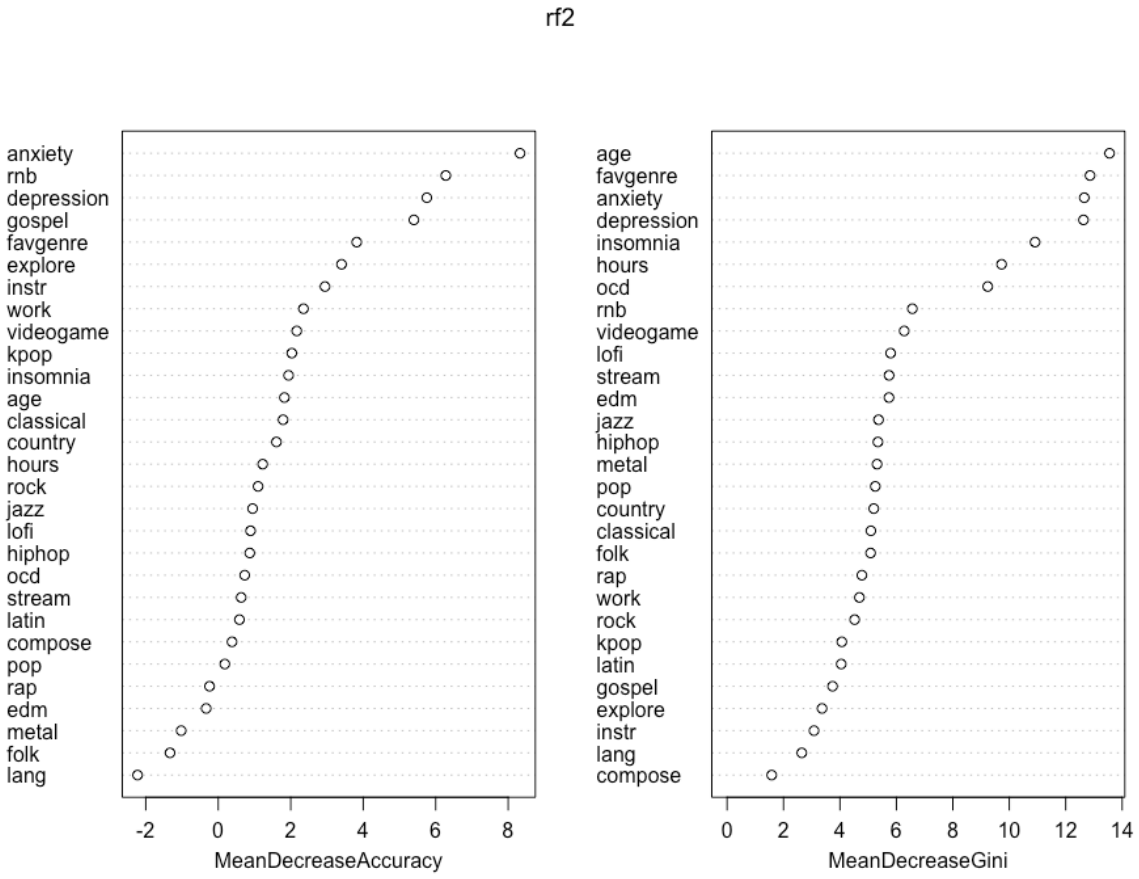

Figura 4.12 Importancia relativa de las variables utilizadas en el algoritmo Random Forest desarrollado con respuesta binaria, en porcentaje de incremento del error cuadrado medio, e incremento de la pureza del nodo cuando se selecciona cada variable

Random Forest Respuesta binaria		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	153	61
	No	3	2

Tabla 4.8 Predicciones sobre el conjunto de prueba utilizando el modelo Random Forest con respuesta binaria

La precisión obtenida es menor que en el caso anterior, del 70.78%. En tan sólo 5 ocasiones se predijo que el encuestado no mejora.

4.3 MÁQUINAS DE VECTOR SOPORTE (SVM)

El siguiente método que se probó fue una máquina de vector soporte. Este método coloca todos los datos en un espacio de n dimensiones, siendo n el número de variables predictoras, y los divide por medio de un hiperplano. Como la división es por medio de un solo plano, la predicción será binaria. Por ello, se utilizó la variable respuesta binaria que indica si la persona respondió que mejora o no respondió que mejora, no diferenciando entre “no notar ninguna diferencia” y “empeorar”.

Se calcularon tres máquinas distintas, cada una con un tipo de “kernel”. Los tres tipos de división utilizada para las regiones “Sí” y “No” fueron un hiperplano lineal, polinómica y radial.

Este método es bastante sensible a datos con un gran desequilibrio entre cada una de las dos posibles respuestas. Este desequilibrio no es especialmente grande en el caso que nos concierne (aproximadamente 70/30), pero el hecho de haber tantas variables predictoras que no están muy correladas con esta variable respuesta, hace que en todos los casos se prediga únicamente el caso “1”, es decir, “mejoría”. Dicho de otra forma, el hiperplano deja todos los datos disponibles del mismo lado. Esto ocurrió para el kernel lineal, para el polinómico y para el radial. Por esta razón, este método no es válido para el problema que fue planteado.

4.4 REGRESIÓN LOGÍSTICA

Se utilizarán las mismas variables que se utilizaron para el análisis de componentes principales: Se retira la variable favgenre, y se utilizan el resto en forma de numéricas centradas (excepto las binarias que siguen correspondiéndose con 1 y 0).

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-0.253	0.355	-0.714	0.475	
age	-0.052	0.108	-0.482	0.630	
hours	-0.041	0.101	-0.405	0.686	
work	0.789	0.224	3.520	0.000	***
instr	0.489	0.240	2.038	0.042	*
compose	0.409	0.297	1.378	0.168	
explore	0.672	0.216	3.114	0.002	**
lang	-0.142	0.206	-0.690	0.490	
classical	-0.169	0.103	-1.641	0.101	
country	0.227	0.105	2.164	0.030	*
edm	0.045	0.101	0.449	0.654	
folk	-0.136	0.107	-1.264	0.206	
gospel	0.143	0.113	1.264	0.206	
hiphop	0.124	0.160	0.775	0.438	
jazz	-0.020	0.111	-0.178	0.859	
kpop	-0.025	0.112	-0.223	0.823	
latin	0.042	0.109	0.384	0.701	
lofi	-0.010	0.110	-0.089	0.929	
metal	-0.043	0.113	-0.379	0.705	
pop	-0.011	0.106	-0.107	0.915	
rnb	0.226	0.127	1.780	0.075	.
rap	-0.179	0.155	-1.157	0.247	
rock	-0.083	0.117	-0.710	0.478	
videogame	-0.004	0.107	-0.040	0.968	
anxiety	0.374	0.113	3.321	0.001	***
depression	-0.076	0.112	-0.683	0.494	
insomnia	-0.059	0.101	-0.585	0.558	
ocd	-0.050	0.100	-0.503	0.615	
apple	0.034	0.452	0.076	0.940	
other	0.140	0.437	0.321	0.748	
pandora	14.264	440.270	0.032	0.974	
spotify	0.222	0.314	0.705	0.481	
youtube	0.302	0.377	0.800	0.423	

Tabla 4.9 Resultados de la regresión logística para predecir la variable “efecto” utilizando todas las demás variables como predictoras

Se obtuvo una desviación de los residuales de 746.84, para 694 grados de libertad, lo que se corresponde con un p-valor de 0.081. Este p-valor es pequeño, pero superior a 0.05, por lo que podemos considerar que existe un modelo estadísticamente significativo.

Utilizando este modelo sobre los propios datos utilizados, el porcentaje de acierto es del 76.34%. Este dato no es concluyente, puesto que obviamente puede existir sobreajuste, ya que los datos usados para desarrollar el modelo y para predecir son los mismos.

Igualmente, al tratarse de un modelo con muchas variables, se procedió a aplicar el método stepwise con el criterio de Akaike, para seleccionar qué variables predictoras generan un modelo más significativo. Tras varias iteraciones, el modelo que minimiza el AIC es el que utiliza 9 de las variables 32 originales. El nuevo modelo de regresión es el siguiente:

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-0.058	0.212	-0.276	0.783	
work	0.711	0.204	3.494	0.000	***
instr	0.650	0.214	3.040	0.002	**
explore	0.634	0.194	3.267	0.001	**
classical	-0.185	0.094	-1.981	0.048	*
country	0.220	0.094	2.329	0.020	*
rnb	0.226	0.094	2.396	0.017	*
rock	-0.173	0.094	-1.845	0.065	.
anxiety	0.271	0.088	3.067	0.002	**
pandora	14.303	437.533	0.033	0.974	

Tabla 4.10 Resultados de la regresión logística para predecir la variable “efecto” utilizando como predictoras las variables seleccionadas por el método stepwise

La desviación de los residuales es de 757.84, para 717 grados de libertad, y el p-valor del modelo es 0.145.

Todas las variables son estadísticamente significativas para un nivel de confianza del 95%, excepto rock y pandora. El p-valor de la variable pandora es muy cercano a 1, por lo que hay una probabilidad muy baja de que su coeficiente sea diferente de 0. Sin embargo, el valor absoluto de este coeficiente es muy grande comparado con el resto. Esto puede deberse a que es una variable binaria con muy pocos valores 1. Para este modelo el porcentaje de acierto sobre los propios datos es del 75.65%, ligeramente inferior al obtenido utilizando todas las variables.

Se realizó una nueva regresión ignorando también la variable pandora, obteniéndose el siguiente resultado.

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-0.043	0.212	-0.205	0.838	
work	0.726	0.203	3.576	0.000	***
instr	0.650	0.213	3.050	0.002	**
explore	0.623	0.194	3.218	0.001	**
classical	-0.181	0.093	-1.940	0.052	.
country	0.225	0.094	2.394	0.017	*
rnb	0.230	0.094	2.440	0.015	*
rock	-0.177	0.094	-1.880	0.060	.
anxiety	0.269	0.088	3.067	0.002	**

Tabla 4.11 Resultados de la regresión logística para predecir la variable “efecto” utilizando como predictoras las variables work, instr, explore, classical, country, rnb, rock y anxiety

La desviación de los residuales ascendió a 762.33 para 718 grados de libertad. El p-valor de este nuevo modelo bajó hasta un valor de 0.122.

El porcentaje de acierto sobre los propios datos es idéntico al anterior: 75.65%. Es superior al porcentaje que se obtendría si se hubiese predicho simplemente “Sí” para todos los casos (74.42%). En cualquier caso, este porcentaje no nos indica de forma fidedigna la robustez del modelo, ya que se han utilizado los mismos datos para las predicciones que para desarrollarlo. De esta forma es fácil que el modelo se ajuste más a los datos concretos que se utilizaron que a una hipotética población general de la que provienen. Para evitar este sobreajuste, se procedió a realizar la misma regresión mediante validación cruzara y bootstrapping.

4.5 VALIDACIÓN CRUZADA K-FOLD

Se repitió la regresión, utilizando validación cruzada 5-fold (5 grupos distintos de validación), con 9 repeticiones. Los valores obtenidos cuando se introducen todas las variables son idénticos a los de la regresión original, presentados en la Tabla 4.9 (al menos hasta el tercer decimal).

Se realizó el mismo proceso con las 9 variables seleccionadas por el método stepwise, y, nuevamente, los valores obtenidos fueron idénticos hasta el tercer decimal que los de la Tabla 4.10. Lo mismo ocurrió para la regresión logística con 8 variables predictoras: se obtuvieron los resultados de la Tabla 4.11.

Al ser el número de datos bastante alto, el resultado por validación cruzada con varias repeticiones va a tender a asemejarse al obtenido calculando la regresión con todos los datos, por ello se obtienen resultados muy similares.

4.6 BOOTSTRAPPING

Mediante bootstrapping, se seleccionan los datos de forma aleatoria con reemplazo hasta tener un número de datos iguales a los de la muestra. En cada repetición de este proceso, se utilizan, de media, el 63.2% de los datos disponibles (varios de ellos repetidos).

En primer lugar, se realizó con todas las variables, y los valores centrales obtenidos son nuevamente idénticos a los obtenidos en una sola regresión y por validación cruzada. Esto puede deberse a que el amplio número de datos y la variabilidad compensan la aleatoriedad de los remuestreos.

Se realizó una nueva regresión, utilizando solo las variables de la Tabla 4.11, para obtener una estimación de los coeficientes mediante un intervalo de confianza. Nótese que los valores centrales son, nuevamente, iguales a los obtenidos en la regresión simple.

Para calcular los intervalos, se tomó un nivel de confianza del 95%, por lo que los límites del intervalo que estime cada coeficiente serán los que estén 1.96 desviaciones estándar a la izquierda y a la derecha del valor central.

Variable	Estimate	Std. Error	Inferior	Superior
(Intercept)	-0.043	0.212	-0.458	0.372
work	0.726	0.203	0.328	1.124
instr	0.650	0.213	0.232	1.067
explore	0.623	0.194	0.244	1.003
classical	-0.181	0.093	-0.363	0.002
country	0.225	0.094	0.041	0.409
rnb	0.230	0.094	0.045	0.416
rock	-0.177	0.094	-0.361	0.007
anxiety	0.269	0.088	0.097	0.442

Tabla 4.12 Intervalos de confianza de los coeficientes resultantes de la regresión logística, calculados por bootstrapping, utilizando como predictoras las mismas variables que en la tabla 4.11

Se obtuvo una raíz del error medio cuadrático de 0.425, y un R^2 de 0.066, por lo que la regresión no es muy buena.

Se observa que los intervalos son bastante amplios, debido a los grandes errores del modelo. Los intervalos correspondientes a los coeficientes de las variables “classical”, “rock” y la ordenada en el origen incluyen el 0, por lo que sus valores centrales no son significativamente distintos de 0. Esto coincide con lo obtenido en la regresión logística presentada en la Tabla 4.11.

4.7 BOOSTED TREE

Se aplicó a los datos con respuesta binaria un algoritmo Boosted tree, con un conjunto de entrenamiento formado por el 75% de los datos. Se utilizó una distribución de Bernoulli y 5000 árboles. A continuación se presentan las importancias de las variables:

Variable	Influencia relativa	Variable	Influencia relativa
age	11.70%	**edm**	2.51%
anxiety	8.62%	**classical**	2.51%
depression	8.18%	**folk**	2.44%
insomnia	7.02%	**work**	2.18%
hours	5.77%	**latin**	2.13%
ocd	5.46%	**instr**	1.85%
lofi	3.78%	**rock**	1.71%
videogame	3.45%	**kpop**	1.61%
pop	3.43%	**gospel**	1.52%
explore	3.34%	**spotify**	0.99%
hiphop	3.19%	**lang**	0.79%
country	3.10%	**compose**	0.66%
rap	2.99%	**youtube**	0.38%
metal	2.91%	**apple**	0.23%
jazz	2.75%	**other**	0.20%
rnb	2.59%	**pandora**	0.00%

Tabla 4.13 Influencia relativa de cada variable en el modelo Boosted Tree

La edad es la variable más importante con cierta diferencia sobre la ansiedad que es la segunda. El resto de las variables relacionadas con los trastornos de salud mental se encuentran también entre las más importantes, junto con las horas diarias. Dentro de los estilos musicales, el lofi, el pop y la música de videojuegos son los que más importancia tienen, y el kpop y el gospel los que menos. Las cuatro variables menos importantes se corresponden con variables “dummy” provenientes de la variable categórica stream.

Se representó el comportamiento de la variable de salida con respecto a las dos variables de mayor importancia de forma marginal:

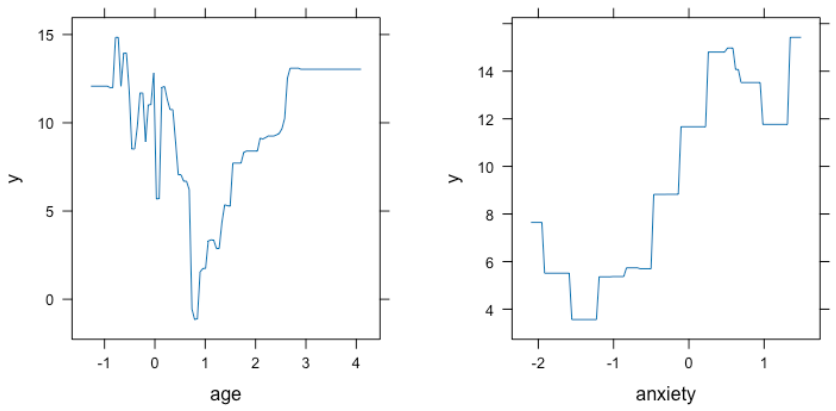

Figura 4.13 Comportamiento marginal de la variable respuesta en función de los valores de las dos variables que presentan mayor importancia en el modelo Boosted Tree: edad y ansiedad

Cuando los valores relacionados a la ansiedad son altos, tiende a aumentar la probabilidad de que la variable respuesta sea catalogada como “1”. Para la variable edad se observa un comportamiento más extraño. Para edades entre -1 y 1 desviaciones de la media se obtiene un descenso en la probabilidad de ser catalogado un dato como “1”. Sin embargo, después la gráfica vuelve a subir, en edades muy a la derecha de la media. Esto puede deberse a que la mayoría de las edades están muy cercanas a la izquierda de la media, y hay algún dato aislado para edades altas que rompe con la tendencia general y produce esa nueva subida. De todos modos, la forma irregular de la gráfica nos indica la poca relación “real” que hay entre las variables.

Aplicando este árbol sobre el conjunto de prueba se obtiene lo siguiente:

Boosted tree		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	112	30
	No	32	8

Tabla 4.14 Predicciones sobre el conjunto de prueba utilizando el modelo Boosted Tree, con respuesta binaria

Las predicciones están distribuidas proporcionalmente de forma similar a los valores reales. No obstante, la precisión obtenida es de solamente un 65.93%, bastante menor que si hubiese predicho siembre “Yes”, en cuyo caso acertaría en el 79.12% de los casos.

4.8 k-NEAREST NEIGHBOURS (kNN)

Se creó un modelo kNN, para valores de n entre 1 y 30 (número de puntos más cercanos que se buscan). Se utilizó una división train:test de 75:25. Para la división realizada, el 76.92% de los resultados son iguales a 1 (el encuestado mejora). El primer modelo que supera este valor es el obtenido para n=3, con una precisión de 79.12%. El mayor valor de precisión obtenido entre los calculados fue para n=10, con una precisión del 81.32%.

N	Precisión	N	Precisión
1	75.27%	**16**	78.57%
2	73.63%	**17**	78.57%
3	79.12%	**18**	78.57%
4	77.47%	**19**	78.57%
5	75.82%	**20**	79.12%
6	76.92%	**21**	78.02%
7	77.47%	**22**	78.57%
8	76.92%	**23**	77.47%
9	78.57%	**24**	78.02%
10	**81.32%**	**25**	78.02%
11	79.12%	**26**	76.92%
12	78.02%	**27**	76.92%
13	78.02%	**28**	76.92%
14	78.57%	**29**	76.92%
15	78.02%	**30**	76.92%

Tabla 4.15 Precisiones para los 30 primeros valores de N del modelo kNN realizado

Estos son los resultados obtenidos para la predicción dos de los mejores modelos kNN desarrollados, n=3 y n=10:

kNN (n=3)		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	132	30
	No	8	12

Tabla 4.16 Predicciones sobre el conjunto de prueba utilizando el modelo kNN con respuesta binaria, para N=3

kNN (n=10)		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	137	31
	No	3	11

Tabla 4.17 Predicciones sobre el conjunto de prueba utilizando el modelo kNN con respuesta binaria, para N=10

Se observa que se predice “No” en bastantes más casos que en otros modelos, y, especialmente en el caso de n=10, con bastante precisión. Sin embargo, se siguen produciendo muchos errores de tipo I (falsos positivos).

5. MODELOS PREDICTIVOS CON DATOS COMPENSADOS

5.1 OBTENCIÓN DE DATOS EQUILIBRADOS

Parece que las variables que se eligieron como predictoras hasta el momento no parecen predecir adecuadamente el efecto que tiene la música sobre la posible mejoría en la salud mental de los encuestados. Uno de los principales problemas que se encontraron en el desarrollo de los modelos fue el desequilibrio entre las distintas opciones de la variable respuesta, ya fuera categórica ternaria o binaria, ya que la opción "presenta mejoría" suponía aproximadamente tres cuartos del total de los datos. Para algunos de los métodos utilizados, como kNN o Boosted Trees, esto puede suponer una sobrerrepresentación de la clase más común, como terminó ocurriendo en la mayoría de los procedimientos.

Para paliar este inconveniente existen diversos métodos, como métodos de remuestreo que den mayor probabilidad de elegir datos de las clases menos comunes, ajuste de probabilidades a priori, o dar distintos pesos a los datos en función de su clase. En el caso que nos concierne, se decidió utilizar únicamente la respuesta binaria, que unifica los casos en los que las personas dicen no mejorar o empeorar en una misma categoría "no mejora", y se remuestrearon los datos hasta tener, de forma aproximada, los mismos casos en ambas clases (Johnson & Kuhn, 2013).

Tras las transformaciones, el número total de datos es 1082, de los cuales la mitad (541) tienen respuesta en la variable effect igual a 1, y la otra mitad, igual a 0.

Con estos nuevos datos, ahora equilibrados, se procederá a repetir alguno de los modelos realizados anteriormente. Previamente, se realizaron las mismas transformaciones que en la base de datos original, para obtener resultados válidos.

5.2 RANDOM FOREST

El algoritmo Random Forest depende de varios árboles de decisión, los cuales son sensibles a desigualdades en la variable respuesta. Por tanto, se realizó un nuevo algoritmo Random Forest con estos nuevos datos, dividiendo los datos en conjuntos de entrenamiento y de prueba con una proporción 70/30. En primer lugar se calculó la cantidad óptima de variables que se deben de probar en cada nodo, obteniéndose lo siguiente:

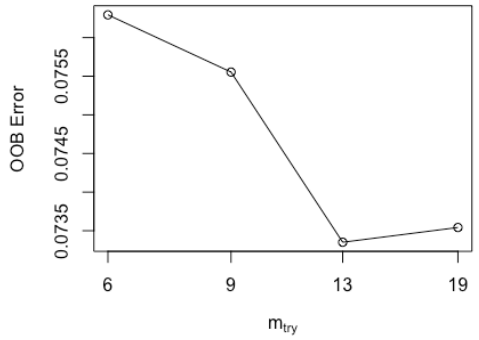

Figura 5.1 Error out-of-bag para cada valor de m_{try} del algoritmo Random Forest desarrollado con los datos compensados

Dado que el valor más pequeño de error out-of-bag se obtuvo para mtry=13, se utilizará este valor para el algoritmo. El número de árboles seleccionado fue 500.

Una vez desarrollado el modelo, se utilizó el conjunto de prueba para predecir la respuesta de la variable effect, obteniéndose estos resultados:

Random Forest		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	125	7
	No	18	175

Tabla 5.1 Predicciones sobre el conjunto de prueba utilizando el modelo Random Forest desarrollado con los datos compensados

La precisión es del 91.46%. Los resultados son notablemente mejores que los obtenidos con los datos originales. Sin embargo, esto no tiene por qué ser bueno, ya que podemos estar sobrerrepresentando los casos en los que el encuestado no mejora.

Se analizaron también el número de nodos de los árboles, y la importancia relativa de las variables:

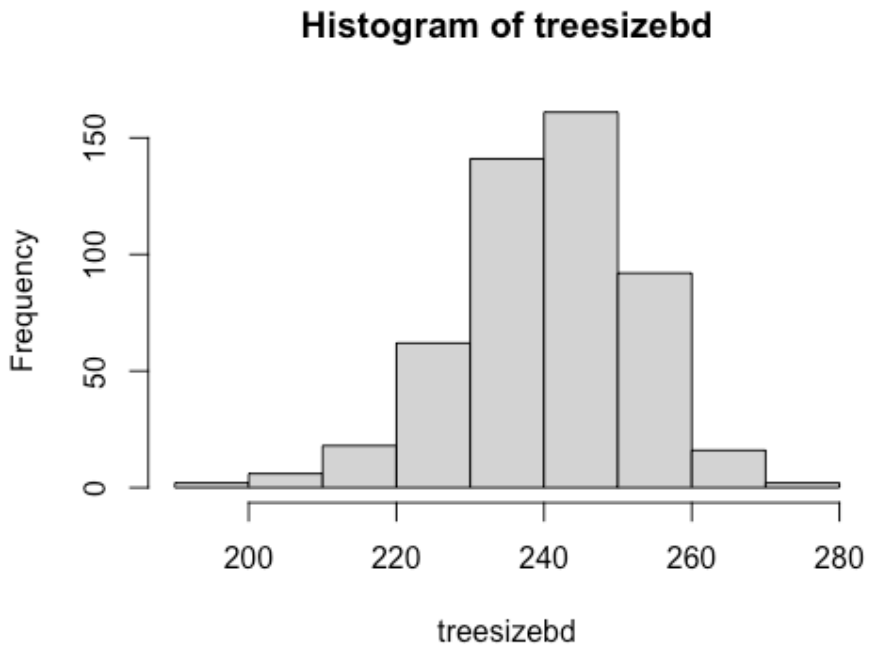

Figura 5.2 Histograma del número de nodos de los 500 árboles del modelo Random Forest desarrollado con los datos compensados

El tamaño de los árboles es mucho más grande que los observados en el epígrafe 4.2, con una media de 240.9. Esto puede ser debido no solo al mayor número de datos, sino también al mayor número de variables que se seleccionan aleatoriamente en cada uno de ellos.

Veamos ahora las importancias relativas de cada variable en el global de todos los árboles:

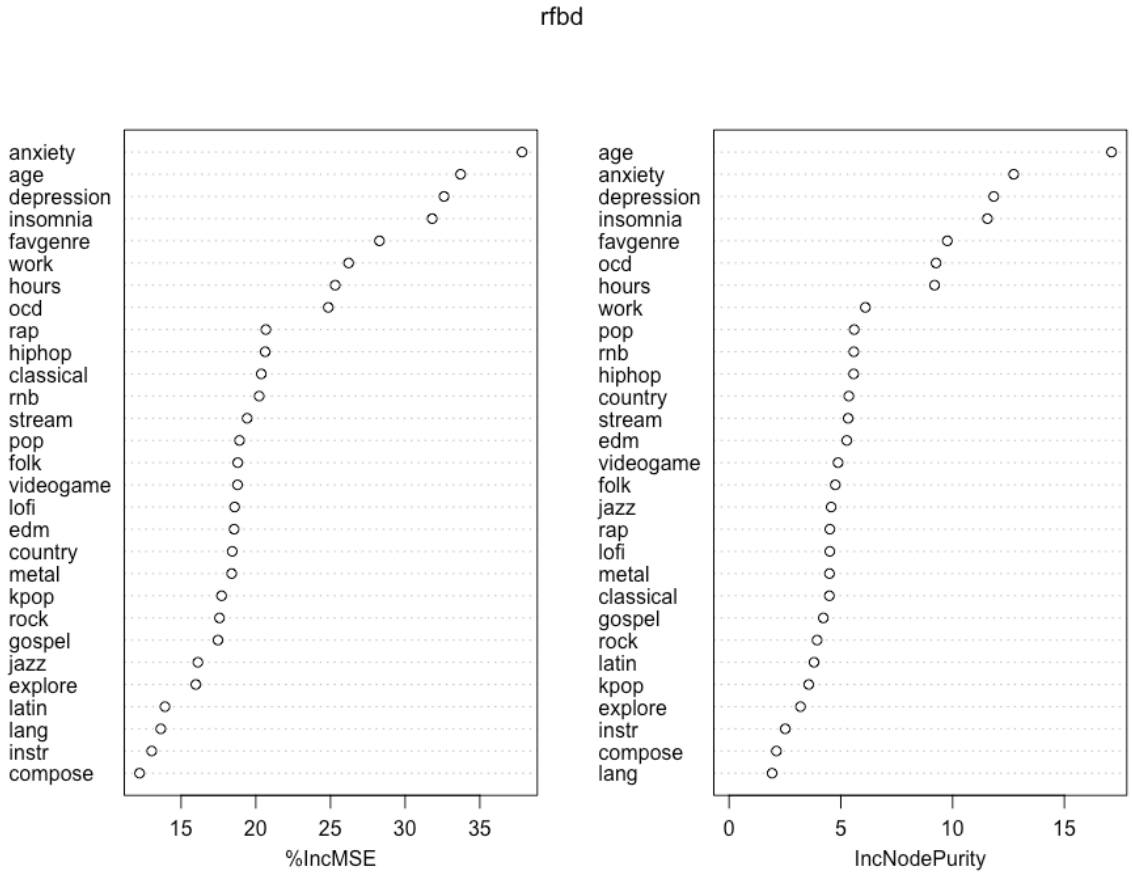

Figura 5.3 Importancia relativa de las variables utilizadas en el algoritmo Random Forest desarrollado con los datos compensados, en porcentaje de incremento del error cuadrado medio, e incremento de la pureza del nodo cuando se selecciona cada variable

Se observa que la edad y las variables relacionadas con la salud mental siguen siendo las más importantes, principalmente la edad y la ansiedad. En esto el resultado se asemeja a lo obtenido originalmente. El género favorito también parece tener bastante influencia, aunque esta variable puede estar contenida en todas las demás variables de frecuencia de escucha de los géneros.

5.3 MÁQUINAS DE VECTOR SOPORTE (SVM)

Se desarrollaron también máquinas de vector soporte para estos nuevos datos. La división train:test fue del 75:25, y en cada caso se escalaron los datos para tener media 0 y desviación típica 1.

Se calcularon máquinas de vector soporte con divisiones lineales, polinómicas y radiales, y se aplicaron a los conjuntos de prueba, obteniéndose los siguientes resultados:

5.3.1 SVM Lineal

SVM (kernel lineal)		Valores reales	
		Yes	**No**
Valores predichos	Yes	85	47
	No	54	85

Tabla 5.2 Predicciones sobre el conjunto de prueba utilizando la máquina de vector soporte lineal desarrollada con los datos compensados

La precisión para la máquina con división lineal es del 62.73%. No es muy alta, por lo que podemos deducir que la división de las regiones es más compleja que un simple hiperplano.

5.3.2 SVM Polinómica

SVM (kernel polinómico)		Valores reales	
		Yes	**No**
Valores predichos	Yes	11	5
	No	28	127

Tabla 5.3 Predicciones sobre el conjunto de prueba utilizando la máquina de vector soporte polinómica desarrollada con los datos compensados

La SVM polinómica tiene una precisión del 87.82%, muy superior a la anterior, pero parece tener una tendencia a predecir el valor “No”. Es posible que las regiones en las que hay varios datos con salida “No” hayan sido sobrerrepresentadas al haber puntos repetidos.

5.3.3 SVM Radial

kNN (n=3)		Valores reales	
		Yes	**No**
Valores predichos	Yes	114	5
	No	25	127

Tabla 5.4 Predicciones sobre el conjunto de prueba utilizando la máquina de vector soporte radial desarrollada con los datos compensados

Con una precisión del 88.93%, esta es la SVM que mejor funciona, en teoría. Es probable que, al ser radial, haya creado pequeñas “regiones” alrededor de los puntos “No” por estar repetidos, y esto infle su precisión real.

5.4 REGRESIÓN LOGÍSTICA

Se realizó una regresión logística con estos nuevos datos. Se comenzó por realizar la regresión introduciendo todas las variables independientes:

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-1.643	0.415	-3.960	0.000	***
age	-0.003	0.007	-0.500	0.617	
hours	-0.014	0.023	-0.594	0.552	
work	0.781	0.167	4.682	0.000	***
instr	0.506	0.173	2.919	0.004	**
compose	0.409	0.211	1.938	0.053	.
explore	0.678	0.159	4.259	0.000	***
lang	-0.143	0.150	-0.952	0.341	
classical	-0.194	0.076	-2.553	0.011	*
country	0.218	0.083	2.629	0.009	**
edm	0.031	0.069	0.446	0.655	
folk	-0.116	0.079	-1.476	0.140	
gospel	0.194	0.114	1.709	0.087	.
hiphop	0.096	0.112	0.855	0.392	
jazz	0.030	0.084	0.350	0.726	
kpop	0.018	0.080	0.230	0.818	
latin	0.027	0.090	0.297	0.767	
lofi	0.004	0.077	0.050	0.960	
metal	-0.007	0.073	-0.093	0.926	
pop	-0.003	0.084	-0.039	0.969	
rnb	0.219	0.086	2.543	0.011	*
rap	-0.160	0.109	-1.475	0.140	
rock	-0.084	0.081	-1.034	0.301	
videogame	-0.004	0.072	-0.054	0.957	
anxiety	0.128	0.029	4.399	0.000	***
depression	-0.027	0.027	-1.012	0.311	
insomnia	-0.022	0.023	-0.953	0.341	
ocd	-0.021	0.025	-0.847	0.397	
apple	0.050	0.337	0.148	0.882	
other	0.095	0.325	0.293	0.769	
pandora	15.319	430.007	0.036	0.972	
spotify	0.237	0.236	1.005	0.315	
youtube	0.311	0.282	1.101	0.271	

Tabla 5.5 Resultados de la regresión logística para predecir la variable “efecto” utilizando todas las demás variables como predictoras, calculada con los datos compensados

La desviación de los residuales es de 1343.5 para 1049 grados de liberta, por lo que el p-valor de la regresión es 1.56e-09. Este valor es prácticamente cero, por lo que no podemos admitir que sea estadísticamente significativo. La precisión sobre los datos utilizados es del 66.54%, lo cual no es muy alto.

Tras aplicar el método stepwise, las variables seleccionadas para repetir el modelo fueron work, instr, compose, explore, classical, country, folk, gospel, rnb, rock, anxiety, insomnia y pandora. Se repitió la regresión con estas variables.

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-1.610	0.264	-6.095	0.000	***
work	0.731	0.156	4.684	0.000	***
instr	0.521	0.167	3.128	0.002	**
compose	0.391	0.205	1.911	0.056	.
explore	0.701	0.146	4.800	0.000	***
classical	-0.181	0.070	-2.567	0.010	*
country	0.218	0.081	2.697	0.007	**
folk	-0.117	0.075	-1.558	0.119	
gospel	0.195	0.110	1.770	0.077	.
rnb	0.206	0.065	3.168	0.002	**
rock	-0.113	0.070	-1.620	0.105	
anxiety	0.105	0.024	4.413	0.000	***
insomnia	-0.032	0.022	-1.466	0.143	
pandora	15.167	427.373	0.035	0.972	

Tabla 5.6 Resultados de la regresión logística para predecir la variable “efecto” utilizando las variables seleccionadas por el método stepwise como predictoras, calculada con los datos compensados

La desviación de los residuales es de 1351.3, con 1068 grados de libertad, lo cual supone un p-valor de 6.98e-09. La precisión en esta nueva regresión es del 65.99%.

Se repitió el modelo ignorando la variable pandora, puesto que presenta un p-valor muy cercano a 1, y un coeficiente inusualmente alto. Al tener tan poca prevalencia, es probable que haga que una o dos predicciones más sean correctas, pero se trata de sobrerrepresentación y no de un efecto real de la relación entre estas variables.

Variable	Estimate	Std. Error	z value	Pr(>|z|)	
(Intercept)	-1.599	0.263	-6.073	0.000	***
work	0.742	0.155	4.775	0.000	***
instr	0.521	0.166	3.145	0.002	**
compose	0.378	0.204	1.848	0.065	.
explore	0.694	0.145	4.774	0.000	***
classical	-0.180	0.070	-2.556	0.011	*
country	0.215	0.080	2.680	0.007	**
folk	-0.117	0.075	-1.570	0.117	
gospel	0.237	0.108	2.191	0.028	*
rnb	0.206	0.065	3.167	0.002	**
rock	-0.113	0.069	-1.633	0.102	
anxiety	0.105	0.024	4.421	0.000	***
insomnia	-0.034	0.022	-1.547	0.122	

Tabla 5.7 Resultados de la regresión logística para predecir la variable “efecto” utilizando como predictoras las variables work, instr, compose, explore, classical, country, folk, gospel, rnb, anxiety e insomnia, calculada con los datos compensados

La desviación de los residuales fue de 1362, con 1069 grados de libertad, lo cual supone un p-valor de 2.47e-09. La precisión fue del 65.25%, lo cual es inferior a los casos anteriores, pero al menos se seleccionaron las variables más significativas, lo cual reduce las posibilidades de sobrerrepresentación.

5.5 BOOTSTRAPPING

Se repitió la regresión mediante bootstrapping ara obtener intervalos de confianza de los coeficientes. Se utilizaron las mismas variables que en la tabla 5.7.

Variable	Estimate	Std. Error	Inferior	Superior
(Intercept)	-1.599	0.263	-2.115	-1.083
work	0.742	0.155	0.438	1.047
instr	0.521	0.166	0.196	0.846
compose	0.378	0.204	-0.023	0.778
explore	0.694	0.145	0.409	0.979
classical	-0.180	0.070	-0.317	-0.042
country	0.215	0.080	0.058	0.372
folk	-0.117	0.075	-0.264	0.029
gospel	0.237	0.108	0.025	0.449
rnb	0.206	0.065	0.078	0.333
rock	-0.113	0.069	-0.249	0.023
anxiety	0.105	0.024	0.058	0.152
insomnia	-0.034	0.022	-0.076	0.009

Tabla 5.8 Intervalos de confianza calculados por bootstrapping para los coeficientes de la regresión logística para predecir la variable “effect”, utilizando como predictoras las mismas variables de la tabla 5.7

Se obtuvo una raíz de los errores cuadráticos de 0.477, un error absoluto medio de 0.444 y un R^2 de 0.099. Los valores centrales son idénticos a los de la regresión logística. Los intervalos son bastante amplios, pero menos que en los calculados por bootstrapping con los datos originales. Se observa que algunas variables no tienen significancia, con una confianza del 95%: aquellas cuyos intervalos incluyen el 0: compose, folk, rock e insomnia. Esto coincide con lo obtenido en la regresión del apartado anterior.

6. APLICACIÓN DE LOS MODELOS PREDICTIVOS

6.1 ELABORACIÓN DE UNA NUEVA ENCUESTA

Paralelamente al resto de los análisis, se realizó una nueva encuesta análoga a la principal, con las mismas preguntas y opciones, para utilizar los modelos desarrollados anteriormente, y comprobar hasta qué punto son útiles.

Como en los anteriores modelos no se tuvo en cuenta la variable BPM, se omitió esa pregunta del cuestionario.

Para realizar esta nueva encuesta se utilizó un formulario de Google, en castellano para mayor comprensión de los encuestados, y con todas las respuestas marcadas como obligatorias para evitar la presencia de datos vacíos. La encuesta fue enviada a varios contactos personales el 6 de agosto de 2024, y los propios encuestados la reenviaron, de forma que se obtuvieron 172 respuestas hasta el cierre de la misma, el 17 de agosto de 2024. Los datos fueron entonces exportados para su utilización en un archivo de tipo xls.

6.2 COMPARACIÓN ENTRE POBLACIONES

Existiendo dos encuestas hechas sobre poblaciones diferentes (una en Washington y otra en España), parece conveniente comprobar la diferencia entre ambas poblaciones.

Medida	Encuesta nueva	Encuesta original
Edad Media	37,05	25,14
Edad Mediana	32	21
Horas Media	2,47	3,52
Horas Mediana	2	3
Work %Sí	45,93%	78,95%
Instr %Sí	34,88%	31,91%
Compose %Sí	8,72%	17,19%
Explore %Sí	57,56%	71,53%
Lang %Sí	72,67%	55,30%

Tabla 6.1 Comparación de los valores de las variables numéricas y las binarias entre ambas encuestas

La edad media de los encuestados es casi 12 años mayor en el caso de la nueva, tal vez porque la original se hizo en un ambiente universitario. La media de horas escuchadas es bastante mayor en EEUU también, aunque puede ser achacable a la diferencia de edad.

Con respecto a las variables binarias se observa mucha diferencia en la variable “work”, según la cual un porcentaje mucho más alto de estadounidenses afirman escuchar música mientras trabajan. Tal vez esta diferencia se deba a que un porcentaje mayor de los encuestados en esta encuesta original fueron estudiantes. También más estadounidenses componen, aunque más españoles tocan un instrumento. Los que respondieron a la encuesta original tienden a explorar nueva música más a menudo, mientras que los de la

nueva escuchan más música en lenguas extranjeras, lo cual puede deberse a que, en general, es más común escuchar música de otros países o idiomas en España que en los países anglosajones.

En cuanto a los servicios de streaming preferidos, no parece haber grandes diferencias, más allá de que ninguno de los encuestados en España utiliza Apple Music ni Pandora. En la nueva encuesta, Spotify sigue siendo el más utilizado con mucha diferencia, aunque Youtube Music es más utilizado que en Estados Unidos, y un porcentaje más alto de personas no utilizan asiduamente ninguno.

Stream	Encuesta nueva	Encuesta original
Spotify	59,88%	62.45%
Youtube Music	20,35%	12.79%
Ninguno	15,12%	9.77%
Otros	4,65%	6.74%
Apple Music	0%	6.88%
Pandora	0%	1.38%

Tabla 6.2 Porcentaje de encuestados que eligieron cada servicio de streaming como favorito en cada encuesta

En cuanto a géneros musicales, los más populares son pop y rock en ambas encuestas, aunque en la nueva con mucha mayor diferencia sobre el resto. También se observa una tendencia mucho más alta a escuchar música latina, que es la tercera, tanto en favorita como en asiduidad de escucha, lo cual parecía bastante previsible. Otros géneros como el gospel o la música de videojuegos, no tuvieron ninguna respuesta en la nueva encuesta, y los valores más bajos de escucha.

Género musical	Nueva encuesta		Encuesta original	
	% fav	Media	% fav	Media
Clásica	1,74%	1,35	7.29%	1.34
Country	0,58%	0,87	3.44%	0.82
EDM	3,49%	0,7	4.95%	1.03
Folk	6,40%	1,22	3.99%	1.01
Gospel	0%	0,52	0.83%	0.38
Hip hop	1,16%	0,96	4.68%	1.38
Jazz	1,16%	0,88	2.75%	1.03
Kpop	0%	0,56	3.16%	0.72
Latina	9,88%	1,89	0.28%	0.60
Lo-fi	1,16%	0,54	1.38%	1.07
Metal	2,33%	1,02	12.10%	1.23
Pop	40,12%	2,52	15.68%	2.03
Rap	0%	0,98	3.03%	1.34
R&B	1,74%	0,94	4.81%	1.25
Rock	30,23%	2,13	25.58%	2.08
Videjuegos	0%	0,49	6.05%	1.25

Tabla 6.3 Comparación entre los datos de la encuesta original y los de la nueva del porcentaje de encuestados que eligieron como favorito cada género, y de la media de las variables de frecuencia de escucha de cada género

En la siguiente tabla se presentan los valores medios y medianos de las variables de salud mental:

Medida	Encuesta nueva	Encuesta original
Ansiedad Media	3.99	5.84
Ansiedad Mediana	3	6
Depresión Media	2.29	4.81
Depresión Mediana	1	5
Insomnio Media	2.66	3.76
Insomnio Mediana	2	3
OCD Media	1.72	2.64
OCD Mediana	0	2

Tabla 6.4 Comparación de la media y la mediana obtenidas para las cuatro variables de salud mental entre la encuesta nueva y la original

EFECTO	Encuesta nueva		Encuesta original
	Frecuencia	Porcentaje	Porcentaje
Mejora	121	70,35%	74.42%
Ningún efecto	51	29,65%	23.25%
Empeora	0	0%	2.34%

Tabla 6.5 Comparación de los valores obtenidos para la variable “effect” entre la encuesta nueva y la original

Se observa que, a diferencia de la encuesta original, en la nueva, la media y mediana de insomnio superan a la depresión. La ansiedad es nuevamente la más alta, lo cual es bastante normal dado que es más común.

Todos los valores son más altos en la encuesta original. Como se vio, la gente joven tiende a proporcionar valores más altos en estas variables, y dada la diferencia de edad media entre ambas muestras, puede explicar, al menos en parte, esta diferencia en la salud mental.

En cuanto al efecto, el porcentaje de personas que afirman mejorar es ligeramente más alto en la encuesta original, pero también lo es el de personas que afirman empeorar. De hecho, en la nueva encuesta, ninguno de los encuestados afirma empeorar con la escucha de música.

Se comprobó también si existen las mismas relaciones entre las variables de salud mental.

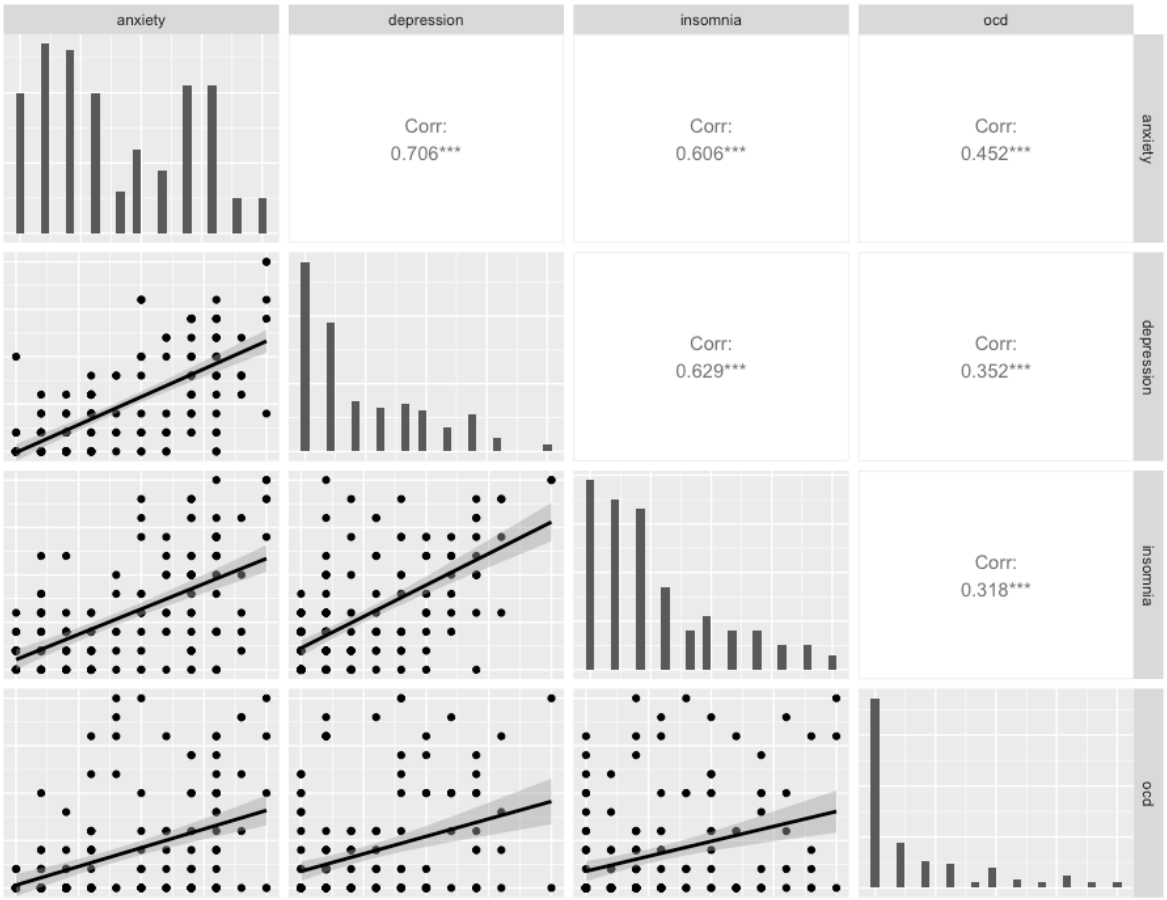

Figura 6.1 Correlaciones entre las cuatro variables relacionadas con trastornos de salud mental en los datos de la nueva encuesta

Las correlaciones son, igual que en el caso de la encuesta anterior, todas positivas. Los valores son todos bastante más altos, lo cual indica que, aunque sus valores fuesen más bajos, es más probable que una persona sufra varios trastornos de salud mental al mismo tiempo. Ansiedad, depresión e insomnio tienen correlaciones bastante fuertes entre ellas, todas ellas superiores a 0.6. La más alta es nuevamente la existente entre la ansiedad y la depresión.

Realizando un test T^2 de Hotelling, se obtuvo un valor de $T^2 = 922.34$, lo cual proporciona un p-valor de prácticamente 0, por lo que podemos rechazar la hipótesis nula de que las poblaciones son iguales. Se puede concluir, por tanto, que las poblaciones que respondieron a ambas encuestas son significativamente diferentes.

6.3 PREDICCIONES CON LOS DATOS ORIGINALES

Se utilizarán algunos de los modelos desarrollados anteriormente para una nueva encuesta. En primer lugar, los modelos desarrollados con los datos originales (sin la compensación de categorías de respuesta).

Se realizaron las transformaciones necesarias para que la forma de los datos coincidiese con la de la base de datos original. Por ejemplo, para algunos modelos se centraron los

datos, por lo que hubieron de centrarse en esta nueva base de datos, utilizando la media y desviación típica de la variable original (no de la nueva encuesta). También se tuvo que tener en cuenta si se introdujeron las variables categóricas como tal, o si se utilizaron variables “dummy” binarias.

También se comprobó que no faltase ningún dato (en esta ocasión no falta ninguno).

Como se puede ver en la tabla 6.5, nadie respondió que empeora en la pregunta “efecto”, por lo que la respuesta “real” siempre será binaria. Sin embargo, se aplicarán también algunos de los métodos que incluían esta tercera opción, sin necesidad de variar la respuesta de estos nuevos datos.

Predicción Árbol 1		Valores reales		
		Improve	No effect	Worsen
Valores predichos	Improve	121	51	0
	No effect	0	0	0
	Worsen	0	0	0

Tabla 6.6 Predicciones sobre los datos de la nueva encuesta utilizando el árbol de decisión obtenido en el epígrafe 4.1.1.1

Para el primer árbol desarrollado, se predice la misma respuesta en todos los casos, “mejorar”. Este método no parece válido para este análisis.

Predicción Árbol 3		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	120	50
	No	1	1

Tabla 6.7 Predicciones sobre los datos de la nueva encuesta utilizando el árbol de decisión obtenido en el epígrafe 4.1.2.3

Para este nuevo árbol, solo en dos casos se predijo que el paciente no mejoraría, y solo en uno de ellos acertó.

Resulta obvio que este método tiende a predecir “Mejora” con demasiada facilidad. Veamos si ocurre lo mismo con los modelos obtenidos mediante el algoritmo Random Forest, más robusto que un sólo árbol.

Predicción Random Forest 1		Valores reales		
		Improve	No effect	Worsen
Valores predichos	Improve	109	41	0
	No effect	12	10	0
	Worsen	0	0	0

Tabla 6.8 Predicciones sobre los datos de la nueva encuesta utilizando el modelo Random Forest obtenido en el epígrafe 4.2.1

La precisión de este modelo es del 69.19%, menor que si hubiese predicho en todos los casos “Mejora”.

Se aplicó seguidamente el algoritmo Random Forest con respuesta binaria desarrollado en el epígrafe 4.2.1:

Predicción Random Forest 2		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	120	49
	No	1	2

Tabla 6.9 Predicciones sobre los datos de la nueva encuesta utilizando el modelo Random Forest con respuesta binaria obtenido en el epígrafe 4.2.2

Con este modelo Random Forest, la precisión obtenida es del 70.93%, superior al caso anterior, pero no parece muy viable para predecir cuándo el encuestado no mejora, puesto que solo lo predijo en 3 casos.

Se aplicaron dos de las regresiones logísticas realizadas con los datos originales. En primer lugar, se aplicó la realizada con todas las variables:

Predicción Regresión logística 1		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	87	26
	No	34	25

Tabla 6.10 Predicciones sobre los datos de la nueva encuesta utilizando la regresión logística calculada en el epígrafe 4.4, utilizando todas las variables como predictoras

La precisión es de solamente un 65.12%. Más de la mitad de los casos que se predijeron como “No” fueron erróneos.

Seguidamente, se aplicó la regresión logística con sólo 8 variables explicativas:

Predicción Regresión logística 3		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	94	32
	No	27	19

Tabla 6.11 Predicciones sobre los datos de la nueva encuesta utilizando la regresión logística calculada en el epígrafe 4.4, utilizando como predictoras las variables work, instr, explore, classical, country, rnb, rock y anxiety

La precisión es del 65.70%, y de nuevo falló en más de la mitad de los casos que se predijeron como “No”.

Se utilizó también el modelo desarrollado mediante el algoritmo Boosted Tree, obteniéndose el siguiente resultado:

Predicción Boosted Tree		Valores reales	
		Yes	**No**
Valores predichos	Yes	18	37
	No	33	84

Tabla 6.12 Predicciones realizadas sobre los datos de la nueva encuesta por el modelo Boosted Tree desarrollado con los datos originales en el epígrafe 4.7

La precisión es solo del 59.30%. En este caso se predicen en más ocasiones la respuesta “No”, pero con errores muy altos.

Para los modelos k-Nearest Neighbours se aplicaron los correspondientes a N=3 y N=10, puesto que son los que mejores resultados de precisión sobre el conjunto de prueba dieron en la base de datos original:

Predicción kNN N=3		Valores reales	
		Yes	**No**
Valores predichos	Yes	95	33
	No	26	18

Tabla 6.13 Predicciones realizadas sobre los datos de la nueva encuesta por el modelo kNN desarrollado en el epígrafe 4.8, para N=3

La precisión para N=3 es del 65.70%.

Predicción kNN N=10		Valores reales	
		Yes	**No**
Valores predichos	Yes	114	41
	No	7	10

Tabla 6.14 Predicciones realizadas sobre los datos de la nueva encuesta por el modelo kNN desarrollado en el epígrafe 4.8, para N=10

Con una precisión del 72.09%, éste es el modelo más preciso hasta el momento. Simplemente predice “No” en menos ocasiones, pero en más de la mitad de éstas es correcto. No obstante, el número de errores de tipo I sigue siendo muy alto.

Como estos modelos están desarrollados sobre un conjunto de entrenamiento, se desarrollarán otros que utilicen el 100% de los datos originales, y comprobaremos qué tal predicen la respuesta de los datos de la nueva encuesta.

6.4 PROGRAMACIÓN DE UN NUEVO MODELO kNN

Se procedió a programar un algoritmo k-Nearest Neighbours, utilizando como datos de entrenamiento todos los datos de la encuesta original, para aplicarlo sobre los datos de la nueva.

N	Precisión	N	Precisión
1	65.70%	**16**	70.35%
2	63.37%	**17**	71.51%
3	65.12%	**18**	70.35%
4	66.86%	**19**	70.93%
5	67.44%	**20**	70.93%
6	66.28%	**21**	70.93%
7	69.77%	**22**	70.93%
8	69.19%	**23**	70.35%
9	70.93%	**24**	69.77%
10	70.35%	**25**	69.77%
11	72.09%	**26**	70.35%
12	70.93%	**27**	70.35%
13	70.93%	**28**	70.35%
14	70.93%	**29**	70.35%
15	70.93%	**30**	70.93%

Tabla 6.15 Precisiones del modelo kNN realizado para los 30 primeros valores de N, utilizando como conjunto de entrenamiento los datos de la encuesta original y como conjunto de prueba los de la nueva encuesta

Las precisiones son menores, en general, que para el kNN original, lo cual tiene sentido, puesto que los datos que conformaban los conjuntos de entrenamiento y prueba pertenecían a la misma población, y, como ya se comprobó, las poblaciones son significativamente diferentes.

El modelo más preciso es el desarrollado para 11 puntos "vecinos", con una precisión del 72.09%. Para muchos otros modelos, la precisión ascendió al 70.93%. De estos, el que tenía el menor número de puntos cercanos buscados, fue n=9. Se comprobaron los resultados para estos dos modelos:

Predicción Nuevo kNN N=9		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	117	46
	No	4	5

Tabla 6.16 Predicciones realizadas sobre los datos de la nueva encuesta por el modelo kNN desarrollado utilizando todos los datos originales como conjunto de entrenamiento, para N=9

Predicción Nuevo kNN N=11		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	119	46
	No	2	5

Tabla 6.17 Predicciones realizadas sobre los datos de la nueva encuesta por el modelo kNN desarrollado utilizando todos los datos originales como conjunto de entrenamiento, para N=11

Al igual que con otros modelos, en muy pocos casos se predice "No". En el caso de n=11, acertó en 5 de 7 de estos casos, pero sigue habiendo un número muy grande de errores de tipo I.

6.5 PREDICCIONES CON LOS DATOS COMPENSADOS

A continuación, se aplicaron algunos de los algoritmos desarrollados con la base de datos "equilibrada" en cuanto a respuesta. Existe el peligro de que estos modelos sean muy buenos representando los valores "No" de estos datos originales, pero de forma demasiado específica, por lo que no serían reproducibles a otras muestras distintas.

En primer lugar, se aplicó el algoritmo Random Forest desarrollado con estos datos:

Predicción Random Forest		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	26	46
	No	25	75

Tabla 6.18 Predicciones sobre los datos de la nueva encuesta utilizando el Random Forest desarrollado con los datos compensados en el epígrafe 5.2

Como es de esperar, predice "No" en muchas más ocasiones que en los casos anteriores, pero ahora, con un error tipo II muy elevado. La precisión es de solamente el 58.72%.

Veamos ahora los resultados de aplicar los modelos predictivos del tipo máquina de soporte vectorial. Se desarrollaron 3, una lineal, una polinómica y una radial. En los conjuntos de prueba de los datos con los que se desarrollaron, mostraron una precisión creciente en este mismo orden.

Predicción SVM (kernel lineal)		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	9	14
	No	107	42

Tabla 6.19 Predicciones sobre los datos de la nueva encuesta utilizando la Máquina de Vector Soporte con kernel lineal desarrollada con los datos compensados

En este caso, la división lineal por medio de un hiperplano hace que en la mayoría de casos se prediga "No", con una precisión de tan solo el 32.56%. Parece que los datos son

tan distintos de los originales que este hiperplano sería completamente diferente si se hubiese desarrollado con los nuevos.

Predicción SVM (kernel polinómico)		**Valores reales**	
		Yes	**No**
Valores predichos	Yes	24	51
	No	70	27

Tabla 6.20 Predicciones sobre los datos de la nueva encuesta utilizando la Máquina de Vector Soporte con kernel polinómico desarrollada con los datos compensados

Para el kernel polinómico, sigue prediciéndose en más de la mitad de los casos "No", con una precisión del 45.35%.

Predicción SVM (kernel radial)		Valores reales	
		Yes	**No**
Valores predichos	Yes	9	31
	No	42	90

Tabla 6.21 Predicciones sobre los datos de la nueva encuesta utilizando la Máquina de Vector Soporte con kernel radial desarrollada con los datos compensados

La precisión en la máquina de soporte vectorial radial es del 57.56%. En este caso predice correctamente muchos valores "Sí", pero es muy imprecisa prediciendo valores "No". Esto puede deberse a que en los datos originales se otorgó más peso a los datos que tenían como respuesta "No", generando "zonas" de predicción "No" en torno a hiperespacios demasiado específicos a estos datos.

Al igual que al desarrollar los datos, la SVM de kernel radial es la que acierta en un número mayor de casos, y la lineal, la que menos. Sin embargo, todas las precisiones son muy débiles, por lo que no son buenos modelos para predecir datos de diferentes poblaciones.

Se aplicaron las regresiones logísticas desarrolladas con los datos equilibrados a los obtenidos en la nueva encuesta. En primer lugar, se utilizó la regresión en la que se utilizaron todas las variables como predictoras:

Predicción Regresión Logística 1		Valores reales	
		Yes	**No**
Valores predichos	Yes	41	13
	No	80	38

Tabla 6.22 Predicciones sobre los datos de la nueva encuesta utilizando la regresión logística calculada con los datos compensados en el epígrafe 5.4, utilizando todas las variables como predictoras

Nuevamente, el error tipo II es muy elevado, lo cual nos indica una sobrerrepresentación de los datos con respuesta "No" en los datos que se utilizaron para desarrollar el modelo. La precisión es de un 45.93%.

Se aplicó ahora la regresión con menos variables, las 12 más significativas:

Predicción Regresión Logística 3		Valores reales	
		Yes	**No**
Valores predichos	Yes	24	51
	No	70	27

Tabla 6.23 Predicciones sobre los datos de la nueva encuesta utilizando la regresión logística calculada con los datos compensados en el epígrafe 5.4, utilizando como predictoras las variables work, instr, compose, explore, classical, country, folk, gospel, rnb, rock, anxiety e insomnia

La precisión en esta regresión es similar al caso anterior, de un 43.02%. Nuevamente se predice "No" en demasiados casos.

7. CONCLUSIONES

Si bien parece innegable que existe una relación entre la escucha de música y la mejoría en la salud mental (al fin y al cabo, entre un 70 y un 75% de las personas afirman mejorar de sus trastornos cuando escuchan música), no parece haber relaciones muy fuertes entre las costumbres específicas de escucha.

La edad y la ansiedad fueron las variables que más relación parecían tener con la variable respuesta. Como se interpretó con anterioridad, el caso de la edad puede deberse a una cuestión de “experiencia” o “relativización”, y en el caso de la ansiedad, puede ser que sea la afección más “leve” y asociada al estado de ánimo de las cuatro que se utilizaron, y por ello, está más sujeta que las demás a mejorías rápidas o a corto plazo.

También parecían tener una relación significativa con la mejoría las variables de trastornos de salud mental. Este hecho puede deberse a que no tiene sentido hablar de “mejoría” en personas que no los padecen, y por eso parecen tener correlación con la variable respuesta.

La razón principal de que los modelos no tengan precisiones muy altas, además de la diferencia entre las poblaciones sobre las que se realizó cada encuesta, es que la salud mental es un asunto tremendamente complejo, en el que la escucha de música es solo una pequeña pieza en comparación con otras cuestiones más trascendentales como puede ser la salud, relaciones interpersonales, situación laboral o económica, o, simplemente, predisposición a este tipo de afecciones.

8. BIBLIOGRAFÍA

Relación de textos citados o utilizados como consulta para este trabajo:

- Johnson, Kjell y Kuhn, Max (2013). Applied predictive modeling, Springer.
- Manly, Bryan F. J..; Navarro Alberto, Jorge A. (2018). Multivariate Statistical Methods, CRC Press Taylor & Francis Group.
- Thulin, Måns (2021). Modern Statistics with R, CRC Press, Taylor & Francis Group.
- Hewson, Paul J. (2009). Multivariate Statistics with R, ©Paul Hewson.
- Hellmuth Margulis, Elizabeth (2019). The Psychology of Music: A Very Short Introduction, Alianza editorial.
- Rasgaitis, Catherine; Music & Mental Health Survey, dominio público (Kaggle.com): https://www.kaggle.com/datasets/catherinerasgaitis/mxmh-survey-results, consultado en Julio de 2024.

ANEXO I. Código utilizado

En este anexo, se proporcionan las entradas utilizadas en R para la realización del trabajo. Nótese que no todos los cálculos y operaciones realizadas se utilizaron finalmente para el informe final, ni aparecen en todos los casos en el mismo orden en el que aparecen en el texto.

Se cargaron tres archivos diferentes como datos: los originales (mxmh_survey_results), los datos “compensados” (mxmh2) y los datos de la encuesta nueva (mhnew).

```
library(readr)
mxmh <- read_csv("mxmh_survey_results.csv")
View(mxmh)
names(mxmh)

mxmh<-mxmh[,-c(1,33)]

names(mxmh) <- c("age","stream","hours","work","instr","compose","favgenre",
                 "explore","lang","bpm","classical","country","edm","folk","gospel",
                 "hiphop","jazz","kpop","latin","lofi","metal","pop","rnb","rap","rock",
                 "videogame","anxiety","depression","insomnia","ocd","effect")

View(mxmh)
library(ggplot2)


#Transformación variables ordinales

mxmh[,c(11:26)][mxmh[,c(11:26)] == "Never"] <- '0'
mxmh[,c(11:26)][mxmh[,c(11:26)] == "Rarely"] <- '1'
mxmh[,c(11:26)][mxmh[,c(11:26)] == "Sometimes"] <- '2'
mxmh[,c(11:26)][mxmh[,c(11:26)] == "Very frequently"] <- '3'

mxmh$classical<-as.numeric(mxmh$classical)
mxmh$country<-as.numeric(mxmh$country)
mxmh$edm<-as.numeric(mxmh$edm)
mxmh$folk<-as.numeric(mxmh$folk)
mxmh$gospel<-as.numeric(mxmh$gospel)
mxmh$hiphop<-as.numeric(mxmh$hiphop)
mxmh$jazz<-as.numeric(mxmh$jazz)
mxmh$kpop<-as.numeric(mxmh$kpop)
mxmh$latin<-as.numeric(mxmh$latin)
mxmh$lofi<-as.numeric(mxmh$lofi)
mxmh$metal<-as.numeric(mxmh$metal)
mxmh$pop<-as.numeric(mxmh$pop)
mxmh$rnb<-as.numeric(mxmh$rnb)
mxmh$rap<-as.numeric(mxmh$rap)
mxmh$rock<-as.numeric(mxmh$rock)
mxmh$videogame<-as.numeric(mxmh$videogame)
```

```
View(mxmh)

#Transformación variables binarias

mxmh[,c(4,5,6,8,9)][mxmh[,c(4,5,6,8,9)] == "No"] <- '0'
mxmh[,c(4,5,6,8,9)][mxmh[,c(4,5,6,8,9)] == "Yes"] <- '1'

mxmh$work<-as.numeric(mxmh$work)
mxmh$instr<-as.numeric(mxmh$instr)
mxmh$compose<-as.numeric(mxmh$compose)
mxmh$explore<-as.numeric(mxmh$explore)
mxmh$lang<-as.numeric(mxmh$lang)
View(mxmh)

#Transformación variables categóricas

table(mxmh$favgenre)
genres <- c("classical","country","edm","folk","gospel",
            "hiphop","jazz","kpop","latin","lofi","metal","pop","rnb","rap","rock",
            "videogame")

mxmh$favgenre[mxmh$favgenre == "Classical"] <- 'classical'
mxmh$favgenre[mxmh$favgenre == "Country"] <- 'country'
mxmh$favgenre[mxmh$favgenre == "EDM"] <- 'edm'
mxmh$favgenre[mxmh$favgenre == "Folk"] <- 'folk'
mxmh$favgenre[mxmh$favgenre == "Gospel"] <- 'gospel'
mxmh$favgenre[mxmh$favgenre == "Hip hop"] <- 'hiphop'
mxmh$favgenre[mxmh$favgenre == "Jazz"] <- 'jazz'
mxmh$favgenre[mxmh$favgenre == "K pop"] <- 'kpop'
mxmh$favgenre[mxmh$favgenre == "Latin"] <- 'latin'
mxmh$favgenre[mxmh$favgenre == "Lofi"] <- 'lofi'
mxmh$favgenre[mxmh$favgenre == "Metal"] <- 'metal'
mxmh$favgenre[mxmh$favgenre == "Pop"] <- 'pop'
mxmh$favgenre[mxmh$favgenre == "R&B"] <- 'rnb'
mxmh$favgenre[mxmh$favgenre == "Rap"] <- 'rap'
mxmh$favgenre[mxmh$favgenre == "Rock"] <- 'rock'
mxmh$favgenre[mxmh$favgenre == "Video game music"] <- 'videogame'

View(mxmh)


#NAs

na_rows <- rowSums(is.na(mxmh))
table(na_rows)
which(na_rows==6)

print(mxmh[562,], width=Inf)
mxmh<-mxmh[-562,]
View(mxmh)
```

```
colSums(is.na(mxmh))

#NAs stream work instr compose

table(mxmh$stream)
table(mxmh$work)
table(mxmh$instr)
table(mxmh$compose)

mxmh[is.na(mxmh$instr),]$instr<-0
mxmh[is.na(mxmh$work),]$work<-1

mxmh[is.na(mxmh$stream),]$stream<-"I do not use a streaming service."

#NAs lang

nrow(mxmh)
table(mxmh$lang)
404*100/732

mean(subset(mxmh, lang=="1")$age, na.rm=TRUE)
mean(subset(mxmh, lang=="0")$age, na.rm=TRUE)

table(mxmh$age,mxmh$lang)


a<-mxmh[!is.na(mxmh$age),]
a<-a[!is.na(a$lang),]
colSums(is.na(a))

agelang<-glm(lang ~ age, data=a, family="binomial")

summary(agelang)

which(is.na(mxmh$lang))
mxmh[is.na(mxmh$lang),]

1/(1+exp(-(0.79832-0.02347*14)))
1/(1+exp(-(0.79832-0.02347*15)))
1/(1+exp(-(0.79832-0.02347*31)))

mxmh[is.na(mxmh$lang),]$lang<-1

#NAs bpm

107*100/736
summary(mxmh$bpm)
table(mxmh$bpm)

library(dplyr)
subset(mxmh, bpm<=230) %>% subset(bpm>=50) %>%
```

```
  group_by(favgenre) %>% summarise(meanBPM=mean(bpm, na.rm=TRUE))

mxmh<-mxmh[,-10]
View(mxmh)

#NAs age

print(mxmh[is.na(mxmh$age),], width=Inf)
which(is.na(mxmh$age))
mxmh<-mxmh[-13,]
View(mxmh)

#NAs effect

print(mxmh[is.na(mxmh$effect),], width=Inf)

mean(subset(mxmh, effect=="Improve")$age, na.rm=TRUE)
mean(subset(mxmh, effect=="No effect")$age, na.rm=TRUE)
mean(subset(mxmh, effect=="Worsen")$age, na.rm=TRUE)
mean(mxmh[is.na(mxmh$effect),]$age, na.rm=TRUE)

which(is.na(mxmh$effect))

mxmh <- mxmh[-c(1,2,161,168,338,441,532),]
View(mxmh)

#Análisis numéricas

summary(mxmh$age)
table(mxmh$age)
sd(mxmh$age)
library(moments)
skewness(mxmh$age)
shapiro.test(mxmh$age)
hist(mxmh$age, xlab="Edad", ylab="Frecuencia", main="Edad de los encuestados")

summary(mxmh$hours)
table(mxmh$hours)
mxmh$hours[mxmh$hours <0.25] <- 0.25
mxmh$hours[mxmh$hours > 13] <- 13
summary(mxmh$hours)
skewness(mxmh$hours)
shapiro.test(mxmh$hours)
hist(mxmh$hours, xlab="Horas", ylab="Frecuencia", main="Horas diarias")

#Análisis binarias

apply(mxmh[,c(4,5,6,8,9)],2,table)

for(i in c(4,5,6,8,9)) {
  print(100*prop.table(table(mxmh[,i])))
```

```
}

#Análisis categóricas

table(mxmh$stream)
prop.table(table(mxmh$stream))*100

table(mxmh$favgenre)
prop.table(table(mxmh$favgenre))*100

#Análisis géneros

apply(mxmh[,c(10:25)],2,table)
apply(mxmh[,c(10:25)],2,mean)
apply(mxmh[,c(10:25)],2,median)
apply(mxmh[,c(10:25)],2,sd)

#Análisis salud mental

apply(mxmh[,c(26:29)],2,table)
apply(mxmh[,c(26:29)],2,mean)
apply(mxmh[,c(26:29)],2,median)
apply(mxmh[,c(26:29)],2,sd)
apply(mxmh[,c(26:29)],2,summary)

table(mxmh$effect)

print(mxmh[which(mxmh$effect=="Worsen"), ], width=Inf)

#Relación de la edad con otras variables

max(mxmh$age)
which(mxmh$age==89)
cor(mxmh[-687,]$age,mxmh[-687,]$hours)
plot(mxmh[-687,]$age,mxmh[-687,]$hours)

mean(subset(mxmh, work=="1")$age)
mean(subset(mxmh, work=="0")$age)
median(subset(mxmh, work=="1")$age)
median(subset(mxmh, work=="0")$age)
t.test(subset(mxmh, work=="0")$age, subset(mxmh, work=="1")$age,
        paired=FALSE, conf.level=0.95)

mean(subset(mxmh, instr=="1")$age)
mean(subset(mxmh, instr=="0")$age)
median(subset(mxmh, instr=="1")$age)
median(subset(mxmh, instr=="0")$age)
t.test(subset(mxmh, instr=="0")$age, subset(mxmh, instr=="1")$age,
        paired=FALSE, conf.level=0.95)

mean(subset(mxmh, compose=="1")$age)
```

```
mean(subset(mxmh, compose=="0")$age)
median(subset(mxmh, compose=="1")$age)
median(subset(mxmh, compose=="0")$age)
t.test(subset(mxmh, compose=="0")$age, subset(mxmh, compose=="1")$age,
        paired=FALSE, conf.level=0.95)

mean(subset(mxmh, explore=="1")$age)
mean(subset(mxmh, explore=="0")$age)
median(subset(mxmh, explore=="1")$age)
median(subset(mxmh, explore=="0")$age)
t.test(subset(mxmh, explore=="0")$age, subset(mxmh, explore=="1")$age,
        paired=FALSE, conf.level=0.95)

mean(subset(mxmh, lang=="1")$age)
mean(subset(mxmh, lang=="0")$age)
median(subset(mxmh, lang=="1")$age)
median(subset(mxmh, lang=="0")$age)
t.test(subset(mxmh, lang=="0")$age, subset(mxmh, lang=="1")$age,
        paired=FALSE, conf.level=0.95)


apple<-subset(mxmh, stream=="Apple Music")
pandora<-subset(mxmh, stream=="Pandora")
spoti<-subset(mxmh, stream=="Spotify")
youtube<-subset(mxmh, stream=="YouTube Music")
other<-subset(mxmh, stream=="Other streaming service")
none<-subset(mxmh, stream=="I do not use a streaming service.")


mean(apple$age)
mean(pandora$age)
mean(spoti$age)
mean(youtube$age)
mean(other$age)
mean(none$age)

median(apple$age)
median(pandora$age)
median(spoti$age)
median(youtube$age)
median(other$age)
median(none$age)

ggplot(mxmh, aes(x=stream, y=age, fill=stream)) + geom_boxplot() +
  theme(axis.text.x=element_blank())


#Relaciones géneros y edad

for(i in c(1:16)) {
  n <- genres[i]
```

```
  print(paste(n," ",round(mean(subset(mxmh, favgenre==n)$age),2)))
}


for(i in c(10:25)) {
  print(cor(mxmh[,1],mxmh[,i]))
}

View(mxmh)
table(mxmh$explore,mxmh$stream)
table(mxmh$instr,mxmh$compose)


#Relaciones con horas diarias

ggplot(mxmh, aes(x=stream, y=hours, fill=stream)) + geom_boxplot() +
  theme(axis.text.x=element_blank())

mean(subset(mxmh, work=="1")$hours)
mean(subset(mxmh, work=="0")$hours)
median(subset(mxmh, work=="1")$hours)
median(subset(mxmh, work=="0")$hours)

mean(subset(mxmh, instr=="1")$hours)
mean(subset(mxmh, instr=="0")$hours)
median(subset(mxmh, instr=="1")$hours)
median(subset(mxmh, instr=="0")$hours)

mean(subset(mxmh, compose=="1")$hours)
mean(subset(mxmh, compose=="0")$hours)
median(subset(mxmh, compose=="1")$hours)
median(subset(mxmh, compose=="0")$hours)

mean(subset(mxmh, explore=="1")$hours)
mean(subset(mxmh, explore=="0")$hours)
median(subset(mxmh, explore=="1")$hours)
median(subset(mxmh, explore=="0")$hours)

mean(subset(mxmh, lang=="1")$hours)
mean(subset(mxmh, lang=="0")$hours)
median(subset(mxmh, lang=="1")$hours)
median(subset(mxmh, lang=="0")$hours)

#Binarias

cor(mxmh[,c(4,5,6,8,9)],method="pearson")

#Relaciones Salud Mental

library(GGally)
ggpairs(mxmh[,c(26:29)], lower = list(continuous = "smooth"),
```

```
        diag = list(continuous = "barDiag"), axisLabels = "none")


#PCA

library(ggplot2)
install.packages('factoextra')
library(factoextra)
library(ggfortify)

cent <- mxmh
cent[,c(1,3,10:29)] <- scale(cent[,c(1,3,10:29)], center=TRUE, scale=TRUE)
cent$work <- as.numeric(cent$work)
cent$instr <- as.numeric(cent$instr)
cent$compose <- as.numeric(cent$compose)
cent$explore <- as.numeric(cent$explore)
cent$lang <- as.numeric(cent$lang)
table(cent$stream)
cent$apple <- ifelse(cent$stream=="Apple Music",1,0)
cent$other <- ifelse(cent$stream=="Other streaming service",1,0)
cent$pandora <- ifelse(cent$stream=="Pandora",1,0)
cent$spotify <- ifelse(cent$stream=="Spotify",1,0)
cent$youtube <- ifelse(cent$stream=="YouTube Music",1,0)
regdata <- cent #Para utilizar más tarde en regresiones
cent$improve <- ifelse(cent$effect=="Improve",1,0)
cent$worsen <- ifelse(cent$effect=="Worsen",1,0)
cent<-cent[,-c(2,7,30)]
View(cent)

pca <- prcomp(cent)
options(max.print=99999)
pca
fviz_screeplot(pca)
cor(pca$x[,1],pca$x[,2])
autoplot(pca, data = cent,
         loadings = TRUE, loadings.colour = 'deepskyblue3',
         loadings.label = TRUE, loadings.label.size = 2.5,
         loadings.label.colour = 'red')


#Árbol de decisión

library(tree)
mxmh$effect<-as.factor(mxmh$effect)

set.seed(1)
trows <- sample(1:nrow(mxmh),nrow(mxmh)*0.8)
train <- mxmh[trows,]
test <- mxmh[-trows,]

tree1 <- tree(effect~., train)
```

```
plot(tree1)
text(tree1, pos=1, cex=0.7)
tree1
nrow(tree1$frame)

tree1test <- predict(tree1, test, type = "class")
table(tree1test, test$effect)
(108+1)/146

set.seed(2)
trows <- sample(1:nrow(mxmh),nrow(mxmh)*0.8)
train <- mxmh[trows,]
test <- mxmh[-trows,]

tree2 <- tree(effect~., train)
plot(tree2)
text(tree2, pos=1, cex=0.7)
tree2
nrow(tree2$frame)

tree2test <- predict(tree2, test, type = "class")
table(tree2test, test$effect)
(97+2)/146

set.seed(3)
trows <- sample(1:nrow(mxmh),nrow(mxmh)*0.8)
train <- mxmh[trows,]
test <- mxmh[-trows,]

tree3 <- tree(effect~., train)
plot(tree3)
text(tree3, pos=1, cex=0.7)
tree3
nrow(tree3$frame)

tree3test <- predict(tree3, test, type = "class")
table(tree3test, test$effect)
(95+12)/146

# Variable respuesta binaria

bin<-mxmh
bin$effect<-as.character(bin$effect)
bin$effect[bin$effect == "Worsen"] <- 'No'
bin$effect[bin$effect == "No effect"] <- 'No'
bin$effect[bin$effect == "Improve"] <- 'Yes'
bin$effect<-as.factor(bin$effect)
table(bin$effect)
View(bin)

#Árboles con respuesta binaria
```

```
set.seed(1)
trows <- sample(1:nrow(bin),nrow(bin)*0.8)
train <- bin[trows,]
test <- bin[-trows,]

treeb1 <- tree(effect~., train)
plot(treeb1)
text(treeb1, pos=1, cex=0.7)
tree1
nrow(treeb1$frame)

treeb1test <- predict(treeb1, test, type = "class")
table(treeb1test, test$effect)
106/146

set.seed(2)
trows <- sample(1:nrow(bin),nrow(bin)*0.8)
train <- bin[trows,]
test <- bin[-trows,]

treeb2 <- tree(effect~., train)
plot(treeb2)
text(treeb2, pos=1, cex=0.7)
treeb2
nrow(treeb2$frame)

treeb2test <- predict(treeb2, test, type = "class")
table(treeb2test, test$effect)
(12+85)/146

set.seed(3)
trows <- sample(1:nrow(bin),nrow(bin)*0.8)
train <- bin[trows,]
test <- bin[-trows,]

treeb3 <- tree(effect~., train)
plot(treeb3)
text(treeb3, pos=1, cex=0.7)
treeb3
nrow(treeb3$frame)

treeb3test <- predict(treeb3, test, type = "class")
table(treeb3test, test$effect)
(6+97)/146


# Random Forest

install.packages("randomForest")
library(randomForest)
```

```
29^(1/2)

set.seed(100)
mtry <- tuneRF(mxmh[-30], mxmh$effect, stepFactor=1.5,
                    improve=0.00001, ntreeTry=500, trace=TRUE, plot=TRUE)
print(mtry)

set.seed(100)
trows <- sample(1:nrow(mxmh),nrow(mxmh)*0.7)
train <- mxmh[trows,]
test <- mxmh[-trows,]

set.seed(100)
rf1 <- randomForest(effect~., data=train,
                              mtry=5, ntree=500, importance=TRUE)

rfpred <- predict(rf1, newdata=test)
table(rfpred, test$effect)

treesize <- treesize(rf1)
hist(treesize)
summary(treesize)

round(importance(rf1),2)
varImpPlot(rf1)

#Random Forest binario

set.seed(292)
mtry <- tuneRF(bin[-30], bin$effect, stepFactor=1.5,
                    improve=0.00001, ntreeTry=500, trace=TRUE, plot=TRUE)
print(mtry)

set.seed(292)
trows <- sample(1:nrow(bin),nrow(bin)*0.7)
train <- bin[trows,]
test <- bin[-trows,]

set.seed(292)
rf2 <- randomForest(effect~., data=train,
                         mtry=5, ntree=500, importance=TRUE)

rf2pred <- predict(rf2, newdata=test)
table(rf2pred, test$effect)
(2+153)/(2+153+3+61)

treesize2 <- treesize(rf2)
hist(treesize2)
summary(treesize2)
```

```
round(importance(rf2),2)
varImpPlot(rf2)


#SVM

install.packages('e1071')
library(e1071)

regdata$effect <- ifelse(regdata$effect=="Improve",1,0)
regdata<-regdata[,-c(2,7)]
View(regdata)

set.seed(126)
trows <- sample(1:nrow(regdata),nrow(regdata)*0.75)
train <- regdata[trows,]
test <- regdata[-trows,]

set.seed(589)
tunesvmlin<-tune(svm,factor(effect)~.,data=train,kernel="linear",
                    ranges=list(cost=c(0.001,0.01,0.1,0.5,1,5,10,20)),scale=FALSE)
svmlin <- tunesvmlin$best.model
summary(svmlin)
predlin <- predict(svmlin, test)
table(predlin,test$effect)

set.seed(213)
tunesvmpol<-tune(svm,factor(effect)~.,data=train,kernel="polynomial",
                    ranges=list(cost=c(0.001,0.01,0.1,0.5,1,5,10,20)),scale=FALSE)
svmpol <- tunesvmpol$best.model
summary(svmpol)
predpol <- predict(svmpol, test)
table(predpol,test$effect)

set.seed(125)
tunesvmrad<-tune(svm,factor(effect)~.,data=train,kernel="radial",
                    ranges=list(cost=c(0.001,0.01,0.1,0.5,1,5,10,20)),scale=FALSE)
svmrad <- tunesvmrad$best.model
summary(svmrad)
predrad <- predict(svmrad, test)
table(predrad,test$effect)


#Regresión Logística

logreg <- glm(effect ~., data=regdata, family="binomial")
summary(logreg)
1-pchisq(logreg$deviance,logreg$df.residual)

lrpred <- predict(logreg, newdata=regdata, type="response")
lrpred <- round(lrpred, 0)
```

```
table(lrpred, regdata$effect)
(32+523)/727

# Stepwise

AIC <- step(object=logreg, direction="both", trace=1)
AIC

logreg2 <- glm(effect ~ work + instr + explore + classical + country + rnb +
                    rock + anxiety + pandora, data=regdata, family="binomial")
summary(logreg2)
1-pchisq(logreg2$deviance,logreg2$df.residual)

lr2pred <- predict(logreg2, newdata=regdata, type="response")
lr2pred <- round(lr2pred, 0)

table(lr2pred, regdata$effect)
(25+525)/727

logreg3 <- glm(effect ~ work + instr + explore + classical + country + rnb +
                    rock + anxiety, data=regdata, family="binomial")
summary(logreg3)
1-pchisq(logreg3$deviance,logreg3$df.residual)

lr3pred <- predict(logreg3, newdata=regdata, type="response")
lr3pred <- round(lr3pred, 0)

table(lr3pred, regdata$effect)
(24+526)/727

# k-fold

library(caret)
set.seed(12)
kftrain <- trainControl(method = "repeatedcv",
                            number = 5, repeats = 9)

regdata$effect <- as.factor(regdata$effect)

kfold <- train(effect ~., data = regdata,
                method = "glm", family="binomial",
                trControl = kftrain)

summary(kfold)
1-pchisq(746.84,694)

kfold2 <- train(effect ~   work + instr + explore + classical + country + rnb +
                     rock + anxiety + pandora, data = regdata,
                  method = "glm", family="binomial",
                  trControl = kftrain)
```

```
summary(kfold2)
1-pchisq(757.11,717)

kfold3 <- train(effect ~   work + instr + explore + classical + country + rnb +
                      rock + anxiety , data = regdata,
                    method = "glm", family="binomial",
                    trControl = kftrain)

summary(kfold3)
1-pchisq(762.33,718)

# Bootstrapping

View(regdata)

set.seed(754)
boottrain <- trainControl(method = "boot", number = 999)
boot <- train(effect ~., data = regdata,
                  method = "glm", family="binomial",
                  trControl = boottrain)

summary(boot)
print(boot)

set.seed(367)
boottrain <- trainControl(method = "boot", number = 999)
boot2 <- train(effect ~ work + instr + explore + classical + country + rnb +
                    rock + anxiety, data = regdata,
                  method = "glm", family="binomial",
                  trControl = boottrain)

summary(boot2)
print(boot2)


#Boosted Tree

install.packages('gbm')
library(gbm)

table(regdata$effect)
str(regdata)

set.seed(613)
trows <- sample(1:nrow(regdata),nrow(regdata)*0.75)
train <- regdata[trows,]
test <- regdata[-trows,]

set.seed(613)
BTree <- gbm(effect~., data=train,
```

```
                    distribution="bernoulli",
                    n.trees=5000,
                    interaction.depth=5)
summary(BTree)
bta<-plot(BTree, i="age")
btb<-plot(BTree, i="anxiety")

library(gridExtra)
grid.arrange(bta,btb,ncol=2)

BTpred <- predict(BTree, newdata=test, n.trees=5000, type="response")
BTpred <- ifelse(BTpred>0.5,"1","0")
table(BTpred,test$effect)
(112+8)/(112+8+30+32)

table(test$effect)
144/(144+38)


#kNN

library(class)

set.seed(492)
trows <- sample(1:nrow(regdata),nrow(regdata)*0.75)
train <- regdata[trows,]
test <- regdata[-trows,]

ncol(train)
nrow(test)

table(test$effect)
140/182

set.seed(492)
for(i in 1:30){
  n<-paste("knn",i,sep="")
  z<-paste("k",i,sep="")
  a<-knn(train[,-33],test[,-33],train$effect,k=i)
  assign(n,a)
  assign(z,sum(a==test$effect)/182)
}

print(c(k1,k2,k3,k4,k5,k6,k7,k8,k9,k10,k11,k12,k13,
        k14,k15,k16,k17,k18,k19,k20))

table(knn3,test$effect)
table(knn10,test$effect)


# Regresiones Nivel Mental
```

```
table(mxmh$anxiety)
table(mxmh$depression)
table(mxmh$insomnia)
table(mxmh$ocd)

regdata$anxiety<-mxmh$anxiety
regdata$depression<-mxmh$depression
regdata$insomnia<-mxmh$insomnia
regdata$ocd<-mxmh$ocd
regdata$mh<-regdata$anxiety+regdata$depression+regdata$insomnia+regdata$ocd
View(regdata)

lmanx<-lm(anxiety~.-depression-insomnia-ocd-effect-mh,data=regdata)
summary(lmanx)
AICanx <- step(object=lmanx, direction="both", trace=1)
AICanx
lmanx2<-lm(anxiety~age+explore+lang+folk+pop+apple+metal,data=regdata)
summary(lmanx2)

lmdep<-lm(depression~.-anxiety-insomnia-ocd-effect-mh,data=regdata)
summary(lmdep)
AICdep <- step(object=lmdep, direction="both", trace=1)
AICdep
lmdep2<-lm(depression~age+hours+country+folk+metal+rap+rock+spotify,data=regdata)
summary(lmdep2)

lmins<-lm(insomnia~.-anxiety-depression-ocd-effect-mh,data=regdata)
summary(lmins)
AICins <- step(object=lmins, direction="both", trace=1)
AICins
lmins2<-lm(insomnia~hours+compose+classical+country+edm+metal,data=regdata)
summary(lmins2)

lmocd<-lm(ocd~.-anxiety-depression-insomnia-effect-mh,data=regdata)
summary(lmocd)
AICocd <- step(object=lmocd, direction="both", trace=1)
AICocd
lmocd2<-lm(ocd~age+hours+lang+country+edm,data=regdata)
summary(lmocd2)

library(moments)
summary(regdata$mh)
skewness(regdata$mh)
shapiro.test(regdata$mh)
length(which(regdata$mh==0))

hist(regdata$mh, xlab="mh", ylab="Frecuencia", main="Suma de Salud Mental")

lmmh<-lm(mh~.-anxiety-depression-insomnia-effect-ocd,data=regdata)
summary(lmmh)
```

```
AICmh <- step(object=lmmh, direction="both", trace=1)
AICmh
lmmh2<-lm(mh~age+hours+country+edm+folk+metal+pop+youtube,data=regdata)
summary(lmmh2)


# Salud mental vs Efecto

cor(regdata$anxiety,regdata$effect)
cor(regdata$depression,regdata$effect)
cor(regdata$insomnia,regdata$effect)
cor(regdata$ocd,regdata$effect)
cor(regdata$mh,regdata$effect)


mhlog<-glm(effect~anxiety+depression+insomnia+ocd, data=bin, family="binomial")
summary(mhlog)
1-pchisq(mhlog$deviance,mhlog$df.residual)

mhlogpred <- predict(mhlog, newdata=regdata, type="response")
mhlogpred <- round(mhlogpred, 0)

table(mhlogpred, bin$effect)

step(object=mhlog, direction="both", trace=1)


#DATOS COMPENSADOS

library(readxl)
mxmh2 <- read_excel("mxmh2.xlsx")
View(mxmh2)

mxmh2<-mxmh2[,-c(1,33)]

names(mxmh2) <- c("age","stream","hours","work","instr","compose","favgenre",
                  "explore","lang","bpm","classical","country","edm","folk","gospel",
                  "hiphop","jazz","kpop","latin","lofi","metal","pop","rnb","rap","rock",
                  "videogame","anxiety","depression","insomnia","ocd","effect")

table(mxmh2$effect)

mxmh2[,c(11:26)][mxmh2[,c(11:26)] == "Never"] <- '0'
mxmh2[,c(11:26)][mxmh2[,c(11:26)] == "Rarely"] <- '1'
mxmh2[,c(11:26)][mxmh2[,c(11:26)] == "Sometimes"] <- '2'
mxmh2[,c(11:26)][mxmh2[,c(11:26)] == "Very frequently"] <- '3'

mxmh2$hours<-as.numeric(mxmh2$hours)
mxmh2$anxiety<-as.numeric(mxmh2$anxiety)
mxmh2$depression<-as.numeric(mxmh2$depression)
mxmh2$insomnia<-as.numeric(mxmh2$insomnia)
```

```
mxmh2$ocd<-as.numeric(mxmh2$ocd)

mxmh2$classical<-as.numeric(mxmh2$classical)
mxmh2$country<-as.numeric(mxmh2$country)
mxmh2$edm<-as.numeric(mxmh2$edm)
mxmh2$folk<-as.numeric(mxmh2$folk)
mxmh2$gospel<-as.numeric(mxmh2$gospel)
mxmh2$hiphop<-as.numeric(mxmh2$hiphop)
mxmh2$jazz<-as.numeric(mxmh2$jazz)
mxmh2$kpop<-as.numeric(mxmh2$kpop)
mxmh2$latin<-as.numeric(mxmh2$latin)
mxmh2$lofi<-as.numeric(mxmh2$lofi)
mxmh2$metal<-as.numeric(mxmh2$metal)
mxmh2$pop<-as.numeric(mxmh2$pop)
mxmh2$rnb<-as.numeric(mxmh2$rnb)
mxmh2$rap<-as.numeric(mxmh2$rap)
mxmh2$rock<-as.numeric(mxmh2$rock)
mxmh2$videogame<-as.numeric(mxmh2$videogame)
View(mxmh2)

mxmh2[,c(4,5,6,8,9)][mxmh2[,c(4,5,6,8,9)] == "No"] <- '0'
mxmh2[,c(4,5,6,8,9)][mxmh2[,c(4,5,6,8,9)] == "Yes"] <- '1'

mxmh2$work<-as.numeric(mxmh2$work)
mxmh2$instr<-as.numeric(mxmh2$instr)
mxmh2$compose<-as.numeric(mxmh2$compose)
mxmh2$explore<-as.numeric(mxmh2$explore)
mxmh2$lang<-as.numeric(mxmh2$lang)

genres <- c("classical","country","edm","folk","gospel",
            "hiphop","jazz","kpop","latin","lofi","metal","pop","rnb","rap","rock",
            "videogame")

mxmh2$favgenre[mxmh2$favgenre == "Classical"] <- 'classical'
mxmh2$favgenre[mxmh2$favgenre == "Country"] <- 'country'
mxmh2$favgenre[mxmh2$favgenre == "EDM"] <- 'edm'
mxmh2$favgenre[mxmh2$favgenre == "Folk"] <- 'folk'
mxmh2$favgenre[mxmh2$favgenre == "Gospel"] <- 'gospel'
mxmh2$favgenre[mxmh2$favgenre == "Hip hop"] <- 'hiphop'
mxmh2$favgenre[mxmh2$favgenre == "Jazz"] <- 'jazz'
mxmh2$favgenre[mxmh2$favgenre == "K pop"] <- 'kpop'
mxmh2$favgenre[mxmh2$favgenre == "Latin"] <- 'latin'
mxmh2$favgenre[mxmh2$favgenre == "Lofi"] <- 'lofi'
mxmh2$favgenre[mxmh2$favgenre == "Metal"] <- 'metal'
mxmh2$favgenre[mxmh2$favgenre == "Pop"] <- 'pop'
mxmh2$favgenre[mxmh2$favgenre == "R&B"] <- 'rnb'
mxmh2$favgenre[mxmh2$favgenre == "Rap"] <- 'rap'
mxmh2$favgenre[mxmh2$favgenre == "Rock"] <- 'rock'
mxmh2$favgenre[mxmh2$favgenre == "Video game music"] <- 'videogame'

mxmh2[is.na(mxmh2$instr),]$instr<-0
```

```
mxmh2[is.na(mxmh2$work),]$work<-1

mxmh2[is.na(mxmh2$stream),]$stream<-"I do not use a streaming service."

mxmh2[is.na(mxmh2$lang),]$lang<-1
View(mxmh2)
mxmh2<-mxmh2[,-10]

which(is.na(mxmh2$age))
mxmh2<-mxmh2[-9,]
View(mxmh2)

which(is.na(mxmh2$effect))
mxmh2 <- mxmh2[-c(1083:1090),]

mxmh2$effect <- ifelse(mxmh2$effect=="Improve",1,0)
View(mxmh2)

bin2 <- mxmh2 #Utilizar bin2 para árboles

mxmh2$apple <- ifelse(mxmh2$stream=="Apple Music",1,0)
mxmh2$other <- ifelse(mxmh2$stream=="Other streaming service",1,0)
mxmh2$pandora <- ifelse(mxmh2$stream=="Pandora",1,0)
mxmh2$spotify <- ifelse(mxmh2$stream=="Spotify",1,0)
mxmh2$youtube <- ifelse(mxmh2$stream=="YouTube Music",1,0)
mxmh2<-mxmh2[,-c(2,7)]
View(mxmh2)

nrow(mxmh2)
table(mxmh2$effect)


# Random Forest

install.packages("randomForest")
library(randomForest)
View(bin2)
ncol(bin2)

set.seed(86)
mtrybd <- tuneRF(bin2[-30], bin2$effect, stepFactor=1.5,
                 improve=0.00001, ntreeTry=500, trace=TRUE, plot=TRUE)
print(mtrybd)

set.seed(86)
trows <- sample(1:nrow(bin2),nrow(bin2)*0.7)
train <- bin2[trows,]
test <- bin2[-trows,]

set.seed(86)
rfbd <- randomForest(effect~., data=train,
```

```
                    mtry=13, ntree=500, importance=TRUE)

rfbdpred <- round(predict(rfbd, newdata=test),0)
table(rfbdpred, test$effect)
(175+125)/(175+128+7+18)

treesizebd <- treesize(rfbd)
hist(treesizebd)
summary(treesizebd)

round(importance(rfbd),2)
varImpPlot(rfbd)


# SVM

install.packages('e1071')
library(e1071)

set.seed(659)
trows <- sample(1:nrow(mxmh2),nrow(mxmh2)*0.75)
train <- mxmh2[trows,]
test <- mxmh2[-trows,]

set.seed(392)
tunesvmlin<-tune(svm,factor(effect)~.,data=train,kernel="linear",
                 ranges=list(cost=c(0.001,0.01,0.1,0.5,1,5,10,20)),scale=TRUE)
svmlin <- tunesvmlin$best.model
summary(svmlin)
predlin <- predict(svmlin, test)
table(predlin,test$effect)
(85+85)/(85+85+47+54)

set.seed(253)
tunesvmpol<-tune(svm,factor(effect)~.,data=train,kernel="polynomial",
                 ranges=list(cost=c(0.001,0.01,0.1,0.5,1,5,10,20)),scale=TRUE)
svmpol <- tunesvmpol$best.model
summary(svmpol)
predpol <- predict(svmpol, test)
table(predpol,test$effect)
(127+111)/(127+111+5+28)

set.seed(992)
tunesvmrad<-tune(svm,factor(effect)~.,data=train,kernel="radial",
                 ranges=list(cost=c(0.001,0.01,0.1,0.5,1,5,10,20)),scale=TRUE)
svmrad <- tunesvmrad$best.model
summary(svmrad)
predrad <- predict(svmrad, test)
table(predrad,test$effect)
(127+114)/(127+114+25+5)
```

```
# Regresión Logística

logr1 <- glm(effect ~., data=mxmh2, family="binomial")
summary(logr1)
1-pchisq(logr1$deviance,logr1$df.residual)

logpr1 <- predict(logr1, newdata=mxmh2, type="response")
logpr1 <- round(logpr1, 0)

table(logpr1, mxmh2$effect)
(356+364)/(356+364+177+185)

AICr <- step(object=logr1, direction="both", trace=1)
AICr

logr2 <- glm(effect ~ work + instr + compose + explore + classical + country +
                folk + gospel + rnb + rock + anxiety + insomnia + pandora,
             data=mxmh2, family="binomial")
summary(logr2)
1-pchisq(logr2$deviance,logr2$df.residual)

logpr2 <- predict(logr2, newdata=mxmh2, type="response")
logpr2 <- round(logpr2, 0)

table(logpr2, mxmh2$effect)
(358+356)/(358+356+185+183)

logr3 <- glm(effect ~ work + instr + compose + explore + classical + country +
                folk + gospel + rnb + rock + anxiety + insomnia,
             data=mxmh2, family="binomial")
summary(logr3)
1-pchisq(logr3$deviance,logr3$df.residual)

logpr3 <- predict(logr3, newdata=mxmh2, type="response")
logpr3 <- round(logpr3, 0)

table(logpr3, mxmh2$effect)
(350+356)/(350+356+185+191)


# Bootstrapping (int. confianza)

library(caret)
set.seed(22)
boottrain <- trainControl(method = "boot", number = 999)
boot3 <- train(effect ~ work + instr + compose + explore + classical + country +
                  folk + gospel + rnb + rock + anxiety + insomnia, data = mxmh2,
               method = "glm", family="binomial",
               trControl = boottrain)
```

```
summary(boot3)
print(boot3)


# NUEVA ENCUESTA

#Media y SD para datos centrados

library(readxl)
mhnew <- read_excel("mhnew.xlsx")
View(mhnew)

mhnew<-mhnew[,-c(1,32)]

mhnew[,c(10:25)][mhnew[,c(10:25)] == "Nunca"] <- '0'
mhnew[,c(10:25)][mhnew[,c(10:25)] == "Rara vez"] <- '1'
mhnew[,c(10:25)][mhnew[,c(10:25)] == "A veces"] <- '2'
mhnew[,c(10:25)][mhnew[,c(10:25)] == "Con frecuencia"] <- '3'

mhnew$hours<-as.numeric(mhnew$hours)
mhnew$anxiety<-as.numeric(mhnew$anxiety)
mhnew$depression<-as.numeric(mhnew$depression)
mhnew$insomnia<-as.numeric(mhnew$insomnia)
mhnew$ocd<-as.numeric(mhnew$ocd)

mhnew$classical<-as.numeric(mhnew$classical)
mhnew$country<-as.numeric(mhnew$country)
mhnew$edm<-as.numeric(mhnew$edm)
mhnew$folk<-as.numeric(mhnew$folk)
mhnew$gospel<-as.numeric(mhnew$gospel)
mhnew$hiphop<-as.numeric(mhnew$hiphop)
mhnew$jazz<-as.numeric(mhnew$jazz)
mhnew$kpop<-as.numeric(mhnew$kpop)
mhnew$latin<-as.numeric(mhnew$latin)
mhnew$lofi<-as.numeric(mhnew$lofi)
mhnew$metal<-as.numeric(mhnew$metal)
mhnew$pop<-as.numeric(mhnew$pop)
mhnew$rnb<-as.numeric(mhnew$rnb)
mhnew$rap<-as.numeric(mhnew$rap)
mhnew$rock<-as.numeric(mhnew$rock)
mhnew$videogame<-as.numeric(mhnew$videogame)
View(mhnew)

mhnew[,c(4,5,6,8,9)][mhnew[,c(4,5,6,8,9)] == "No"] <- '0'
mhnew[,c(4,5,6,8,9)][mhnew[,c(4,5,6,8,9)] == "Sí"] <- '1'

mhnew$work<-as.numeric(mhnew$work)
mhnew$instr<-as.numeric(mhnew$instr)
mhnew$compose<-as.numeric(mhnew$compose)
mhnew$explore<-as.numeric(mhnew$explore)
mhnew$lang<-as.numeric(mhnew$lang)
```

```
mhnew$favgenre[mhnew$favgenre == "Clásica"] <- 'classical'
mhnew$favgenre[mhnew$favgenre == "Country"] <- 'country'
mhnew$favgenre[mhnew$favgenre == "EDM"] <- 'edm'
mhnew$favgenre[mhnew$favgenre == "Folk"] <- 'folk'
mhnew$favgenre[mhnew$favgenre == "Gospel"] <- 'gospel'
mhnew$favgenre[mhnew$favgenre == "Hip hop"] <- 'hiphop'
mhnew$favgenre[mhnew$favgenre == "Jazz"] <- 'jazz'
mhnew$favgenre[mhnew$favgenre == "K-pop"] <- 'kpop'
mhnew$favgenre[mhnew$favgenre == "Latina"] <- 'latin'
mhnew$favgenre[mhnew$favgenre == "Lo-fi"] <- 'lofi'
mhnew$favgenre[mhnew$favgenre == "Metal"] <- 'metal'
mhnew$favgenre[mhnew$favgenre == "Pop"] <- 'pop'
mhnew$favgenre[mhnew$favgenre == "R&B"] <- 'rnb'
mhnew$favgenre[mhnew$favgenre == "Rap"] <- 'rap'
mhnew$favgenre[mhnew$favgenre == "Rock"] <- 'rock'
mhnew$favgenre[mhnew$favgenre == "Música de videojuegos"] <- 'videogame'
View(mhnew)

na_rows2 <- rowSums(is.na(mhnew))
table(na_rows2)

mhnew$effect <- ifelse(mhnew$effect=="Mejoran",1,0)

table(mxmh2$stream)
table(mhnew$stream)
mhnew$stream[mhnew$stream == "No suelo utilizar servicios de streaming"] <-
  'I do not use a streaming service.'
mhnew$stream[mhnew$stream == "Youtube Music"] <- 'YouTube Music'
mhnew$stream[mhnew$stream == "Otros"] <- 'Other streaming service'
View(mhnew)

newcent <- mhnew
newcent$spotify <- ifelse(newcent$stream=="Spotify",1,0)
newcent$youtube <- ifelse(newcent$stream=="YouTube Music",1,0)
newcent$other <- ifelse(newcent$stream=="Other streaming service",1,0)
newcent$apple <- 0
newcent$pandora <- 0
newcent<-newcent[,-c(2,7)]
View(newcent)
newreg<-newcent
newcent2<-newcent

newcent$age<-(newcent$age-mean(mxmh$age))/sd(mxmh$age)
newcent$hours<-(newcent$hours-mean(mxmh$hours))/sd(mxmh$hours)
newcent$classical<-(newcent$classical-mean(mxmh$classical))/sd(mxmh$classical)
newcent$country<-(newcent$country-mean(mxmh$country))/sd(mxmh$country)
newcent$edm<-(newcent$edm-mean(mxmh$edm))/sd(mxmh$edm)
newcent$folk<-(newcent$folk-mean(mxmh$folk))/sd(mxmh$folk)
newcent$gospel<-(newcent$gospel-mean(mxmh$gospel))/sd(mxmh$gospel)
newcent$hiphop<-(newcent$hiphop-mean(mxmh$hiphop))/sd(mxmh$hiphop)
```

```
newcent$jazz<-(newcent$jazz-mean(mxmh$jazz))/sd(mxmh$jazz)
newcent$kpop<-(newcent$kpop-mean(mxmh$kpop))/sd(mxmh$kpop)
newcent$latin<-(newcent$latin-mean(mxmh$latin))/sd(mxmh$latin)
newcent$lofi<-(newcent$lofi-mean(mxmh$lofi))/sd(mxmh$lofi)
newcent$metal<-(newcent$metal-mean(mxmh$metal))/sd(mxmh$metal)
newcent$pop<-(newcent$pop-mean(mxmh$pop))/sd(mxmh$pop)
newcent$rnb<-(newcent$rnb-mean(mxmh$rnb))/sd(mxmh$rnb)
newcent$rock<-(newcent$rock-mean(mxmh$rock))/sd(mxmh$rock)
newcent$videogame<-(newcent$videogame-
mean(mxmh$videogame))/sd(mxmh$videogame)
newcent$anxiety<-(newcent$anxiety-mean(mxmh$anxiety))/sd(mxmh$anxiety)
newcent$depression<-(newcent$depression-
mean(mxmh$depression))/sd(mxmh$depression)
newcent$insomnia<-(newcent$insomnia-mean(mxmh$insomnia))/sd(mxmh$insomnia)
newcent$ocd<-(newcent$ocd-mean(mxmh$ocd))/sd(mxmh$ocd)
View(newcent)

newcent2$age<-(newcent2$age-mean(mxmh2$age))/sd(mxmh2$age)
newcent2$hours<-(newcent2$hours-mean(mxmh2$hours))/sd(mxmh2$hours)
newcent2$classical<-(newcent2$classical-mean(mxmh2$classical))/sd(mxmh2$classical)
newcent2$country<-(newcent2$country-mean(mxmh2$country))/sd(mxmh2$country)
newcent2$edm<-(newcent2$edm-mean(mxmh2$edm))/sd(mxmh2$edm)
newcent2$folk<-(newcent2$folk-mean(mxmh2$folk))/sd(mxmh2$folk)
newcent2$gospel<-(newcent2$gospel-mean(mxmh$gospel))/sd(mxmh2$gospel)
newcent2$hiphop<-(newcent2$hiphop-mean(mxmh2$hiphop))/sd(mxmh2$hiphop)
newcent2$jazz<-(newcent2$jazz-mean(mxmh2$jazz))/sd(mxmh2$jazz)
newcent2$kpop<-(newcent2$kpop-mean(mxmh2$kpop))/sd(mxmh2$kpop)
newcent2$latin<-(newcent2$latin-mean(mxmh2$latin))/sd(mxmh2$latin)
newcent2$lofi<-(newcent2$lofi-mean(mxmh2$lofi))/sd(mxmh2$lofi)
newcent2$metal<-(newcent2$metal-mean(mxmh2$metal))/sd(mxmh2$metal)
newcent2$pop<-(newcent2$pop-mean(mxmh2$pop))/sd(mxmh2$pop)
newcent2$rnb<-(newcent2$rnb-mean(mxmh2$rnb))/sd(mxmh2$rnb)
newcent2$rock<-(newcent2$rock-mean(mxmh2$rock))/sd(mxmh2$rock)
newcent2$videogame<-(newcent2$videogame-
mean(mxmh2$videogame))/sd(mxmh2$videogame)
newcent2$anxiety<-(newcent2$anxiety-mean(mxmh2$anxiety))/sd(mxmh2$anxiety)
newcent2$depression<-(newcent2$depression-
mean(mxmh2$depression))/sd(mxmh2$depression)
newcent2$insomnia<-(newcent2$insomnia-
mean(mxmh2$insomnia))/sd(mxmh2$insomnia)
newcent2$ocd<-(newcent2$ocd-mean(mxmh2$ocd))/sd(mxmh2$ocd)
View(newcent2)


#Análisis previo

table(mhnew$effect)
121/172
1-121/172

summary(mhnew$age)
```

```
summary(mhnew$hours)

for(i in c(4,5,6,8,9)) {
  print(100*prop.table(table(mhnew[,i])))
}

apply(mhnew[,c(26:29)],2,mean)
apply(mhnew[,c(26:29)],2,median)

table(mhnew$stream)
prop.table(table(mhnew$stream))*100

table(mhnew$favgenre)
prop.table(table(mhnew$favgenre))*100

apply(mhnew[,c(10:25)],2,mean)

library(GGally)
ggpairs(mhnew[,c(26:29)], lower = list(continuous = "smooth"),
          diag = list(continuous = "barDiag"), axisLabels = "none")


#Comparación de las poblaciones
#Variables categóricas como binarias dummies, todas las variables sin escalar

p1<-mxmh
p1$effect <- ifelse(p1$effect=="Improve",1,0)
p1$apple <- ifelse(p1$stream=="Apple Music",1,0)
p1$other <- ifelse(p1$stream=="Other streaming service",1,0)
p1$pandora <- ifelse(p1$stream=="Pandora",1,0)
p1$spotify <- ifelse(p1$stream=="Spotify",1,0)
p1$youtube <- ifelse(p1$stream=="YouTube Music",1,0)
p1<-p1[,-c(2,7)]

p2<-mhnew
p2$apple <- ifelse(p2$stream=="Apple Music",1,0)
p2$other <- ifelse(p2$stream=="Other streaming service",1,0)
p2$pandora <- ifelse(p2$stream=="Pandora",1,0)
p2$spotify <- ifelse(p2$stream=="Spotify",1,0)
p2$youtube <- ifelse(p2$stream=="YouTube Music",1,0)
p2<-p2[,-c(2,7)]

install.packages("Hotelling")
library(Hotelling)
print(hotelling.test(p1, p2))


#Aplicación de los modelos predictivos (DATOS ORIGINALES)

library(tree)
library(caret)
```

```
library(randomForest)
library(gbm)
library(class)


tree1newpred <- predict(tree1, newdata=mhnew, type = "class")
table(tree1newpred, mhnew$effect)

treeb1newpred <- predict(treeb1, newdata=mhnew, type = "class")
table(treeb1newpred, mhnew$effect)

rf1newpred <- predict(rf1, newdata=mhnew)
table(rf1newpred, mhnew$effect)
(109+10)/172

rf2newpred <- predict(rf2, newdata=mhnew)
table(rf2newpred, mhnew$effect)
122/172

lr1newpred <- predict(logreg, newdata=newcent, type='response')
lr1newpred <- round(lr1newpred, 0)
table(lr1newpred, newcent$effect)
(87+25)/172

lr3newpred <- predict(logreg3, newdata=newcent, type='response')
lr3newpred <- round(lr3newpred, 0)
table(lr3newpred, newcent$effect)
(19+94)/172

btreenewpred <- predict(BTree, newdata=newcent, n.trees=5000, type="response")
btreenewpred <- round(btreenewpred, 0)
table(btreenewpred, newcent$effect)
(18+84)/172

set.seed(492)
trows <- sample(1:nrow(regdata),nrow(regdata)*0.75)
train <- regdata[trows,]

knn3model <- knn(train[,-28],newcent[,-28],train$effect,k=3)
table(knn3model, newcent$effect)
(18+95)/172

knn10model <- knn(train[,-28],newcent[,-28],train$effect,k=10)
table(knn10model, newcent$effect)
(10+114)/172


#Repetir kNN

set.seed(515)
for(i in 1:30){
```

```
  n<-paste("Knn",i,sep="")
  z<-paste("K",i,sep="")
  a<-knn(regdata[,-28],newcent[,-28],regdata$effect,k=i)
  assign(n,a)
  assign(z,sum(a==newcent$effect)/172)
}

print(c(K1,K2,K3,K4,K5,K6,K7,K8,K9,K10,K11,K12,K13,
        K14,K15,K16,K17,K18,K19,K20,K21,K22,K23,K24,K25
        ,K26,K27,K28,K29,K30))

table(Knn9,newcent$effect)

length(Knn11)
table(Knn11,newcent$effect)


#Aplicación de los modelos predictivos (DATOS COMPENSADOS)

rfbdnewpred <- predict(rfbd, newdata=mhnew)
rfbdnewpred <- round(rfbdnewpred, 0)
table(rfbdnewpred, mhnew$effect)
(75+26)/172

library(e1071)

svmlnewpred <- predict(svmlin, newdata=newcent2)
table(svmlnewpred, newcent2$effect)
(42+14)/172

svmpnewpred <- predict(svmpol, newdata=newcent2)
table(svmpnewpred, newcent2$effect)
(51+27)/172

svmrnewpred <- predict(svmrad, newdata=newcent2)
table(svmrnewpred, newcent2$effect)
(90+9)/172

logr1newpred <- predict(logr1, newdata=newreg, type='response')
logr1newpred <- round(logr1newpred, 0)
table(logr1newpred, newreg$effect)
(38+41)/172

logr3newpred <- predict(logr3, newdata=newreg, type='response')
logr3newpred <- round(logr3newpred, 0)
table(logr3newpred, newreg$effect)
(38+36)/172
```